



INVESTICE DO AI INFRASTRUKTURY A JEJICH SOCIOEKONOMICKÉ DOPADY: PŘÍPADOVÁ STUDIE USA A PREDIKČNÍ MODEL PRO ČR

René Kachyňa

Bakalářská práce
Fakulta informačních technologií
České vysoké učení technické v Praze
Katedra softwarového inženýrství
Studijní program: Informatika
Specializace: Softwarové inženýrství
Vedoucí: PhDr. Ing. Tomáš Evan, Ph.D.
15. června 2026



Zadání bakalářské práce

Název:	Investice do AI infrastruktury a jejich socioekonomické dopady: Případová studie USA a predikční model pro ČR
Student:	René Kachyňa
Vedoucí:	PhDr. Ing. Tomáš Evan, Ph.D.
Studijní program:	Informatika
Obor / specializace:	Softwarové inženýrství 2021
Katedra:	Katedra softwarového inženýrství
Platnost zadání:	do konce letního semestru 2027/2028

Pokyny pro vypracování

Cílem práce je prozkoumat dopady stavby datových center pro umělou inteligenci na lokální ekonomiky v USA a na základě těchto zjištění vytvořit predikční model pro Českou republiku. Součástí práce je implementace interaktivní aplikace, která tyto dopady vizualizuje a umožňuje simulaci různých scénářů rozvoje infrastruktury.

Práce bude obsahovat následující části:

1. Rešerše specifických požadavků moderní AI infrastruktury (energetická náročnost, chlazení, prostorové nároky).
2. Sběr a analýza dat o vlivu výstavby datových center v oblastech s vysokou koncentrací těchto investic (ceny energií, trh s bydlením, nezaměstnanost).
3. Identifikace klíčových parametrů a vytvoření modelu pro odhad dopadů potenciální výstavby AI infrastruktury na českou energetickou síť a ekonomiku.
4. Srovnání zjištěných dat z USA s možnostmi a limity České republiky (např. kapacita energetické sítě, legislativa).
5. Návrh a realizace webové aplikace, která slouží jako interaktivní rozhraní pro vizualizaci získaných dat a spouštění simulací predikčního modelu pro ČR.
6. Ověření funkčnosti vytvořeného predikčního modelu na testovacích scénářích a zhodnocení přínosů aplikace pro interpretaci socioekonomických dopadů investic do AI.

České vysoké učení technické v Praze

Fakulta informačních technologií

© 2026 René Kachyňa. Všechna práva vyhrazena.

Tato práce vznikla jako školní dílo na Českém vysokém učení technickém v Praze, Fakultě informačních technologií. Práce je chráněna právními předpisy a mezinárodními úmluvami o právu autorském a právech souvisejících s právem autorským. K jejímu užití, s výjimkou bezúplatných zákonných licencí a nad rámec oprávnění uvedených v Prohlášení, je nezbytný souhlas autora.

Odkaz na tuto práci: Kachyňa René. *Investice do AI infrastruktury a jejich socioekonomické dopady: Případová studie USA a predikční model pro ČR*. Bakalářská práce.

České vysoké učení technické v Praze, Fakulta informačních technologií, 2026.

*Rád bych poděkoval PhDr. Ing. Tomáši Evanovi, Ph.D.,
za vedení této práce.
Dále děkuji své rodině za dlouhodobou a neustávající
podporu během studia.*

Prohlášení

Prohlašuji, že jsem předloženou práci vypracoval samostatně a že jsem uvedl veškeré použité informační zdroje v souladu s Metodickým pokynem o dodržování etických principů při přípravě vysokoškolských závěrečných prací.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona, ve znění pozdějších předpisů, zejména skutečnost, že České vysoké učení technické v Praze má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle § 60 odst. 1 citovaného zákona.

Dále prohlašuji, že jsem v průběhu příprav a psaní závěrečné práce použil nástroje umělé inteligence Gemini Pro 3.1 a Gemini Flash 3.5. Vygenerovaný obsah jsem ověřil. Stvrzuji, že jsem si vědom, že za obsah závěrečné práce plně zodpovídám.

V Praze dne 15. června 2026

Abstrakt

Přestože se uživatelům může umělá inteligence jevit jako nehmotná entita existující v cloudu, její trénování a inference vyžadují rozsáhlou fyzickou infrastrukturu. Výstavba a následný provoz těchto výpočetních center představují jak příležitost pro ekonomiku, tak významnou zátěž pro životní prostředí a elektrizační soustavu. Pro posouzení jejich dopadů v České republice byly na základě empirických dat z USA identifikovány proměnné s největším vlivem na ekonomiku, energetiku a oblast ESG. Tyto poznatky byly následně upraveny s ohledem na specifika České republiky a integrovány do prediktivního matematického modelu.

Výsledky naznačují, že z pohledu národního hospodářství není výstavba datových center jednoznačně přínosná, zejména z důvodu nízké tvorby pracovních míst a omezených daňových příjmů. Významnou limitací je rovněž kapacita přenosové soustavy a lokální dostupnost zdrojů vody pro chlazení. Ze strategického hlediska však rozvoj této infrastruktury hraje důležitou roli v udržení technologické a národní suverenity.

Klíčová slova datová centra, umělá inteligence, Česká republika, prediktivní model

Abstract

Although artificial intelligence may appear to users as an intangible entity existing in the cloud, its training and inference require extensive physical infrastructure. The construction and operation of these data centers represent an economic opportunity while simultaneously posing a challenge to the environment and the power grid. Based on empirical data from the USA, key variables influencing the economy, energy sector, and ESG factors were identified. To assess their impacts in the Czech Republic, these findings were adapted to local conditions and integrated into a predictive mathematical model.

The results suggest that, from a national economic perspective, the development of data centers is not unequivocally beneficial, primarily due to low employment generation and limited tax revenues. Significant constraints include the capacity of the transmission grid and the local availability of water resources for effective cooling. However, from a strategic standpoint, the development of such infrastructure plays a crucial role in maintaining technological and national sovereignty.

Keywords data centers, artificial intelligence, Czech Republic, predictive model

Obsah

Úvod	1
1 Historie DC a dnešní nároky	2
1.1 Historie a architektura	2
1.1.1 Tradiční pojetí DC a standardy spolehlivosti	2
1.1.2 Koncept integrovaného systému WSC	3
1.1.3 Architektura moderních AI továren	4
1.2 Konstrukce a hardware	5
1.2.1 Fyzické parametry serverových skříní	5
1.2.2 Čipy a specializované akcelerátory	5
1.2.3 Vnitřní uspořádání a technické zóny	6
1.3 Energie	6
1.3.1 Příkon a spotřeba datových center	6
1.3.2 Power Usage Effectiveness	7
1.3.3 Odkud datová centra berou energii	8
1.4 Voda a chlazení	8
1.4.1 Thermal Design Power	8
1.4.2 Od vzduchového chlazení ke kapalinovému	9
1.4.3 Odběr a spotřeba vody moderních DC	9
1.5 Faktory pro výběr lokace AI datového centra	10
1.6 Shrnutí	12
2 Výstavba AI DC v USA	13
2.1 Energetická zátěž a rezervace kapacity	13
2.1.1 Přímé dopady připojení AI centra do sítě	13
2.1.2 Socializace nákladů na výstavbu infrastruktury	14
2.1.3 Zdražování velkoobchodní ceny elektřiny	15
2.2 Odběr a spotřeba vody z okolí	15
2.2.1 Přímé dopady AI center na vodní zdroje	15
2.2.2 Srovnání charakteru spotřeby vody a elektřiny	16
2.3 Dopady na ekonomiku	16
2.3.1 Provozní a kapitálové výdaje DC	16
2.3.2 Daně a daňové pobídky	17
2.3.3 Tvorba pracovních míst	18
2.4 Sociální dopady	19
2.5 Shrnutí dat důležitých pro model ČR	19

3	Připravenost ČR na AI DC	21
3.1	Trh datových center v ČR	21
3.1.1	Obecná charakteristika českého trhu s DC	21
3.1.2	Aktuální výstavba a budoucí projekty	22
3.2	Energetika a vodní zdroje v ČR	22
3.2.1	Role ČEPS: Kapacita a stabilita sítě	23
3.2.2	Energetický mix ČR a propojení s Evropou	23
3.2.3	Dostupnost vody pro chlazení	24
3.3	Legislativní a ekonomické prostředí	24
3.3.1	Pobídky, dotace a role Evropské unie	25
3.3.2	Daně a ekonomika	25
3.3.3	Detailnější rozbor DPH	26
3.4	Shrnutí připravenosti ČR na výstavbu AI DC	27
4	Model výstavby AI DC v ČR	29
4.1	Detailní průzkum českého trhu pomocí scraperu	29
4.2	Vymezení modelu	30
4.2.1	Výstupy modelu	31
4.2.2	Nezahrnuté výpočty	31
4.3	Obecný popis modelu	32
4.3.1	Vstupy modelu a typy DC	32
4.3.2	Práce se scénáři	33
4.3.3	Ekonomická část modelu	34
4.3.4	Práce s časovým rozdělením	34
4.4	Metodologie výpočtů	35
4.4.1	Spotřeba datových center	35
4.4.2	Náklady na výstavbu a provoz DC	35
4.4.3	Pracovní místa a zdanění práce	36
4.4.4	Ekologická daň a daň z nemovitosti	37
4.4.5	HPH (Hrubá přidaná hodnota)	37
4.4.6	Environmentální dopady	38
4.4.7	Rozdělení výpočtů do fází výstavby a provozu	39
4.5	Finální struktura modelu	39
5	Vizualizace modelu v aplikaci	41
5.1	Motivace k vytvoření aplikace	41
5.2	Technologický stack	42
5.2.1	Jádro aplikace a správa stavu	42
5.2.2	Uživatelské rozhraní a vizualizace	42
5.3	Architektura aplikace a datový tok	43
5.3.1	Datový tok a správa stavu	44
5.3.2	Struktura projektu a oddělení zodpovědnosti	44
5.4	Dlouhodobá údržba a provoz aplikace	45
5.4.1	Nasazení na server	45

5.4.2	Testování aplikace	46
5.5	Uživatelské rozhraní a průchod aplikací	46
5.5.1	První pohled na model	46
5.5.2	Ovládací panel	47
5.5.3	Záložka Přehled	47
5.5.4	Záložka Elektřina	48
5.5.5	Záložka Ekonomika	49
5.5.6	Záložka ESG	50
5.5.7	Nastavení a debugování	50
6	Testovací scénáře pro model	51
6.1	Metodologie testování	51
6.2	Testovací scénáře	52
6.2.1	Testování v uživatelském rozhraní	52
6.2.2	Testovací scénář 1: Česká republika	52
6.2.3	Testovací scénář 2: Irsko	53
6.2.4	Testovací scénář 3: Německo	55
6.2.5	Testovací scénář 4: USA	55
6.3	Vyhodnocení testování modelu	56
7	Limitace a přínosy práce	57
7.1	Diskuse výsledků získaných z modelu	57
7.2	Limitace	58
7.3	Zhodnocení přínosů práce	59
7.4	Možnosti dalšího rozvoje	60
8	Závěr	61
A	Popis požadavků v klasifikaci Tier	62
B	Vstupní data pro model	63
C	Snímky obrazovky průchodu aplikací	67
	Bibliografie	80
	Obsah příloh	90

Seznam obrázků

C.1	Ukázka prvního pohledu na model po načtení aplikace	68
C.2	Ukázka návodu na použití aplikace	69
C.3	Ukázka stavu aplikace po zadání několika DC	70
C.4	Ukázka návodu na zadání vstupních dat	71
C.5	Ukázka nastavování parametrů pro jednotlivé scénáře	72
C.6	Ukázka zobrazení dopadů zadaných DC na spotřebu elektřiny .	73
C.7	Ukázka obsahu KPI karet pro spotřebu elektřiny	74
C.8	Ukázka zobrazení dopadů zadaných DC na ekonomiku	75
C.9	Ukázka zobrazení dopadů zadaných DC na okolí	76
C.10	Ukázka nastavení zobrazení bez hoveru	77
C.11	Ukázka zobrazení pro ladění modelu	78
C.12	Ukázka zobrazení pro výběr testovacích portfolií	79

Seznam tabulek

1.1	Souhrn požadavků pro klasifikaci Tier	3
1.2	Srovnání instalovaného příkonu	7
1.3	Přehled vývoje TDP	8
2.1	Údaje získané z amerického trhu	20
3.1	Přehled daňových sazeb v ČR pro rok 2026	26
3.2	Shrnutí kvantifikovatelných specifik ČR	28
4.1	Poskytovatelé DC v ČR	30
6.1	Složení portfolia pro testovací scénář Česko	52
6.2	Složení portfolia pro testovací scénář Irsko	53
6.3	Složení portfolia pro testovací scénář Německo	55
6.4	Složení portfolia pro testovací scénář USA	56
B.1	Podrobné parametry modelových scénářů	65

Seznam zkratek

ACC	Annualized Capital Costs (anualizované kapitálové náklady)
AI	Artificial Intelligence (umělá inteligence)
API	Application Programming Interface
B2B	Business-to-Business
BCG	Boston Consulting Group
CAGR	Compound Annual Growth Rate (složená roční míra růstu)
CI/CD	Continuous Integration / Continuous Deployment
CPU	Central Processing Unit (procesor)
CSS	Cascading Style Sheets (kaskádové styly)
D2C	Direct-to-Chip (přímé chlazení čipů kapalinou)
DC	Data Center (datové centrum)
DPFO	Daň z příjmů fyzických osob
DPPO	Daň z příjmů právnických osob
DPH	Daň z přidané hodnoty
ESG	Environmental, Social, and Governance
EU	Evropská unie
FTE	Full-Time Equivalent
GB	Gigabyte
GPU	Graphics Processing Unit (grafický procesor)
GTAI	Germany Trade & Invest
GVA	Gross Value Added (hrubá přidaná hodnota)
GW	Gigawatt
HDP	Hrubý domácí produkt
HPH	Hrubá přidaná hodnota
IEA	International Energy Agency
IT	Informační technologie (Information Technology)
JSON	JavaScript Object Notation
KPI	Key Performance Indicator (klíčový ukazatel výkonnosti)
LLM	Large Language Model (velký jazykový model)
MVA	Megavoltampér
MW	Megawatt
NIMBY	Not In My Back Yard (ne v mém sousedství)
OPEX	Operating Expense (provozní náklady)
OZE	Obnovitelné zdroje energie
PERT	Program Evaluation and Review Technique
PUE	Power Usage Effectiveness

RECG	Regional Economic Consulting Group
SIMT	Single Instruction, Multiple Threads
SSH	Secure Shell (zabezpečený komunikační protokol)
TC	Training Center
TDP	Thermal Design Power
TPU	Tensor Processing Unit
UI	User Interface (uživatelské rozhraní)
UPS	Uninterrupted Power Supply
USA	Spojené státy americké (United States of America)
USD	Americký dolar (United States Dollar)
UX	User Experience (uživatelský zážitek)
WSC	Warehouse-Scale Computer

Úvod

Přestože o nich většina uživatelů internetu nemá ponětí, datová centra tvoří nepostradatelný základ moderního digitálního světa. Jejich role se postupně vyvinula od jednoduchých úložišť dat až po komplexní výpočetní uzly v měřítku celých skladových hal. Zlomovým okamžikem v jejich evoluci se stal nástup generativní umělé inteligence (AI), který radikálně změnil nároky nejen na samotná datová centra, ale také na energetickou infrastrukturu. Oproti tradičním cloudovým službám totiž trénování a provoz moderních AI modelů vyžaduje extrémní výpočetní výkon.

Současná AI infrastruktura čelí kritice kvůli svým environmentálním dopadům, které zahrnují nejen obrovskou spotřebu elektřiny, ale také významné emise skleníkových plynů a narůstající odběr vody. Odhaduje se, že vývoj, trénování a provoz velkých jazykových modelů může během jednoho roku používání vyprodukovat až 160 000 tun uhlíku (jako provoz 30 000 benzinových aut) [1] a odebrat asi 5 miliard litrů sladké vody (což je polovina odběru Spojeného království) [2]. Tato technologická náročnost vytváří bezprecedentní tlak na lokální zdroje v místech, kde se AI datová centra koncentrují.

Ohniskem rozvoje AI infrastruktury jsou v současnosti Spojené státy americké, kde se v nadcházejících letech očekává prudký nárůst poptávky po elektřině vyvolaný zvýšenou poptávkou po výpočetním výkonu. Tento trend se však postupně globalizuje a zasahuje i Evropu. Vzhledem k tomu, že se otevření prvního AI datového centra v České republice očekává již na konci roku 2026 a zprovoznění největšího tuzemského DC je plánováno na začátek roku 2027, je nezbytné včas analyzovat rizika a příležitosti s nimi spojené.

Tato práce slouží jako studie socioekonomických dopadů investic do AI infrastruktury na území USA, které v této oblasti představují nejrozvinutější trh. Cílem je na základě analýzy amerických dat identifikovat klíčové korelace a vytvořit prediktivní model, který umožní simulovat dopady výstavby podobných center v České republice a potenciálně i v dalších zemích čelících AI transformaci. Cílem naopak není hodnotit přínosy umělé inteligence jako takové - model má sloužit k prozkoumání dopadů *fyzické přítomnosti* datových center na území ČR, aniž by zahrnoval jejich produkty.

Historie DC a dnešní nároky

Digitální svět je často vnímán jako nehmotná entita existující v cloudu, ale jeho fyzické základy v podobě datových center procházejí nejvýraznější transformací od dob prvních sálových počítačů. Paradigma datového centra se totiž přesunulo od skladu informací k superpočítači provádějícímu náročné výpočty. [3, s. 11]

Právě tento technologický skok, doprovázený přechodem ke kapalinovému chlazení [4], definuje nové nároky na infrastrukturu i její okolí. Následující text analyzuje historický vývoj těchto staveb, technologické příčiny jejich rostoucí náročnosti a faktory, které v současnosti určují umístění datových center.

1.1 Historie a architektura

Historicky byla datová centra chápána jako zázemí pro ukládání dat a distribuované výpočty, nicméně s rozvojem cloudu a následným nástupem specializovaných AI továren se tato role zásadně proměnila. Tato sekce popisuje, jak se z původních ubytoven pro servery staly integrované výpočetní celky, které dnes fungují jako jeden monolitický superpočítač. [3, 5, 6]

1.1.1 Tradiční pojetí DC a standardy spolehlivosti

Rihards Balodis a Inara Opmane [7, s. 180–181] v roce 2012 definovali datové centrum jako specializované fyzické prostředí určené pro bezpečné umístění počítačových systémů a jejich komponent. Jeho nezbytné zázemí tvoří systémy pro distribuci a zálohování elektřiny, redundantní komunikační rozvody, klimatizace, systémy požární ochrany a prvky fyzického zabezpečení objektu.

Modernější definice datových center zahrnují i samotná výpočetní zařízení. Například podle odborného článku z roku 2020 v časopise Facilities [8] je DC definováno jako významná infrastruktura obsahující velké množství serverů a počítačů, která poskytuje internetové služby společností po celém světě.

Tabulka 1.1 Souhrn požadavků pro klasifikaci Tier [9, s. 13]. N označuje kritickou kapacitu nezbytnou pro podporu aktuálního IT zatížení

Parametr	Tier I	Tier II	Tier III	Tier IV
Dostupnost	99,671 %	99,741 %	99,982 %	99,995 %
Redundance komponent	N	N+1	N+1	>2N
Distribuční cesty	1	1	1 akt., 1 zálož.	2 akt.
Souběžná udržitelnost	Ne	Ne	Ano	Ano
Odolnost proti poruchám	Ne	Ne	Ne	Ano

Historicky tak byla datová centra vnímána především jako *budovy*, jež mají poskytovat vhodné podmínky pro provoz počítačových systémů. Novější definice vnímá datové centrum nejen jako budovu, ale jako soubor vybavení pro zpracování, ukládání a přeposílání informací. Oba texty se však shodují v tom, že datová centra vyžadují speciální komunikační nástroje a subsystémy pro napájení, regulaci okolní teploty a vlhkosti vzduchu [7, 8].

Výše uvedené klíčové subsystémy ovlivňují výslednou dostupnost služeb pro koncové uživatele. Za účelem sjednocení těchto požadavků navrhla organizace Uptime Institute čtyři třídy DC v rámci celosvětově uznávané klasifikace Tier [9]. Tato certifikace definuje úrovně, které se od sebe liší zejména mírou redundance komponent a konfigurací distribučních cest pro provoz IT vybavení.

Souhrn parametrů pro jednotlivé úrovně Tier uvádí tabulka 1.1, detailnější popis je obsažen v příloze A. Tato klasifikace tvoří vrchol éry, v níž byla spolehlivost definována fyzickou redundancí komponent. S nástupem virtualizace se však pozornost přesunula k softwarově definované infrastruktuře.

1.1.2 Koncept integrovaného systému WSC

Na přelomu tisíciletí se začalo formovat nové paradigma distribuovaných výpočtů. Namísto delegování zátěže na koncová zařízení (osobní počítače) se požadavky na výkon a kapacitu přesunuly do centralizované infrastruktury [5]. Tento koncept poskytování škálovatelného výpočetního výkonu, softwaru a úložiště prostřednictvím internetu se nazývá Cloud Computing [10].

Právě Cloud Computing umožnil vývoj softwarových systémů s nároky, které řádově přesahovaly možnosti izolovaných uživatelských zařízení – úzkým místem se tak stala infrastruktura samotného provozovatele softwaru. V reakci na tyto potřeby vznikly mohutnější a výkonnější výpočetní celky s vyšší kapacitou, které L. A. Barroso definuje jako Warehouse-Scale Computers (WSC) [5, 6].

Barroso rozdíl mezi WSC a tradičním DC ilustruje v pěti dimenzích hardwarové a softwarové architektury [5, s. 2–4]:

Homogenita Tradiční datová centra hostí různorodý hardware mnoha firem. WSC zpravidla využívá jednotný hardware pod kontrolou jediné organizace, aby byla zajištěna rychlá nahraditelnost a nákladová efektivita.

Software Zatímco běžný poskytovatel dodává pouze budovu, konektivitu a fyzickou správu hardwaru [11, s. 10], WSC disponuje komplexní softwarovou vrstvou, která propojuje tisíce serverů a umožňuje jim komunikovat.

Škálovatelnost WSC je navržen pro běh masivních internetových služeb využívajících desetitisíce serverů současně. To je umožněno díky efektivní komunikaci mezi servery, kterou běžná DC neposkytují.

Odolnost Tradiční centra se snaží chybám hardwaru předcházet, což je nákladné. WSC naopak s výpadky komponent počítá a řeší je pomocí architektury navržené pro automatickou (graceful) toleranci jejich poruch.

Měřítko WSC bývají o jeden až dva řády větší než běžná podniková datová centra, přičemž veškeré prostředky (dodávky energie, chlazení) jsou sdíleny v rámci společné infrastruktury pro správu zdrojů.

Technologický vývoj se mezi lety 2004 a 2008 soustředil na optimalizaci provozu. Důležitou inovací bylo zavedení metriky PUE, která je popsána v podsektci 1.3.2. Později se začaly objevovat první úlohy zaměřené na hluboké učení (např. projekt Google Brain) [3], což předznamenalo přerod univerzálních WSC v úzce specializovaná AI centra.

1.1.3 Architektura moderních AI továren

Nejmodernější druh datových center se nazývá AI Factory (továrna na AI). Podle slovníku společnosti NVIDIA, předního dodavatele hardwaru pro AI datová centra, jde o specializovanou výpočetní infrastrukturu, která vytváří hodnotu spravováním dat po celou dobu životního cyklu AI. [12]

Popisovaný životní cyklus je iterativní proces zahrnující sbírání dat, trénování a ladění modelu až po jeho hodnocení. Poté se model přesouvá do fáze *inference*, tedy přeměny vstupu na výstupy (dotazování modelu). Koncept AI továrny představuje moderní přístup, který se snaží tyto fáze propojit v jednom datovém centru. V praxi se však zatím provozují zpravidla odděleně:

- **Trénovací centra** jsou navržena pro vysoký a konzistentní výkon, pročež vyžadují pokročilé metody chlazení [13]. Komunikace probíhá v rámci jednoho DC, takže mohou být v odlehlých lokalitách. Jde o novou technologii.
- **Inferenční centra** kladou důraz na efektivitu a nízkou latenci, kvůli čemuž by měla být stavěna v blízkosti optických sítí. Jejich zátěž je vysoce stochastická [13, 14]. Podobají se WSC a jsou již dobře zavedená.

Rozdíl mezi trénovacími centry a WSC spočívá v přechodu od izolovaných úloh k realizaci masivně paralelizovaných výpočtů. Barrosova definice WSC počítá s nezávislostí jednotlivých serverů (jakýkoli server lze díky virtualizaci nahradit). Naproti tomu TC funguje jako jeden logický superpočítač, takže

porucha jediného procesoru může zastavit trénování celého modelu [5, s. 270]. Tato provázanost definuje trénovací centrum jako úzce specializovaný stroj, kde je integrace a rychlost propojení důležitější než kdykoli předtím.

Dalším rozdílem je požadovaná dostupnost: Zatímco tradiční datová a inferenční centra bývají zpravidla Tier III nebo IV, trénovací centra mohou využívat architekturu s nižší úrovní fyzické redundance, často odpovídající úrovni Tier I. Případný výpadek pro ně díky postupnému ukládání stavu nepředstavuje kritické ohrožení služby, ale pouze dočasnou ztrátu výpočetního času [5, s. 83]. Tato optimalizace pro nákladovou efektivitu a rychlost výstavby na úkor drahé dostupnosti umožňuje zkrátit čas potřebný pro vývoj nových modelů, což je pro rychle se vyvíjející odvětví z byznysového hlediska důležité [14, s. 24].

1.2 Konstrukce a hardware

Následující část se zaměřuje na jednotlivé komponenty tvořící a podporující výpočetní výkon datových center. Stežejním tématem je standardizace serverových skříní, fyzická konstrukce moderních akceleratorů a členění vnitřních prostorů datového centra, které musí splňovat extrémní nároky na statické zatížení budov. Zdrojům energie a chlazení DC se věnují sekce 1.3 a 1.4.

1.2.1 Fyzické parametry serverových skříní

Základním stavebním kamenem každého datového centra je *rack*. Jde o standardizovaný kovový rám, do kterého se horizontálně zasouvají a upevňují modulární komponenty (servery, úložiště, síťové přepínače, směrovače, ...). Vnější konstrukce standardního racku je přibližně 1 980 mm vysoká, 580–640 mm široká a 660–760 mm hluboká, ale existují i jiné velikosti. [15, s. 2940]

Podle standardu EIA-310-D má mít běžný rack montážní šířku 19 palců (482,6 mm), což odpovídá standardní šířce předního panelu IT vybavení. Stejný standard definuje jednotku U (1 U = 44,45 mm), která představuje montážní výšku typického IT zařízení. Pokud je tedy rack popsán jako 42U, dokáže pojmout 42 zařízení s výškou 1 U. Specifické komponenty, zejména výkonné AI akcelerátory, však mohou mít kvůli chlazení výšku 4 U, 8 U nebo i více. [16]

Z těchto důvodů standardní racky pro potřeby výkonných AI serverů nepostačují. V. Avelar [17, s. 13–14] doporučuje, aby byly racky pro trénování umělé inteligence širší (např. 750 mm místo 600 mm pro uložení rozvodů kapalinového chlazení), hlubší (přes 1200 mm) a vyšší (48 U a více). Plně osazený AI rack může vážit přes 900 kg, což je potřeba zvážit při jeho přepravě i návrhu DC.

1.2.2 Čipy a specializované akcelerátory

Historicky byla datová centra poháněna univerzálními procesory (CPU), které jsou vynikající pro sériové zpracování složitého, větveného a nepravidelného kódu. Trénování umělé inteligence je však výpočetně velmi specifické – spoléhá

na několik málo operací, které jsou paralelně aplikovány na obrovské množství dat [5, s. 133–134]. CPU tak byly nahrazeny jinými druhy čipů, které jsou pro takto specifické úkoly efektivnější [18, s. 1391].

Mezi používané komponenty patří především grafické procesory (GPU), které obsahují tisíce jednodušších jader (architektura SIMT) užitečných při paralelizaci. Dalším evolučním krokem jsou čipy navržené čistě pro potřeby AI, což je činí efektivnějšími. Za zmínku stojí TPU (Tensor Processing Units) vyvinuté společností Google, které využívají systolická pole – propojenou síť výpočetních jednotek optimalizovaných pro maticové násobení. [5, s. 134–139]

Některé analogie uvádějí, že CPU je jako sportovní auto, protože dokáže velice rychle přepravit pár lidí. Naproti tomu GPU jsou jako autobusy, které sice jedou pomaleji a nevejdou se na všechny cesty, ale dokážou přepravit stovky lidí najednou. Nejsou kvalitativně horší ani lepší, jen slouží k jinému účelu.

1.2.3 Vnitřní uspořádání a technické zóny

Vnitřní dispozice datového centra se člení na dvě hlavní oblasti: White Space a Gray Space. První představuje plochu vyhrazenou pro IT vybavení (racky, síťové prvky a servery). Gray Space naopak zahrnuje plochu pro veškerou podpůrnou infrastrukturu (transformátory, UPS a systémy chlazení) [19, s. 300]. U tradičních DC tvořilo technické zázemí menší část celkové dispozice, přičemž poměr mezi Gray a White Space byl u větších datových center až 1:3 [20].

Extrémní výkonová hustota AI racků však tento poměr mění: Jednak zmenšuje nároky na podlahovou plochu v rámci počítačového sálu (výkon je mnohem více koncentrovaný), jednak vyžaduje větší napájecí a chladicí systémy, které fyzicky zabírají stále více prostoru (zejména kvůli mohutnému potrubí). Jejich vzájemný poměr se tak může posunout až nad hranici 1:1 [20].

1.3 Energie

Energetická infrastruktura se stala hlavním limitujícím faktorem moderních datových center. Tato kapitola analyzuje, jakým způsobem revoluce v oblasti umělé inteligence narušila dekádu trvající stabilitu energetické spotřeby a jaké nároky klade nejen na samotná DC, ale také na sdílenou energetickou síť.

1.3.1 Příkon a spotřeba datových center

Při analýze energetické náročnosti je nezbytné rozlišovat mezi příkonem (jednotka watt) a spotřebou (jednotka watthodina). V tomto kontextu příkon představuje okamžitý odběr elektřiny, který v čase kolísá podle vytížení DC. Příkon dále rozdělujeme na dvě kategorie: celkový příkon definuje horní hranici odběru celého datového centra při 100% vytížení, zatímco instalovaný příkon (IT příkon) definuje horní hranici odběru samotného IT vybavení. Spotřeba pak vyjadřuje množství elektřiny, která byla odebrána za určitý čas.

■ **Tabulka 1.2** Srovnání instalovaného příkonu dle typu datového centra. Vlastní zpracování podle dat od Barrosa [5], IEA [22] a Chen [23]

Typ DC	Instal. příkon	Zaměření
Enterprise DC	< 1 MW	Lokální firemní IT
Cloud Computing	10–50 MW	SaaS, IaaS
Hyperscale AI	100–1 000+ MW	Trénování LLM

Zatímco menší podniková datová centra měla historicky příkon menší než 1 MW [5, 21], větší datová centra určená pro Cloud Computing mají příkon 10 až 50 MW [22, s. 38]. Moderní hyperscale AI trénovací klastry však fungují v úplně jiných mezích – jedno takové zařízení vyžaduje příkon 100 MW až 1 GW [21, 23]. Přehled instalovaného příkonu datových center je uveden v tabulce 1.2.

Instalovaný příkon není směrodatný pro spotřebu – je nutné zvážit jeho skutečné využití. Cloudová DC jsou typicky využívána z asi 33,5 % [5, s. 224], u AI trénovacích center se využití blíží 100 %. Jinými slovy, po dobu trénování modelu se průměrný příkon blíží instalovanému příkonu [17, s. 3]. Příkladem: Pokud ve 200MW datovém centru běží AI servery 80 % času [24, s. 27] (zbylých 20 % jsou prostoje), jeho roční spotřeba činí asi 1,401 TWh. To odpovídá spotřebě Karlovarského kraje za rok 2024 (≈1,5 TWh) [25].

1.3.2 Power Usage Effectiveness

Pro zvýšení efektivity je nutné co největší část spotřebované energie využít na samotný výpočetní výkon, což ale není možné bez podpůrné infrastruktury. Z tohoto důvodu je nutné podrobně analyzovat, kam a v jakém množství energie skutečně proudí. Spotřebu energie v DC proto dále rozdělujeme na [21, 23]:

- **IT vybavení** (servery, disková pole, sítě): zhruba 40–50 % spotřeby.
- **Chladicí infrastrukturu**: tradičně spotřebovává 30–40 % dodané energie.
- **Podpůrná zařízení** (napájení, osvětlení, zabezpečení): zbylých 10–30 %.

K měření celkové efektivity se používá metrika PUE (Power Usage Effectiveness), která udává poměr mezi celkovou energií dodanou do budovy a energií, která skutečně dorazí k IT vybavení [23]:

$$PUE = \frac{\text{Total Facility Electricity Consumption}}{\text{IT Equipment Electricity Consumption}} \geq 1.$$

Zatímco v roce 2010 byla průměrná hodnota PUE datových center po celém světě kolem 2,5 (tzn. na každý 1 watt pro server připadlo 1,5 wattu na chlazení a ztráty), průměr se dnes podařilo snížit na 1,55 [26]. Moderní AI továrny však míří k vyšší efektivitě – Google a Meta uvádějí, že jejich vybraná DC mají PUE pod 1,1 [23, 21], pravděpodobně díky efektivnímu chlazení vodou.

1.3.3 Odkud datová centra berou energii

Většina datových center je napájena z veřejné elektrické sítě. Hyperscale centra se často připojují k vysokonapěťové soustavě (v USA 115–230 kV), zatímco menší DC využívají střední napětí [23, s. 4]. Původ této energie tak závisí na energetickém mixu daného regionu, přičemž celosvětově v napájení DC převažují fosilní paliva. Podíl OZE má v budoucnu růst. [22, s. 86]

Kromě toho je každé centrum vybaveno vlastními záložními (naftovými, plynovými) generátory nebo velkokapacitními palivovými články. Ty mohou sloužit nejen jako záloha, ale i jako primární napájení. Obrovská spotřeba podněcuje trend umisťování AI DC přímo ke zdrojům energie: velké firmy je začínají stavět v bezprostřední blízkosti jaderných elektráren. [23, 13, 22]

1.4 Voda a chlazení

Výkonné čipy není možné chladit vzduchem kvůli jeho fyzikálním vlastnostem, pročež byli designéři datových center nuceni přejít na kapalinové chlazení. Voda totiž disponuje mnohem vyšší tepelnou kapacitou a vodivostí než vzduch, takže dokáže odvést více tepla za kratší čas. To však představuje nový problém – DC se stala závislá na dalším sdíleném zdroji, který musí odněkud čerpat.

1.4.1 Thermal Design Power

Metrika TDP (Thermal Design Power) určuje maximální tepelný výkon jednoho čipu při běžném provozu [27], což je důležité pro návrh chladicího systému. Z prvního zákona termodynamiky zároveň plyne, že TDP je přibližně roven doporučenému příkonu čipu [17]. Tato metrika však neurčuje *maximální* generované teplo – to může být při intenzivních výpočtech krátkodobě vyšší [28].

Ze získané literatury plyne, že za posledních 10 let došlo u IT komponent k obrovskému nárůstu TDP, který způsobily především moderní AI čipy. Nejvýkonnější GPU dnes dosahují TDP až 1400 W, historický přehled je v tabulce 1.3.

■ **Tabulka 1.3** Přehled vývoje TDP grafických procesorů NVIDIA. Tabulka převzata od Schneider Electric [17] a doplněna o nové údaje z dokumentace NVIDIA [29, 30]. Srovnání: CPU servery měly v roce 2010 TDP kolem 120 W, dnes mají asi 400 W [4]

GPU	Paměť	Rok vydání	TDP
V100 SXM2	32 GB	2018	300 W
A100 SXM	80 GB	2020	400 W
H100 SXM	80 GB	2022	700 W
B200 (Blackwell)	186 GB	2025	1000 W
B300 (Blackwell Ultra)	279 GB	2025	1400 W

Mnohem větší problém než růst TDP však představuje fyzická blízkost čipů, která je vynucena požadavky na rychlou synchronizaci při trénování modelů. Na větší vzdálenosti se totiž musí použít velmi drahá [17, s. 4] a energeticky náročná [13, s. 36] optická vlákna, která synchronizaci i tak zpomalují. Návrháři komponent se proto snaží umístit co nejvíce čipů do jednoho serveru, což vede k prostorové koncentraci tepla. Nejnovější AI racky dosahují hustoty výkonu přes 100 kW (běžně 30 až 80 kW), která z fyzikálních důvodů přesahuje možnosti vzduchového chlazení a vynucuje si přechod na chlazení kapalinové. [13, s. 23]

1.4.2 Od vzduchového chlazení ke kapalinovému

Tradiční chlazení vzduchem historicky dominovalo díky své jednoduchosti a nízké ceně, ale postačuje pro racky se spotřebou do 20 kW [17, s. 10]. U AI racků spotřeba stoupá až na 100 kW, kvůli čemuž se kapalinové chlazení stalo absolutní nutností – kapaliny teplo odvádějí efektivněji než vzduch [23, s. 4]. Kvůli tomu je při návrhu datových center potřeba zvážit několik faktorů:

Výhody vodního chlazení Systémy chlazení, kde je kapalina přiváděna přímo k čipu (tzv. Direct-to-Chip), umožňují snížit spotřebu energie na chlazení až o 90 %. Kapalinové chlazení je tedy velmi efektivní – jak již bylo zmíněno, nejnovější datová centra používající tuto technologii dosahují PUE nižší než 1,1 [21, 23]. Nejnovější systémy, jako je immersion cooling (servery jsou plně ponořené v kapalině), dosahují ještě vyšší efektivity ($PUE < 1,03$) a oproti vzduchovému chlazení mají o 95 % nižší spotřebu energie. [13, s. 17–19]

Nevýhody vodního chlazení Vyšší účinnost je však vykoupena vysokými počátečními investicemi a vyšší technologickou náročností. Systémy jako D2C vyžadují specializované chladicí desky na procesorech, těsná potrubí uvnitř racků a jednotky pro distribuci kapaliny [13, s. 18]. Navíc je obtížné přestavět vzduchem chlazená DC na vodní chlazení, neboť nemívají dostatečně vyztužené podlahy (kapalina tvoří další zátěž) [17, s. 11].

Ačkoli je tedy konstrukce vodního chlazení mnohem nákladnější, v dlouhodobém horizontu se tato investice může vrátit v nižších nákladech na elektřinu. Především se ale jedná o technologickou nutnost, která je způsobena zvyšující se hustotou výkonu na jeden rack. Nabízí se ale otázka, kde datová centra vodu na chlazení berou a zda to nepřináší další náklady – finanční i environmentální.

1.4.3 Odběr a spotřeba vody moderních DC

Přechod od vzduchového chlazení k pokročilým kapalinovým systémům dramaticky snížil spotřebu elektrické energie nutnou pro chlazení. Tento zisk v energetické efektivitě je však často na úkor zvýšených nároků na spotřebu vody. Při hodnocení vlivu DC na vodní zdroje je nutné rozlišovat mezi:

- odběrem vody (water withdrawal), který představuje celkový objem sladké vody odčerpané z podzemních nebo povrchových zdrojů;
- a spotřebou vody (water consumption), která označuje nenávratně ztracenou část odebrané vody (nejčastěji se odpařuje do atmosféry); [2]
- platí tedy vztah $\text{Water consumption} \leq \text{Water withdrawal}$.

Datová centra přímo odebírají vodu pro své chladicí systémy (Scope 1). Teplo ze serverů se přenáší do vodního okruhu a v chladicí věži se část této vody cíleně odpaří, čímž se teplo uvolní do okolí. V okruhu by se nicméně mohly koncentrovat minerály, soli a bakterie, takže i nevypařená voda se musí pravidelně vypouštět a neustále doplňovat novou sladkou vodou. Z toho důvodu vyžadují některá vodou chlazená DC neustálý přítok vody, mnohdy pitné. [2]

Mnohem větší zátěž na vodní zdroje však představuje tzv. nepřímý odběr (Scope 2). Jde o vodu odebíranou v elektrárnách, které pokrývají energetickou spotřebu datových center – zejména tepelné či jaderné elektrárny potřebují k výrobě elektřiny masivní chlazení a vodní elektrárny zase ztrácejí vodu odparem z nádrží [2, 24]. V USA je průměrný odběr vody pro výrobu elektřiny odhadován na 43,8 litru na každou spotřebovanou kilowatthodinu [2].

Pro představu, typické 100MW hyperscale datové centrum může spotřebovat kolem 2 milionů litrů vody denně (Scope 2), což odpovídá spotřebě zhruba 6 500 domácností. 60 % z této spotřeby je nepřímá. [22]

1.5 Faktory pro výběr lokace AI datového centra

Ken Baudry [19] uvádí, že výběr lokality funguje vylučovací metodou – začíná se širokým geografickým záběrem a postupně se eliminují místa, která nesplňují kritické požadavky, až zbyde několik málo kandidátů. S nástupem AI datových center se navíc kritéria radikálně zpřísnila. Ta nejdůležitější byla autorem této práce rozdělena do skupin inspirovaných analýzou PESTLE:

Politické faktory Při mezinárodní expanzi podniky zohledňují zákony o ochraně soukromí a geopolitická rizika spojená s tím, kde jsou data fyzicky uložena [19, s. 96]. Důležitá je i stabilita podnikatelského prostředí, protože DC vyžadují obrovské investice. Z pohledu vlád se AI postupně stává záležitostí státní bezpečnosti, jednotlivé státy (nebo celky jako EU) se mohou snažit snížit svou závislost na zahraničních datových centrech, což může způsobit jejich širší distribuci po celém světě [31, s. 25].

Ekonomické faktory Náklady na výstavbu a provoz DC drasticky ovlivňují místní vlády, zejména na území USA. Provozovatelé proto hledají daňové pobídky a úlevy, například odpuštění daně z nemovitosti [19, s. 89–97]. Moderní DC se navíc často stavějí dál od velkých metropolí – v odlehlých oblastech lze rychleji sehnat stavební povolení a také v nich jdou stavět nové rozvodové sítě. [31, s. 25]

Sociální faktory Datová centra ke svému provozu vyžadují kvalifikovaný personál, kvůli čemuž je podle některých zdrojů výhodou blízkost technických univerzit a výzkumných center [19]. To však může vyvolávat představu, že provoz datových center vyžaduje velký počet pracovníků, což je v přímém rozporu s četnými studiemi [32, 33]. Kvalifikovaný personál tedy zapotřebí je, ale v malých počtech, kvůli čemuž blízkost technických univerzit není tak relevantní jako ostatní faktory. Mnohem důležitějším sociálním aspektem jsou iniciativy obyvatel – stavba datových center vyvolává společenské konflikty, protože přímo soutěží o vodní zdroje s místními obyvateli a zemědělstvím [34, s. 4]. Problémy představuje také nepřetržité hučení způsobené chladicími systémy a zhoršená dopravní infrastruktura.

Technologické faktory Dostupnost spolehlivé a levné elektřiny je dnes hlavním faktorem. Protože výstavba nových přenosových soustav trvá 4 až 10 let, datová centra narážejí na přetížené sítě a dlouhé pořadníky pro připojení (fronty mohou trvat i roky). [14, 22] Z tohoto důvodu se nová DC často umísťují ke zdrojům energií, jak je popsáno v kap. 1.3.3. Pro inferenční centra je pak důležitá také konektivita (kap. 1.1.3), kvůli čemuž by měla být stavěna v blízkosti páteřní optické sítě.

Legislativní faktory Z pohledu legislativy je důležité, jakým způsobem je výstavba datových center regulována. V současnosti se již objevují specifické zákony, které se jejich výstavby a provozu přímo týkají. Například v Oregonu byl prosazen zákon, který datová centra zavazuje k alespoň 10letému provozu a zakazuje socializaci nákladů na infrastrukturu. [14, s. 19]

Environmentální faktory Kvůli chlazení se preferují lokality s chladnějším podnebím, které umožňují využívat venkovní vzduch po většinu roku [5, 19]. Pro odpařovací systémy je důležitá i dostupnost vody. Druhým environmentálním faktorem je stabilita a bezpečnost prostředí – lokality se zkoumají z hlediska rizika zemětřesení, záplav, hurikánů, tornád či tsunami. [7, 19]

1.6 Shrnutí

Datová centra prošla za posledních 30 let radikální proměnou. Od sálových počítačů a nezávislých firemních serveroven v 90. letech se průmysl na počátku tisíciletí přesunul k tzv. WSC. Tyto obří komplexy propojily statisíce levných CPU serverů do jednoho fungujícího celku, aby obsloužily globální cloudové služby a vyhledávání. Nástup umělé inteligence však odstartoval novou éru – WSC se mění na AI Factories, což jsou vysoce specializované superpočítače navržené nikoli pro běh mnoha nezávislých úloh, ale pro masivně paralelní trénink velkých jazykových modelů. [5, 6, 19]

Tradiční servery postavené na univerzálních procesorech (CPU) přestaly pro AI stačit. Výpočetní zátěž převzaly specializované akcelerátory (jako GPU a TPU), které jsou optimalizované pro trénování AI. S tím však vzrostl tepelný výkon a energetická spotřeba samotných čipů (TDP) a nutnost umístit je fyzicky co nejblíže k sobě kvůli komunikační latenci. To vedlo k nárůstu výkonové hustoty racků (z tradičních 5–10 kW na 30–100+ kW). [5, 21, 23]

Kvůli tomu spotřeba energie datových center výrazně roste. AI datová centra vstupují do „gigawattové éry“ a zvyšují nároky na svou efektivitu (PUE). Zásadním problémem pro elektrickou síť ale není jen celkový objem, nýbrž pulzní chování AI zátěže – synchronizované výpočty tisíců GPU generují obrovské výkyvy spotřeby v řádu desítek megawattů během milisekund, což ohrožuje frekvenční stabilitu sítě a zhoršuje kvalitu dodávek (harmonické zkreslení, problikávání). Jedno 200MW DC může ročně spotřebovat přibližně 1,4 TWh elektřiny, což je podobně jako spotřeba Karlovarského kraje. [21, 23, 25]

AI racky kvůli vysoké hustotě výkonu nelze spolehlivě chladit vzduchem. Nastupuje proto kapalinové chlazení, které je jak výkonnější, tak energeticky efektivnější. Na druhou stranu vyžaduje vysoké počáteční investice a spotřebuje obrovské množství vody (odpařuje se v chladicích věžích). Do spotřeby vody datovým centrem lze zahrnout také vodu, která byla spotřebována pro výrobu jím odebrané elektřiny. Běžné hyperscale centrum tak může denně spotřebovat až 2 miliony litrů vody, což je podobně jako 6 500 domácností. [1, 13, 22, 34]

Při vybírání lokality pro výstavbu AI datového centra je hlavní prioritou kapacita a propustnost elektrické sítě (často se čeká roky na připojení). Hledají se místa s levnou a stabilní bezuhlíkovou energií (blízkost větrných, solárních či jaderných elektráren), dostatečným zdrojem vody pro chlazení, páteří optickou sítí a příznivým legislativním i daňovým prostředím. [19, 23, 31, 35]

Výstavba AI DC v USA

Historický vývoj spotřeby datových center představuje zajímavý paradox. Mezi lety 2010 a 2018 výpočetní zátěž datových center vzrostla o 550 % a globální úložná kapacita se znásobila 26krát [26, s. 10]. Navzdory tomu zůstávala celosvětová spotřeba elektřiny datovými centry téměř konstantní (zhruba 200 TWh ročně), zejména díky inovacím v systémech chlazení. [5, s. 255]

Kolem roku 2018 však efektivita narazila na své technologické limity a křivka energetické náročnosti začala růst. V roce 2022 dosáhla světová spotřeba DC zhruba 460 TWh (2 % světové poptávky po elektřině) [26, 21] a do roku 2030 by se podle IEA mohla zdvojnásobit [22, s. 14]. Tato kapitola analyzuje dopady takto rozsáhlé výstavby DC na lokální ekonomiky v USA.

2.1 Energetická zátěž a rezervace kapacity

Ve Spojených státech amerických výstavba datových center prokazatelně způsobuje růst cen za dodávky elektrických energií pro běžné domácnosti. Příčinou je jak zdražování silové elektřiny, tak vznikající náklady na vývoj infrastruktury. Cílem této sekce je zmapovat mechanismy zdražování energií na území USA a nastínit komplikace s připojováním DC do elektrizační soustavy.

2.1.1 Přímé dopady připojení AI centra do sítě

Datová centra jsou zdrojem velké a nestabilní zátěže, která se může v krátkém čase změnit až o desítky megawattů. Kvůli tomu je zapotřebí pečlivěji řídit elektrizační soustavu, což s sebou přináší vysoké náklady. Mnohé z těchto efektů se však projeví až při výstavbě většího počtu DC ve stejné lokalitě.

Prvním a nejviditelnějším dopadem jsou extrémní nároky na kapacitu sítě. Moderní AI kampusy vyžadují připojení v řádu stovek MW, přičemž v budoucnu se plánují stavět centra s připojením až 1 GW [23, s. 5]. Existující infrastruktura však na takovou zátěž zpravidla není připravená, kvůli čemuž

vzniká časový nesoulad – zatímco DC lze postavit za 1 až 2 roky, celý proces od plánování až po zprovoznění vysokonapěťové přenosové soustavy trvá 5 až 10 let [14, s. 11, 21, s. 13]. To vede k přetěžování existujících sítí, frontám na připojení a v extrémních případech (v Irsku) i k plošným moratoriím na připojování nových DC, aby nedošlo ke kolapsu dodávek elektřiny [21, s. 14].

Druhým problémem je nestabilita odběru, která je pro AI datová centra charakteristická [21, s. 8–9]. Jejich příkon totiž dokáže během několika sekund klesnout nebo stoupnout o stovky megawattů, obvykle kvůli střídání fáze intenzivního trénování a méně intenzivního zálohování (v praxi existují záznamy o změně 400 MW za 36 sekund). Tyto extrémní a rychlé skoky vyčerpávají rezervy sítě pro primární regulaci frekvence, způsobují lokální kolísání napětí a zvyšují náklady provozovatelů sítě na udržování rychlých záloh. [14, s. 13]

Mnohem nebezpečnější scénář představuje tzv. sympathetic tripping. Při významnějším poklesu napětí v síti by mohlo dojít k poškození drahého HW, kvůli čemuž jsou systémy UPS a měniče v DC navrženy tak, aby byly schopny okamžitě přejít na vlastní záložní generátory. Pokud však dojde k běžné poruše a v reakci na ni se odpojí celé AI centrum, zmizí ze sítě během několika vteřin obrovská zátěž. Frekvence v síti tak vzroste, což se stane podnětem pro odpojení dalších datových center a nastane řetězová reakce. [21, s. 11]

Reálný příklad se odehrál v červenci 2024, kdy drobný pokles napětí v síti vyvolal ochranné odpojení 60 datových center najednou, čímž síť okamžitě ztratila 1 500 MW zátěže a frekvence vzrostla na kritickou úroveň. [14, s. 13]

2.1.2 Socializace nákladů na výstavbu infrastruktury

Nová zátěž v síti se rychle promítá do peněženek běžných spotřebitelů. Výstavba nutné infrastruktury a zvýšená poptávka po energii mění tržní dynamiku, což má následující dopady na obyvatele a důsledky pro místní ekonomiku.

K pokrytí spotřeby datových center je nutné investovat do nových elektráren, rozvodů a přenosových soustav – jen v USA se tyto náklady do roku 2030 odhadují na zhruba 720 miliard dolarů. Historicky se prostředky vynaložené na rozvoj sítě socializovaly, tj. provozovatel sítě je jednoduše rozpočítal do účtů za elektřinu všem svým zákazníkům v dané oblasti. [14, s. 18–19]

V praxi tato socializace znamená, že běžní občané a místní podniky dotují průmysl datových center. Například v roce 2024 v síti PJM (sahající přes 7 východních států) bylo na běžné a komerční zákazníky přeneseno 4,4 miliardy dolarů v poplatcích za modernizaci sítě, kterou vyvolala nová DC [14, s. 19].

Pro vyvážení tohoto nesouladu se dnes v USA používá jiný přístup: Datová centra si mohou zažádat o rezervaci určité kapacity, která jim bude po schválení přidělena. Ponesou tak větší část nákladů na modernizaci infrastruktury, ale omezí tím možnost vzniku nových projektů. Kapacita je totiž smluvně vyhrazena pouze pro jejich použití, i když zrovna není naplněna. [22, s. 106–107]

2.1.3 Zdražování velkoobchodní ceny elektřiny

Charakter odběru DC ovlivňuje i samotné trhy s elektřinou. Aby bylo možné pokrýt špičky ve spotřebě AI datových center, operátoři sítí musí častěji spouštět dražší elektrárny pro pokrytí kolísavé poptávky, což plošně zvedá mezní náklady na výrobu energie. Vysoký nárůst ceny lze pozorovat také v kapacitních aukcích, kde si síť zajišťuje zálohy do budoucna. V regionu PJM pro období 2026–2027 stoupla cena více než desetinásobně z cca 28,9 USD/MW na 329,17 USD/MW, a to primárně kvůli očekávanému růstu datových center. [23, s. 9]

V Nebrasce se očekává, že náklady na výrobu elektřiny pro DC společností Google a Meta způsobí místním obyvatelům nárůst cen elektřiny o 2,5 až 3 % ročně [26, s. 23]. Celonárodní odhady pro USA hovoří o tom, že by kvůli datovým centrům mohly účty za elektřinu stoupnout v průměru o 8 % do roku 2030 [14, s. 19]. Tento trend je viditelný i v Evropě – například v Irsku, kde více než pětinu elektřiny odebírají datová centra, byly velkoobchodní ceny elektřiny v průměru o třetinu vyšší než ve zbytku kontinentu [26, s. 23].

2.2 Odběr a spotřeba vody z okolí

Výstavba a provoz datových center představují zátěž pro lokální vodní zdroje. Stejně jako v případě elektrické sítě, obrovské objemy odebírané a spotřebovávané vody si vynucují nákladné investice do místní infrastruktury a v obdobích sucha ohrožují vodní bezpečnost okolních měst. Celosvětový roční odběr vody spojený s provozem DC se odhaduje na stovky miliard litrů a do roku 2030 by mohl přesáhnout 1 200 miliard litrů [22, s. 242].

2.2.1 Přímé dopady AI center na vodní zdroje

Přítomnost datového centra dokáže radikálně změnit hydrologickou bilanci celých oblastí. Typické 100MW hyperscale datové centrum spotřebuje kolem 2 milionů litrů vody denně (Scope 2), což odpovídá spotřebě zhruba 6 500 domácností. 60 % z této spotřeby je nepřímá, čili plynoucí z výroby elektřiny [22]. Prakticky to znamená, že většina vody může být odpařena v jiné oblasti, nicméně zbylých 40 % je nenávratně odebráno z bezprostředního okolí DC.

Vodní spotřebu datových center nejlépe ilustrují reálné příklady amerických měst. V oblasti The Dalles (Oregon) tvořil v roce 2024 odběr vody pro datová centra společnosti Google 461,1 milionu galonů ročně (cca 1,74 miliardy litrů), což představovalo 30 % odběru celého města. Od roku 2012 zde vodní spotřeba datových center vzrostla o 342 %. Dalším příkladem je Newton County (Georgia), kde DC firmy Meta využívají kolem 71,5 milionu galonů ročně (asi 268 milionů litrů). Do roku 2030 se však očekává nárůst tohoto odběru až na 365 milionů galonů ročně. Pokud nedojde ke zvýšení kapacity infrastruktury, obě města budou do roku 2035 čelit deficitu vodních zásob. [34, s. 4–5]

2.2.2 Srovnání charakteru spotřeby vody a elektřiny

Přestože jsou problémy s odběrem elektřiny a vody docela podobné, je důležité ilustrovat několik rozdílů. Elektřinu je možné (leč za cenu ztrát a nákladů na vedení) přenášet na dlouhé vzdálenosti, takže se náklady rozprostřou do širšího regionu. Voda je naopak lokalizovaný zdroj a její nedostatek v oblasti se obtížně kompenzuje. Příkladem může být období sucha v roce 2021, kdy byl taipejským výrobcům čipů omezen přístup k vodě [22, s. 243]. Ve Spojených státech ale existují obavy, že kvůli smluvním závazkům by v případech nedostatku vody šla spotřeba na úkor obyvatel, nikoli datových center [34].

Dalším aspektem je možnost reagovat na krizi v infrastruktuře. Pokud hrozí blackout z nedostatku elektřiny, lze u datových center v kritickou chvíli dočasně odložit výpočetní zátěž do jiné oblasti nebo omezit výkon, aby se síť odlehčilo [19, s. 586]. U vody toto neplatí. Pokud nastane vlna veder, chladicí systémy spotřebují vody ještě mnohem více [2, s. 3]. A protože u chlazení nelze nastavovat intenzitu tak snadno jako u spotřeby, datová centra by z lokálního systému vodu odčerpávala neustále.

2.3 Dopady na ekonomiku

Rozvoj infrastruktury pro AI DC s sebou nese specifickou ekonomickou dynamiku, která kombinuje extrémní kapitálovou náročnost se znatelnými dopady na lokální rozpočty a trh práce. Tato sekce analyzuje ekonomický životní cyklus datových center, od počátečních miliardových investic do výstavby a technologií až po energeticky náročný provoz.

2.3.1 Provozní a kapitálové výdaje DC

Výstavba moderního datového centra vyžaduje vysoké kapitálové investice, které se standardně přepočítávají na kapacitu (v MW). Průměrné náklady na vybudování DC o 1 MW IT příkonu se pohybují kolem 10 až 11 milionů dolarů [36, s. 7, 33, s. 25] (bez nákladů na IT vybavení). Pokud vezmeme jako modelový příklad 100MW datové centrum, jeho výstavba (trvajících typicky 18 až 24 měsíců) vyžaduje kapitálovou investici ve výši přibližně 1 miliardy dolarů. Tyto náklady lze rozdělit do tří hlavních kategorií [37, s. 9]:

- **Pozemky (cca 6,2 %):** Jde zpravidla o nejmenší položku (cca 13,4 milionu USD), ale ceny pozemků se mohou lišit podle lokality.
- **Hrubá stavba a budova (cca 20,9 %):** Výstavba samotné budovy, příjezdových cest a rozvodů spotřebuje přibližně pětinu rozpočtu.
- **Vybavení (cca 72,9 %):** Nejdražší složkou jsou chladicí věže, generátory, UPS systémy a optické sítě.

Je však nutné poznamenat, že část dat použitých pro určení výše uvedených podílů pro kapitálové výdaje pochází z roku 2016, a proto nemusí být přesná pro moderní AI centra.

Jakmile je datové centrum spuštěno, jeho provozní náklady (OPEX) typicky představují zhruba 8,6 % původních kapitálových výdajů [37, s. 9]. U modelového 100MW centra by se tedy roční provozní náklady odhadovaly na 86 milionů dolarů. Podobnou částku ve své práci uvádí také Serena Thi To [36, s. 9]. Rozdělení nákladů je následující [37, s. 9]:

- **Elektřina (40 % – 80 %):** Jednoznačně největší položkou je spotřeba energie. Při průměrném konzervativním využití kapacity (60 %) zaplatí 100MW centrum jen za elektřinu přes 50 milionů dolarů ročně.
- **Personál (cca 15 %):** Zajištění ostrahy, údržby a IT podpory v absolutních číslech tvoří jen menší část rozpočtu.
- **Údržba, daně a pojištění (zbylých 5 až 40 %):** Údržba chlazení, softwarové licence, lokální daně z nemovitosti a hardwaru.

Přestože Pham [37] používá vzorek dat obsahující především klasická datová centra, podobný podíl nákladů na elektřinu ve své práci uvádí také Patel [38, s. 955], který popisuje právě moderní AI datová centra.

2.3.2 Daně a daňové pobídky

Výstavba a provoz datových center generují pro státní a lokální rozpočty příjmy ve formě majetkových daní, daní z příjmu zaměstnanců a daní z prodeje (Sales Tax). Poměrně detailní analýzu nabízí studie Johnson Economics [39] pro výstavbu 16 až 20 datacenter o celkové kapacitě 1 GW v oregonském Morrow County, která potrvá přibližně 8 let. Samotná výstavba by měla do ekonomiky přinést 10 miliard dolarů a po deseti letech provozu (při postupném zprovoznění datových center, tedy kumulativně) další 4 miliardy dolarů.

Stejná studie uvádí, že by datová centra za dvacet let provozu do místního rozpočtu přinesla asi 1,25 miliardy dolarů a nad to další peníze do federální pokladny. Problém nicméně představují daňové pobídky, které stát poskytuje, aby investici vůbec přilákal. V tomto případě by se kvůli nim do místního rozpočtu dostalo pouze 300 milionů dolarů – jen čtvrtina původního odhadu.

Hlavním důvodem těchto pobídek je ostrá globální i mezistátní konkurence. Politici jejich povolování obhajují očekáváním, že datová centra zafungují jako magnet pro další technologické firmy, podpoří lokální trh práce a urychlí modernizaci veřejné infrastruktury [33]. Pro provozovatele DC je to výhodné, protože odpuštění daně na drahé servery nebo poskytnutí úlevy na majetkových daních mohou snížit OPEX i o vyšší desítky tisíc dolarů na jeden megawatt kapacity ročně [33, s. 27]. Empirické výzkumy ale ukazují, že pro místní rozpočet to tak výhodné není – datová centra rozvoj technologií nepodporují a jejich přínos pro zaměstnanost je omezený [33, 32].

2.3.3 Tvorba pracovních míst

Vliv datových center na zaměstnanost je charakteristický nepoměrem mezi fází výstavby a fází samotného provozu. Během 18 až 24 měsíců trvající fáze výstavby jednoho DC vzniká obrovské množství dočasných pracovních míst napříč celým dodavatelským řetězcem. Výstavba menšího (asi 20MW) datového centra podpoří lokálně přibližně 1 688 přímých a nepřímých pracovních míst [37]. Výstavba větších 100MW komplexů pak může vytvořit 5 700 [36, s. 6] dočasných pracovních míst. Studie RECG [40, s. 1] uvádí, že výstavba 1GW datového centra vytvoří 34 000 přímých pracovních míst a dalších 11 000 nepřímých pracovních míst, zejména pro vytvoření dostatečné infrastruktury. Celkově se tedy ukazuje trend, že každých 100 MW kapacity DC může do regionu skutečně přinést zhruba 5 700 dočasných pracovních míst.

Interpretace těchto dat je však problematická kvůli odlišným metodikám výpočtu. Rozdíl spočívá v rozlišení mezi počtem dočasných pozic a počtem odpracovaných hodin – zatímco optimistické modely (např. RECG [40]) sčítají počet všech úvazků, analýza Johnson Economics pro oregonské Morrow County [39] volí přepočet na plné pracovní úvazky (FTE, Full Time Equivalent). Pro srovnatelný 1GW projekt (tvořený z 20 menších DC) odhaduje Oregon pouze 6 400 přímých FTE pozic rozprostřených do osmi let výstavby, což odpovídá stabilnímu vytížení pro zhruba 800 pracovníků ročně (640 FTE na 100 MW výkonu). Podobné údaje uvádí také analýza BCG, která stanovuje průměrně 500 FTE při výstavbě 100 MW kapacity [41, s. 10].

Zaměstnanost ve fázi provozu datového centra je napříč nalezenými studiemi velmi dobře zdokumentovaná a v zásadě se neliší. Všechny ukazují, že potřeba lidské práce po spuštění operací DC klesá – To [36, s. 7] uvádí, že přímo ve 100MW datovém centru celoročně pracuje pouze 30 až 50 FTE. Podobné údaje plynou z analýzy Johnson Economics [39, s. 15], která uvádí 560 FTE na 16 až 20 datových center. Počet zaměstnanců potvrzují také studie Economic Consulting Group [40, s. 14] pro 1GW datové centrum, které odhaduje 430 FTE pozic. Analýza BCG [41, s. 10] pak ukazuje 50 FTE. V průměru tedy můžeme říci, že na každých 100 MW kapacity datového centra skutečně připadá zhruba 30 až 50 trvalých pracovních míst.

Tyto pozice nabízejí vysoce nadprůměrné mzdové ohodnocení. Například ve Virginii dosahoval v roce 2020 průměrný plat pracovníka datového centra přes 134 000 dolarů, což je víc než dvojnásobek průměru v tamním soukromém sektoru [42, s. 83]. V absolutních číslech jde ale pro celkovou zaměstnanost v regionu o zanedbatelné množství. Některé z těchto pracovních rolí, jako je ostraha či úklid, navíc bývají obsazovány externími dodavateli a nenabízejí stejné benefity a jistoty jako přímé úvazky [32, s. 7]. Rozsáhlé výzkumy navíc rozporují, že by přítomnost datového centra automaticky stimulovala vznik dalších navázaných pracovních míst [33].

2.4 Sociální dopady

Poslední sekce této kapitoly je věnovaná dopadům na místní komunity. Jedním z nejvýraznějších problémů DC je nepřetržitý hluk generovaný chladicími ventilátory a pravidelným testováním záložních dieselových generátorů. Tento neustálý hukot je v některých oblastech tak rušivý, že donutil místní obyvatele k přestěhování. K hluku se navíc přidává zhoršená kvalita ovzduší ze spalín, neestetické obří haly a zátěž pro veřejnou infrastrukturu. [42, 43]

Tyto skutečnosti daly v zasažených regionech vzniknout silnému občanskému odporu, který se označuje jako NIMBY (Not In My Back Yard, česky „ne na mém dvorku“). Tento termín vystihuje postoj, kdy veřejnost sice obecně uznává nezbytnost fyzické infrastruktury pro technologický pokrok, ale kategoricky odmítá snášet její negativní dopady ve svém sousedství, nebo alespoň v okolí přírodních parků a historicky významných míst [42]. Tito občané bojují za zachování své kvality života a ochranu lokálních zdrojů na úkor technologického pokroku, kvůli čemuž bývá jejich postoj vnímán jako sobecký a krátkozraký.

2.5 Shrnutí dat důležitých pro model ČR

Tato kapitola představila komplexní přehled dopadů výstavby a provozu datových center na lokální ekonomiky ve Spojených státech. USA v tomto sektoru ovšem představují světového lídra a extrémní koncentrace výkonu (80 % kapacity pochází z území pouhých 15 států) [26] vytváří specifické prostředí, které pro Českou republiku nemusí být ve všech ohledech přenositelné.

Pro tuzemský model tak nejsou přímo relevantní údaje o kritických čekacích dobách na připojení nebo o řetězových reakcích v síti (sympathetic tripping ze sekce 2.1.1). Stejně tak konkrétní predikce nárůstu cen elektřiny pro domácnosti jsou v ČR ovlivněny odlišným energetickým mixem, jinou strukturou velkoobchodního trhu a silnější regulací.

Ačkoli je tedy nutné vnímat americká data v jejich specifickém kontextu, tato kapitola tvoří nezbytný základ pro pochopení univerzálních mechanismů, které rozvoj AI infrastruktury doprovázejí. Zároveň slouží analýza amerického trhu jako benchmark pro scénáře maximálního rozvoje infrastruktury, která v ČR zatím neexistuje, ale představuje technologický cíl pro příští dekády.

Některé údaje jsou pro modelování tuzemských dopadů přesto relevantní, neboť se odvíjí od příkonu daného DC. Tyto klíčové parametry jsou přehledně popsány v tabulce 2.1 a slouží jako vstupní data pro upřesnění dopadů výstavby datových center v České republice, kterému se věnuje kapitola 3.

■ **Tabulka 2.1** Údaje pro americký trh vztažené k typickému 100MW datovému centru

Parametr	Hodnota na 1 MW	Zdroj
Náklady na výstavbu	10 až 11 mil. USD	[36, 33]
Náklady: pozemky (6,2 %)	0,62 až 0,68 mil. USD	[37]
Náklady: hrubá stavba a budova (20,9 %)	2,09 až 2,299 mil. USD	[37]
Náklady: infrastruktura (72,9 %)	7,29 až 8,02 mil. USD	[37, 14]
Roční provozní výdaje (OPEX)	0,86 až 0,95 mil. USD/rok	[37, 36]
OPEX: elektřina (40–80 %)	0,34 až 0,76 mil. USD/rok	[37, 38]
OPEX: personál (15 %)	0,13 až 0,14 mil. USD/rok	[37]
OPEX: údržba, daně, pojištění (5–40 %)	0,04 až 0,38 mil. USD/rok	[37]
Pracovní místa při výstavbě	57 míst	[36]
Převod na FTE (Full Time Equivalent)	5,50 až 6,40 FTE	[39, 41]
Náklady na mzdy při výstavbě	27,6 až 45,8 % nákl. na stavbu	[36, 40]
Pracovní místa při provozu	0,30 až 0,50	[36, 40, 41]
Mzdová hladina zaměstnanců DC	2x průměr soukromého sektoru	[42]
Spotřeba vody za den	56 400 l	[31, 26, 21, 22]
Náklady na vybudování kapacity sítě	0,66 mil. USD	[40, 44]

Připravenost ČR na AI DC

Třetí kapitola se věnuje specifickým podmínkám pro výstavbu a provoz AI datových center v ČR. Důraz klade na identifikaci limitů a příležitostí, které by realizaci takových DC v českém kontextu ovlivnily. Posuzovaná kritéria vycházejí z oblastí identifikovaných v kapitole 2 jako klíčových pro úspěšnou výstavbu a provoz DC (dostupnost elektřiny, vody, kapacity sítě, ...).

3.1 Trh datových center v ČR

Podle dostupných analýz je na území ČR v provozu 55 datových center s kombinovaným příkonem cca 150 MW. Téměř polovina z nich jsou kolokační, zbytek tvoří enterprise DC a malou část cloud computing DC. Momentálně jsou ve výstavbě dvě AI datová centra, která mají během následujících let přidat dalších 100 MW. ČR se tak dostává do rané fáze rozvoje trhu s výkonnými datovými centry připravenými na trénování a provoz modelů umělé inteligence.

3.1.1 Obecná charakteristika českého trhu s DC

V ČR jsou dnes provozovány desítky datových center. Údaje dostupné ze Statista (leden 2026) [45] ukazují, že v roce 2025 bylo na území ČR v provozu přibližně 43 DC. Tato data pocházejí od srovnávací služby Data Center Map, která na svých stránkách nabízí aktualizované informace – k březnu 2026 eviduje na území ČR 55 datových center [46]. Tato čísla však zahrnují i zařízení, která jsou momentálně ve výstavbě (Prague Gateway DC a DC v Kanicích u Brna).

Existují také konkrétní studie, které na DC v ČR dodávají detailnější pohled. Podle Mordor Intelligence [47] byla instalovaná kapacita českých datových center 152 MW. Studie dále uvádí, že v Praze a Středočeském kraji se nachází přibližně 75 % instalovaného příkonu, nicméně podle údajů z Data Center Map je ve stejných regionech pouze polovina konkrétních subjektů. Z toho lze konstatovat, že datová centra v okolí Prahy jsou řádově výkonnější než v ostatních regionech.

Podle stejné studie Mordor Intelligence tvoří 44 % kapacit v České republice relativně velké kampusy s instalovanou kapacitou 5–15 MW [47]. Podobnou statistiku ukazují i data z Data Center Map, která ji doplňují o informaci, že zbylá část DC má kapacitu menší než 5 MW. Dále je asi 48 % kapacit nabízeno kolokačními DC, zatímco zbylých 52 % je tvořeno enterprise DC. Marginální podíl tvoří také cloud computing DC (např. společnost ZonerCloud).

3.1.2 Aktuální výstavba a budoucí projekty

K březnu 2026 jsou na území ČR ve výstavbě dva velké projekty. Konkrétně jde o již zmíněné Prague Gateway DC, které by mělo mít na konci roku 2027 instalovaný příkon 26 MW a white-space plochu 4 000 m² s více než 2 000 racky. Toto DC má ambice stát se součástí projektu AI Gigafactory, jehož cílem je vytvořit evropskou infrastrukturu pro vývoj AI systémů. [48, 49]

Aby se však mohlo Prague Gateway DC do AI Gigafactory zapojit, musí splňovat požadavky na minimální příkon. Náměstek ministra průmyslu a obchodu Jan Kavalírek [50] uvádí, že v další fázi výstavby by se měl příkon DC navýšit na 77 MW a celková investice bude okolo 90 miliard korun (včetně výpočetního vybavení), z čehož jedna třetina bude financována z evropských fondů a českého státního rozpočtu. Výpočetní výkon pak budou využívat jak soukromí investoři, tak evropské a české instituce. Uvedená částka odpovídá datům z USA, podle nichž by budova DC stála 770 mil. USD a vybavení 2,7 mld. USD – celkem 80 mld. korun (bez nákladů na úpravy elektrizační soustavy).

Dalším významným projektem je AI datové centrum v Kanicích, které má být provozováno společností MasterDC. Na pozemku o velikosti 26 000 m² bude postaveno několik hal – první již na konci roku 2026 s instalovaným příkonem 4 MW a white-space plochou 1 000 m² pro 100 racků. V dalších fázích by se měl příkon navýšit na 25 MW a celkové PUE bude 1,2. [51]

Přestože se tyto projekty mohou zdát oproti plánům na gigawattové kampusy v USA jako relativně nevýznamné, český trh je pořád v rané fázi vývoje. Vhodné srovnání se nabízí s Irskem, které svou ranou fázi zažilo teprve nedávno. Podle dat Centrálního statistického úřadu Irska [52] byl v roce 2015 podíl DC na celkové spotřebě 5 %, zatímco v roce 2023 tvořil již 23 % (CAGR 21 %). V ČR je instalovaný příkon DC 150 MW [47], což při předpokládaném 50% využití představuje asi 1 % z celkové spotřeby elektřiny v zemi. Uvážíme-li stejné CAGR, do 10 let by tento podíl mohl dosáhnout 7 %. To však předpokládá vytvoření vhodných podmínek pro rozvoj hyperscale DC.

3.2 Energetika a vodní zdroje v ČR

Česká republika má omezenou kapacitu přenosové sítě zvláště vysokého napětí a v některých lokalitách chybí také kapacity distribuční sítě. Kvůli postupnému vypínání uhelných elektráren se ČR navíc stane v roce 2027 dovozcem elektřiny,

a to i bez vlivu nových datových center. Díky propojení s evropským trhem to však (při postupném zvyšování spotřeby) nepředstavuje problém. Na druhou stranu ČR dlouhodobě trpí suchem a do roku 2060 má mít zápornou vodní bilanci. To by mohlo být bariérou pro provozovatele citlivé na náklady.

3.2.1 Role ČEPS: Kapacita a stabilita sítě

Společnost ČEPS, a. s. působí jako výhradní provozovatel přenosové soustavy v České republice a ze zákona zodpovídá za její bezpečný provoz a rozvoj. Její klíčovou úlohou je udržovat rovnováhu mezi výrobou a spotřebou elektřiny (resp. udržování frekvence 50 Hz) a řídit toky výkonu v síti. Z hlediska celkového transformačního výkonu disponuje přenosová soustava kapacitou 24 500 MVA [53, s. 127] – dvojnásobkem historicky maximálního zatížení (12 133 MW) [53, s. 148]. Tyto zdánlivě volné kapacity však představují bezpečnostní rezervu dle kritéria N-1, které garantuje ochranu proti výpadku jakéhokoli prvku sítě. V praxi jsou proto klíčové transformační uzly dimenzovány tak, aby pracovaly pouze na 50 % svého instalovaného výkonu. Druhá polovina slouží jako záloha pro případ nečekané poruchy. [53]

Pro developery jsou však omezující hlavně lokální limity sítě. Podle Mordor Intelligence [47] je situace nejkritičtější v metropolitní oblasti Prahy a ve středních Čechách, kde se koncentruje největší zájem developerů. Přestože ČEPS plánuje proinvestovat 80 miliard korun do roku 2034 na rozvoj a posílení sítě, rychlému řešení kapacitních problémů brání časová náročnost výstavby. Samotný proces vybudování nového (nebo modernizace stávajícího) vedení zvláště vysokého napětí trvá standardně 7 až 10,5 roku [54], v extrémních případech až 15 let. Největší brzdou přitom není technická realizace (stavba zabere jeden až dva roky), ale zdoluhavé přípravné a povolovací procesy. Konkrétně jde o složitou legislativu, proces posuzování vlivů na životní prostředí a majetkové vypořádání s vlastníky pozemků. [54, 55]

3.2.2 Energetický mix ČR a propojení s Evropou

Celková výroba elektřiny brutto v ČR pro rok 2024 dosáhla 73,9 TWh a spotřeba činila 67,2 TWh. Výroba stála na dvou dominantních pilířích: jaderné energii (40 % vyrobené elektřiny) a uhlí (34 %). Třetí složkou jsou obnovitelné zdroje energie (OZE) s celkovým podílem téměř 17 % (biomasa a bioplyn 7 %, fotovoltaika 5 %, vodní 4 %, větrné elektrárny 1 %). Důležitou roli v mixu hrají také zemní plyn (5 %) a černé uhlí (2 %, dlouhodobě klesající). Co se týče emisí oxidu uhličitého, Ministerstvo průmyslu a obchodu uvádí emisní faktor 0,33 tuny CO₂ na 1 MWh vyrobené elektřiny (brutto). [56, 57]

Podle předpokládaných scénářů se očekává proměna energetického mixu, zejména postupný útlum uhelných elektráren s očekávaným koncem kolem roku 2033. Výpadek produkce z uhlí bude nutné kompenzovat rozvojem OZE

(plánuje se podíl 30 %), především solárních a větrných elektráren. Závislost těchto zdrojů na aktuálním počasí však vyžaduje výstavbu flexibilních plynových zdrojů, které poslouží jako záloha pro vyrovnávání výkyvů v síti. Stabilitou dekarbonizovaného mixu se pak má stát rozšířená jaderná energetika s plánovaným uvedením do provozu ve druhé polovině 30. let. [53, kap. 2 a 6]

První kroky této změny už lze pozorovat – ke konci roku 2026 se mají vypnout uhelné elektrárny Chvaletice, Počerady a teplárny Kladno. Tyto elektrárny dohromady vytvářely asi 8 TWh elektřiny, přičemž exportní saldo bylo v roce 2024 6,4 TWh [58]. ČR se tak definitivně stane importérem elektřiny.

Vyčerpání domácí přebytečné kapacity ovšem není překážkou pro výstavbu nových datových center. Bartoš [53] popisuje, že česká soustava je synchronně propojena se sítí kontinentální Evropy a tvoří nedílnou součást jednotného vnitřního trhu, díky čemuž lze chybějící elektřinu – kvůli vypínání elektráren, budování datových center nebo obojí – dodat ze zahraničí. Hlavním fyzickým limitem pro obsluhu takové spotřeby je především propustnost přeshraničních přenosových vedení (interkonektorů), jejichž bezpečnou kapacitu ČEPS ve spolupráci se sousedními státy neustále kontroluje a dlouhodobě posiluje. [53]

3.2.3 Dostupnost vody pro chlazení

Česká republika leží na hlavním evropském rozvodí, přičemž většina velkých řek (Vltava, Labe, Morava, Odra) zde pramení a voda z území pouze odtéká. Země je tak extrémně závislá na atmosférických srážkách a akumulaci vody v nádržích [59], kvůli čemuž od roku 2014 čelí opakovaným a vleklým suchům. Klimatické modely do roku 2060 predikují zhoršení situace a nedostatek vody, protože její spotřeba převyší přirozenou obnovu zdrojů [60].

Extrémní nároky datového centra na vodu by s velkou pravděpodobností dále narazily na tvrdý odpor veřejnosti. Nedostatek pitné vody totiž považují Češi za absolutně nejzávažnější globální environmentální problém – v roce 2018 ho jako velmi vážný označilo 63,7 % obyvatel, čímž předstihl i hromadění odpadu či globální oteplování. Lidé s vyššími obavami jsou silně motivováni vodou šetřit. [61]

3.3 Legislativní a ekonomické prostředí

Hlavní mimotržní motivací pro výstavbu DC v ČR jsou přímé dotace poskytované vládou a EU. Nejvýznamnější z nich je projekt AI Gigafactory, který má mobilizovat investice ve výši 20 miliard eur. Co se týče ekonomických přínosů, většina toků do veřejného rozpočtu by pocházela z daní fyzických osob, neboť právnické osoby by nejspíš provedly daňovou optimalizaci. Důležitou roli hrají také nemovitostní a ekologické daně z elektřiny. Z pohledu DPH mají datová centra minimální přínosy, protože daň se platí v místě spotřeby, nikoli v místě provedení výpočtu. Navíc své služby obvykle poskytují jiným firmám.

3.3.1 Pobídky, dotace a role Evropské unie

Evropské země (na rozdíl od USA) k podpoře využívají především přímé dotační programy, nikoli daňové úlevy. Národní strategie umělé inteligence ČR 2030 [62] spoléhá zejména na Národní plán obnovy, ze kterého je vyčleněno několik miliard Kč na konektivitu, kybernetickou bezpečnost a cloudová řešení. Projekt Technologická inkubace agentury CzechInvest má podpořit začínající startupy částkou zhruba 850 milionů korun. Strategie dále počítá s efektivním čerpáním z masivních evropských programů, jako jsou Digitální Evropa a Horizont Evropa. Jde však o obecné, zastřešující oblasti, takže výši konkrétní podpory na výstavbu DC lze odhadovat jen stěží.

Na celoevropské úrovni představuje zcela zásadní krok AI Continent Action Plan [63], který přichází s ambiciózním projektem AI Gigafactories (AI gigatováren). Tato obří zařízení – integrující 100 000 čipů a přitom zohledňující jejich environmentální dopady – mají trénovat nejsložitější modely umělé inteligence. Tyto gigatovárny mají vznikat na principu partnerství veřejného a soukromého sektoru, přičemž plánovaný nástroj InvestAI má mobilizovat investice ve výši 20 miliard eur na vybudování až pěti takových center napříč EU.

3.3.2 Daně a ekonomika

Ekonomické přínosy pro Českou republiku jsou realizovány skrze několik daňových úrovní. V případě datových center je nutné rozlišovat mezi jednorázovými příjmy ve fázi výstavby a kontinuálními příjmy v průběhu provozu zařízení – veskrze se však získávají následujícím způsobem:

- **Daň z přidané hodnoty (DPH):** Pro provozovatele datového centra (plátce daně) je DPH u investic a provozních nákladů zpravidla fiskálně neutrální, protože své služby neposkytuje koncovému zákazníkovi.
- **Daň z příjmů právnických osob (DPPO):** V prvních letech provozu je daňový výnos omezen vysokými odpisy technologického vybavení. Z dlouhodobého hlediska se jí dá vyhnout daňovou optimalizací.
- **Zdanění práce a odvody:** Daňové příjmy pocházejí od zaměstnanců na stavbě, v samotném DC i v externích službách (např. úklid).
- **Majetkové daně:** Daň z nemovitých věcí je výhradním příjmem obce, na jejímž území DC stojí. Od roku 2024 došlo k navýšení sazeb pro průmyslové objekty, což z DC činí klíčové plátce do místních rozpočtů.
- **Energetické daně:** Vzhledem k vysoké spotřebě elektřiny odvádí dodavatel energie za DC tzv. ekologickou daň. Tato daň je spravována Celní správou ČR a tvoří přímý příjem státního rozpočtu.

Souhrnný přehled daňových sazeb a relevantní legislativy pro modelování dopadů v roce 2026 uvádí tabulka 3.1.

■ **Tabulka 3.1** Přehled daňových sazeb v ČR pro rok 2026

Daň / Odvod	Sazba (2026)	Základ daně	Zákon č.
DPH (standardní)	21 %	Cena plnění	235/2004 Sb.
DPPO	21 %	Zisk PO	586/1992 Sb.
DPFO (základní)	15 %	Hrubá mzda	586/1992 Sb.
Sleva na popl.	30 840 Kč/rok	–	586/1992 Sb.
DPFO (zvýšená)	23 %	Mzda nad limit	586/1992 Sb.
Sociální poj. (firma)	24,8 %	Hrubá mzda	589/1992 Sb.
Sociální poj. (zam.)	7,1 %	Hrubá mzda	589/1992 Sb.
Zdravotní poj. (firma)	9,0 %	Hrubá mzda	592/1992 Sb.*
Zdravotní poj. (zam.)	4,5 %	Hrubá mzda	592/1992 Sb.*
Daň z elektřiny	28,30 Kč/MWh	Množství el.	261/2007 Sb.
Daň z nemovitostí	18,00 Kč/m ² **	Zastavěná plocha	338/1992 Sb.

* Poměr definován v zákoně č. 48/1997 Sb.

** Sazba se liší pro kategorie pozemků a staveb. Výsledná daň je dále násobena místním koeficientem obce (1,0 až 5,0).

3.3.3 Detailnější rozbor DPH

DPH je účtována na každém stupni dodavatelského řetězce a její konečnou zátěž nese vždy koncový spotřebitel. Na rozdíl od DPPO je tedy obtížná na optimalizaci – nedá se jí vyhnout pomocí účetních strategií, neboť není závislá na zisku. Pro kolokační datová centra však platí, že většina jejich služeb není poskytována přímo koncovým zákazníkům, ale jiným podnikům (B2B). V takových případech je DPH pro plátce zpravidla neutrální.

Pokud se jedná o DC pro trénování AI, mohou nastat dvě situace. V prvním případě DC poskytuje služby jiným podnikům, které si trénují vlastní modely – DPH tak zůstane neutrální. V druhém případě trénování probíhá pro účely samotné firmy provozující DC, tudíž nevznikne žádný prodej (mimo interní účetní operace). Trénování AI modelů konečnými spotřebiteli nepředpokládáme.

Jedinou relevantní situací pro zvážení DPH představují nákupy předplatného lepších AI modelů (nebo nákupy tokenů) koncovými zákazníky, které se řídí zákonem č. 235/2004 Sb., o dani z přidané hodnoty:

- **§5, odst. 1:** Osobou povinnou k dani je osoba, která *samostatně uskutečňuje ekonomickou činnost* ...
- **§10i, odst. 1:** Místem plnění při poskytnutí služby osobě *nepovinné* k dani je *místo příjemce služby* ..., pokud jde o elektronicky poskytovanou službu.
- **§10i, odst. 2:** Pro účely DPH se rozumí elektronicky poskytovanou službou služba poskytovaná prostřednictvím veřejné datové sítě ..., a to zejména poskytnutí obrázků, textů nebo informací anebo zpřístupňování databází.

Tyto výňatky jsou implementací evropské směrnice 2006/112/ES, která v článku 7 jako jeden z druhů elektronicky poskytovaných služeb konkrétně charakterizuje *služby automaticky generované z počítače přes internet nebo elektronickou síť v reakci na zadání konkrétních dat příjemcem*, což plně odpovídá podstatě inference modelů umělé inteligence.

Z uvedeného zákona plyne, že při inferenci AI modelů pro účely DPH záleží na poloze koncového zákazníka (osoby nepovinné k dani), nikoli na fyzické lokalitě datového centra. Prakticky to znamená, že výstavba DC na území ČR nepřináší z hlediska DPH žádný užitek, protože stejného důsledku by bylo dosaženo i v případě, že by se nacházelo v jiné zemi EU.

3.4 Shrnutí připravenosti ČR na výstavbu AI DC

V současné době se český trh s datovými centry nachází v rané fázi rozvoje. Velkokapacitní projekty se na území ČR právě realizují (kapacity se zvýší o 30 MW do konce roku 2027), ale komplexní strategický výhled pro masivní rozvoj výpočetní infrastruktury prozatím chybí. Lze však předpokládat, že potenciální úspěch těchto pilotních projektů může působit jako katalyzátor a spustit vlnu dalších investic – podobně jako tomu bylo v jiných evropských regionech (Irsko, Německo).

V oblasti energetiky je nutné reflektovat, že se ČR v blízké budoucnosti stane importérem elektřiny [58], a to i bez vlivu nových DC. Díky propojenosti evropského trhu s energiemi to však nemusí být překážkou. Riziko však spočívá v nedostatku rezervních kapacit přenosové sítě a kapacit přeshraničních interkonektorů. Zásadním limitem České republiky zůstává nedostatek vody. ČR je závislá primárně na srážkách [59], což při nárocích moderních chladicích systémů představuje významnou bariéru pro škálování výkonu [2].

Ekonomické přínosy zůstávají nejednoznačné. Většina daňových příjmů z provozu datových center by pocházela z daní z příjmu fyzických osob a z nemovitostních daní. Naopak daň z příjmu právnických osob by pravděpodobně byla optimalizována pro minimalizaci daňové zátěže. Kvůli principu zdanění v místě spotřeby nelze dobře odhadnout ani daň z přidané hodnoty. Dále nebyla nalezena žádná dostupná literatura o tom, jaké nepřímé a indukované dopady by mohla mít výstavba DC na lokální ekonomiky v České republice.

Parametry důležité pro model jsou shrnuty v tabulce 3.2.

■ **Tabulka 3.2** Shrnutí kvantifikovatelných specifik ČR

Parametr	Hodnota	Zdroj
Výroba elektřiny (2024, brutto)	73,9 TWh	[56]
Spotřeba elektřiny (2024, brutto)	67,2 TWh	[56]
Max. transformační výkon p. s.	24 500 MVA	[53, s. 127]
Minimální zatížení sítě	6 000 MW	[56]
Běžné zatížení sítě	9 000 MW	prům. min. a max.
Maximální zatížení sítě	12 250 MW	[53]
Spotřeba vody jednoho obyvatele	88 m ³	[64]
Emisní faktor z výroby elektřiny (brutto)	0,33 t CO ₂ /MWh	[56]
Průměrná mzda v ČR	52 283 Kč	[65]
Daňové zatížení práce	15 % + 45,4 %	tab. 3.1
Stand. sazba DPFO	15 %	tab. 3.1
Sleva na poplatníka	30 840 Kč/rok	tab. 3.1
Odvody (zaměstnanec)	7,1 % + 4,5 %	tab. 3.1
Odvody (zaměstnavatel)	24,8 % + 9,0 %	tab. 3.1
Sazba ekologické daně	28,30 Kč/MWh	tab. 3.1
Sazba daně z pozemku	9,00 Kč/m ²	338/1992 Sb., §6 2b
Sazba daně z budovy	18,00 Kč/m ²	338/1992 Sb., §11 1h

[illegible][illegible][illegible][illegible]

- [illegible]

■ **Tabulka 4.1** Poskytovatelé DC v ČR podle agregovaného příkonu a whitespace (Zdroj dat: Data Center Map, obohacený o katastrální data a manuální doplnění). Tabulka zahrnuje pouze DC, která jsou k dubnu 2026 v provozu

Poskytovatel	Σ MW	Σ whitespace [m^2]
TTC TELEPORT, s.r.o.	20,000	5 600
CE Colo	15,000	6 200
O2 Czech Republic a.s.	12,033	5 359,2
T-Mobile Czech Republic a.s.	11,550	624,6
Master Internet, Ltd.	7,464	2 450
Seznam.cz	6,200	2 946,9
Ceske Radiokomunikace	5,488	1 433,6
Nej.cz	4,737	1 555
Státní pokladna – CSS	4,000	782
WEDOS Internet, a.s.	3,500	330

4. **Analýza:** Poslední část datového toku je samotná analýza, která počítá základní statistiky. Výstupem je celkový IT příkon datových center v ČR a jejich whitespace. Dále jsou data agregována podle jednotlivých provozovatelů pro identifikaci hlavních hráčů na českém trhu.

Scraper je plně ovladatelný z příkazové řádky, přičemž jednotlivé fáze lze spouštět samostatně, nebo spustit celý proces najednou (bez manuálního zásahu do dat). Kromě obohacení z katastru nemovitostí je celý skript navržen tak, aby umožňoval snadné přizpůsobení pro jiné země, což by mohlo být užitečné pro případné rozšíření této práce o další geografické oblasti. V tabulce 4.1 jsou uvedeny společnosti s největším IT příkonem.

Analýza českých datových center ukázala poměry velikosti budovy na pozemku (0,7274, $n=10$), velikosti whitespace na budově (0,4698, $n=6$) a poměr instalovaného příkonu k velikosti whitespace (0,0030 MW/ m^2 , $n=17$). Nezávisle na těchto dílčích poměrech činí průměrná velikost pozemku pro datové centrum o IT příkonu 1 MW 2998,0 m^2 ($n=26$). Tyto hodnoty byly vypočítány z netransformovaných dat, aby nedošlo k jejich zkreslení. V modelu budou následně použity k odhadu velikosti DC pro výpočet daně z nemovitosti.

4.2 Vymezení modelu

V této sekci budou detailně vymezeny cíle, rozsah a hlavní předpoklady, které byly stanoveny při tvorbě modelu. Dále bude popsána struktura výstupů, které jsou rozděleny do tří hlavních oblastí. Součástí vymezení je také explicitní uvedení toho, co model záměrně nezahrnuje, a důvody pro tato rozhodnutí.

4.2.1 Výstupy modelu

Cílem je vymodelovat socioekonomické dopady výstavby a provozu datových center v České republice, přičemž takové vymezení je relativně obecné a umožňuje zahrnout širokou škálu dopadů. Pro zachování přehlednosti a srozumitelnosti byly vymezeny tři hlavní oblasti, které bude model kvantifikovat. Konkrétně jde o oblast ekonomickou, energetickou a environmentálně-sociální.

Ekonomické výstupy V ekonomické oblasti model kvantifikuje příjmy související s výstavbou a provozem datového centra. Jedná se zejména o zdanění práce (DPFO a odvody) ve fázi výstavby i provozu. Dále odhadne daň z nemovitosti a daň ekologickou. Model také vypočítá hrubou přidanou hodnotu (HPH) vytvořenou výstavbou a provozem datového centra.

Energetické výstupy V energetické rovině model určí celkovou spotřebu elektřiny v průběhu provozu a umožní její zasazení do kontextu české energetiky. Součástí výstupů bude také ukazatel, který srovná spotřebu nově postavených datových center s kapacitou elektrizační soustavy.

ESG Model shrne dopady DC na okolí a vyčíslí celkovou spotřebu vody v průběhu provozu. V neposlední řadě model vypočítá emise oxidu uhličitého ze spotřebované elektřiny (Scope II) a umožní jejich srovnání s referenčními hodnotami (např. s provozem aut nebo s domácnostmi).

Uvedené výstupy tvoří hlavní podklad pro vyhodnocení dopadů výstavby datových center a pro srovnání uvažovaných scénářů (popsaných v podsekcí 4.3.2). Členění na ekonomickou, energetickou a environmentálně-sociální oblast zároveň umožní prezentovat výsledky ve srozumitelné podobě.

4.2.2 Nezahrnuté výpočty

Model záměrně nezahrnuje dopady, které by vyžadovaly těžce přístupná data, obtížně obhajitelné předpoklady nebo metodologii přesahující rozsah této práce. Vyloučené výpočty jsou uvedeny níže včetně hlavních důvodů jejich nezahrnutí.

Indukované ekonomické efekty Model nezahrnuje indukované efekty, typicky vyjádřené multiplikátory vzniku dalších pracovních míst. Tyto dopady jsou v daném kontextu nejisté a jejich kvantifikace by vyžadovala samostatný makroekonomický rámec, což přesahuje rozsah této práce.

Přínos inovací Přínos technologického rozvoje model nevyčísluje, protože je obtížné jej spolehlivě kvantifikovat a jednoznačně přiřadit ke konkrétním datovým centrům. Dostupné studie zároveň naznačují, že tyto přelivy jsou omezené a jejich zahrnutí by v rámci modelu nebylo dostatečně robustní.

Výnosy z AI produktů a služeb Model nepočítá se zvýšenou produktivitou z AI, protože její použití není vázáno k fyzické poloze datového centra a tudíž je pro model výstavby irrelevantní. ČR může profitovat ze zvýšené produktivity, aniž by se datová centra nacházela přímo na jejím území.

Dopady na cenu elektřiny Model nezahrnuje ani odhad zvýšení ceny energií pro obyvatele ČR, neboť je silně závislý na rozsahu výstavby (reálné efekty by se projevíly až při masivním rozvoji datových center), na konkrétních smluvních podmínkách a na regulačních složkách ceny energií.

Souhrnně lze říci, že model se zaměřuje na metriky, které je možné transparentně odvodit z dostupných vstupů a které jsou přímo vázány na výstavbu a provoz datového centra v českém prostředí. Současně jsou explicitně vymezeny oblasti, u nichž by kvantifikace vyžadovala dodatečná data nebo silné předpoklady, což by vedlo k výsledkům s nízkou obhajitelností.

4.3 Obecný popis modelu

V následujícím textu je vysvětlena volba vstupů modelu, které byly zvoleny na základě jejich relevance pro ostatní výpočty. Dále je popsána práce se scénáři, která umožňuje zachytit nejistotu a variabilitu v odhadech dopadů. Na závěr je stručně popsána ekonomická část modelu, která se zaměřuje na HPH jako nejrobustnější metriku pro vyhodnocení ekonomických dopadů.

4.3.1 Vstupy modelu a typy DC

Vstupy modelu jsou zvoleny tak, aby umožnily definovat velikost datového centra, jeho energetickou efektivitu a základní provozní charakteristiky. Zároveň jde o parametry, které lze v praxi zadat z relativně dostupných informací a které mají přímý dopad na hlavní výstupy modelu.

Instalovaný příkon Instalovaný příkon (IT příkon) určuje velikost datového centra. Do modelu vstupuje jako veličina ovlivňující spotřebu elektřiny a od ní odvozené environmentální dopady.

Power Usage Effectiveness Parametr PUE popisuje energetickou efektivitu provozu datového centra. Určuje vztah mezi užitečnou spotřebou výpočetního vybavení a celkovou spotřebou elektřiny, čímž významně ovlivňuje výslednou spotřebu elektřiny a navazující výpočty.

Typ datového centra Volba typu datového centra (kolokační, AI trénovací, AI inferenční) slouží k nastavení předkonfigurované sady fixních parametrů, které typicky charakterizují daný provoz (např. průměrné vytížení). Typ DC ovlivňuje také způsob, jakým je v modelu vyjádřen ekonomický přínos.

Rozdělení na tři typy datových center slouží k zachycení jejich odlišného provozního profilu a byznysového modelu: kolokační centra zjednodušeně monetizují pronájem prostoru, trénovací centra poskytují výpočetní výkon (využití GPU) a inferenční centra monetizují modely umělé inteligence (podle počtu zpracovaných tokenů). V dalších částech metodologie jsou proto některé výpočty uvedeny zvlášť pro každý z typů DC.

4.3.2 Práce se scénáři

Data vycházející z amerického trhu se sice napříč jednotlivými studiemi řádově shodují, ale v některých případech mohou mít odchylku až desítek procent. Namísto převzetí jednoho čísla je proto vhodné pracovat s rozsahem hodnot, který se z literatury podařilo získat. Například počet FTE v provozu datového centra se pohybuje mezi 30 až 50. Rozdíl na první pohled nevypadá důležitě, ale v dlouhodobém měřítku se významně projeví.

Kvůli tomu byly do modelu implementovány tři scénáře, které jsou definovány optikou ekonomických přínosů, zejména hrubé přidané hodnoty. To se může vůči ostatním oblastem projevit inverzně – nižší spotřeba energie sice způsobí nižší přidanou hodnotu, ale na druhou stranu tím může vyvolat méně emisí CO₂ do atmosféry. Ekonomická oblast byla zvolena jako kotvicí kvůli tomu, že se obecně jedná o primární determinant rozhodovacího procesu jak soukromých investorů, tak státního aparátu.

Pesimistický scénář v každém aspektu počítá s takovými hodnotami, které povedou k nejmenšímu příjmu do veřejného rozpočtu a nejnižší hrubé přidané hodnotě. Opak platí pro scénář optimistický, který povede k nejvyšším příjmům do veřejného rozpočtu a nejvyšší hrubé přidané hodnotě. Realistický scénář používá střední hodnotu (pokud byla z literatury získána), nebo aritmetický průměr nejvyšší a nejnižší hodnoty. V případech, kdy odborná literatura neuvádí specifické rozpětí pro pesimistický a optimistický scénář, se uplatní uniformní odchylka 20 % od realistické (středové) hodnoty.

Model následně vypočítá konkrétní hodnoty pro jednotlivé scénáře a také jednu finální očekávanou hodnotu, která se bude řídit pravděpodobnostním rozdělením jednotlivých scénářů. Rozdělení bylo inspirováno běžně používanou metodikou PERT, která stanovuje váhy přibližně 17 % pro optimistický, 66 % pro realistický a 17 % pro pesimistický scénář. V tomto modelu budou použity hodnoty 20 % pro optimistický scénář, 60 % pro realistický scénář a 20 % pro pesimistický scénář. Mírné posílení vah okrajových scénářů reflektuje relativně vysokou volatilitu trhu s AI technologiemi a energiemi. Výsledná očekávaná hodnota se vypočítá podle vzorce

$$E(X) = 0,2 \cdot X_{opt} + 0,6 \cdot X_{real} + 0,2 \cdot X_{pes}.$$

4.3.3 Ekonomická část modelu

Ekonomická část modelu je metodologicky nejnáročnější, protože čisté zisky a navazující fiskální přínosy do značné míry závisí na účetní politice a daňové optimalizaci provozovatele, jak bylo ilustrováno v kapitole 3.3.2. Odhadování dopadů na veřejný rozpočet naráží na nedostatek informací o míře zadlužení provozovatelů, jejich skutečných provozních nákladech, sektorových maržích a především o reálných čistých ziscích generovaných na území jednoho státu. Právě tyto proměnné přitom zásadně ovlivňují výslednou daňovou povinnost. Ani daň z přidané hodnoty (DPH) není pro interpretaci ekonomického přínosu vhodným ukazatelem, jak popisuje podsekcce 3.3.3.

Ekonomický přínos je proto v modelu primárně vyjádřen pomocí hrubé přidané hodnoty (HPH). HPH je standardní makroekonomická veličina, která zachycuje nově vytvořenou hodnotu v rámci produkčního procesu: zjednodušeně vyjadřuje rozdíl mezi hodnotou vytvořeného výstupu (produkce) a hodnotou mezipotřeby, tedy vstupů nakoupených od jiných subjektů, které byly při tvorbě výstupu spotřebovány [66]. Z hlediska interpretace lze HPH chápat jako část hodnoty, která vzniká uvnitř sledované činnosti.

HPH je možné interpretovat jako zdroj pro odměny práce (mzdy a související odvody), spotřebu fixního kapitálu (odpisy) a provozní přebytek (resp. podnikatelský zisk). Po zohlednění daní a dotací na produkty odpovídá součet HPH napříč odvětvími hrubému domácímu produktu, tudíž jde o veličinu úzce spojenou s celkovou ekonomickou aktivitou [67]. V kontextu této práce HPH reprezentuje ekonomickou hodnotu vytvářenou výstavbou a provozem datového centra v ČR, aniž by byla přímo svázána s tím, jak je výsledný zisk účetně vykázán nebo jak je následně přerozdělen mezi vlastníky.

Výhodou HPH pro účely modelu je tedy její robustnost vůči účetním přesunům zisku a daňové optimalizaci: i při nejistotě ohledně čistého zisku lze HPH interpretovat jako reálně vytvořenou hodnotu spojenou s daným DC. Konkrétní výpočetní postupy jsou uvedeny v podsekcce 4.4.5.

4.3.4 Práce s časovým rozdělením

Výstavba a provoz datového centra nepředstavují pouze jednorázový investiční stimul, ale dlouhodobý proces s předpokládanou životností přesahující 25 let. Z makroekonomického hlediska vstupuje do takto dlouhých časových řad faktor inflace, která v čase mění nominální hodnotu peněz.

Předkládaný model však s inflací explicitně nepracuje a veškeré výpočty provádí ve stálých cenách vztažených k roku 2026. Tento metodický přístup byl zvolen záměrně: umožňuje totiž modelovat reálný ekonomický přínos a přidanou hodnotu bez zkreslení cenovou hladinou. Zjednodušeně řečeno, model předpokládá fixní kupní sílu peněz po celou dobu provozu. Výsledné hodnoty tak odpovídají dnešní hodnotě investic a budoucích přínosů, což usnadňuje jejich interpretaci a srovnání se současnými makroekonomickými agregáty.

4.4 Metodologie výpočtů

Tato sekce popisuje metodologii výpočtů použitou v modelu a rozkládá ji na dílčí, opakovaně použitelné výpočetní bloky. Každá subsekce zavádí jeden takový blok, definuje jeho vstupy a základní vztahy a stručně vysvětluje jeho roli v modelu. Uvedené vztahy jsou formulovány obecně, tj. nezávisle na tom, zda jsou později aplikovány na fázi výstavby nebo na fázi provozu. Samotné rozdělení na uvedené fáze je řešeno až v závěru této sekce.

4.4.1 Spotřeba datových center

Ze vstupů se dá bez dalších předpokladů vypočítat celkový příkon datového centra P , který je založený na IT příkonu P_{IT} a PUE:

$$P = PUE \cdot P_{IT}.$$

Maximální spotřebu elektřiny datového centra $E_{\max}$ za čas τ získáme vynásobením celkového příkonu P časem τ podle vzorce

$$E_{\max} = P \cdot \tau.$$

Datová centra však neběží celou dobu na 100 % své kapacity (především kolokační a inferenční). Reálnou spotřebu E_{real} vypočítáme vynásobením maximální spotřeby $E_{\max}$ koeficientem využití $k_{\text{utilization}}$:

$$E_{\text{real}} = E_{\max} \cdot k_{\text{utilization}}.$$

Jak bylo popsáno v kapitole 1.3.1, základní jednotkou příkonu P jsou wattly a jednotkou spotřeby E jsou watthodiny.

4.4.2 Náklady na výstavbu a provoz DC

Z literatury plyne jednoznačný vztah mezi náklady na výstavbu datového centra (bez výpočetního vybavení) I_{build} a jeho instalovaným příkonem v megawattech P_{IT} . Náklady na výstavbu tak lze snadno vypočítat rovnicí:

$$I_{\text{build}} = P_{IT} \cdot I_{\text{build per MW}},$$

kde $I_{\text{build per MW}}$ jsou náklady na výstavbu DC s 1 MW IT příkonu.

Analogicky vypočítáme náklady na IT vybavení $I_{\text{equipment}}$:

$$I_{\text{equipment}} = P_{IT} \cdot I_{\text{equipment per MW}},$$

kde $I_{\text{equipment per MW}}$ jsou náklady na IT vybavení DC s 1 MW IT příkonu.

Při srovnávání investic s dalšími metrikami je však problém, že se IT vybavení odepisuje rychleji než budova. V průběhu času se tak mění váha

jednotlivých investic v celkových nákladech a jejich prostý součet nestačí. Byl proto zaveden výpočet ročních odpisů D_y , které se vypočítají jako

$$D_y = \frac{I_{\text{equipment}}}{UL_{\text{equipment}}} + \frac{I_{\text{build}}}{UL_{\text{build}}},$$

kde $UL_{\text{equipment}}$ (Useful Life) je délka odepisování IT vybavení a UL_{build} je délka odepisování budovy. V tomto zjednodušeném modelu by se ke stejnému výsledku došlo sečtením kapitálových nákladů za životnost projektu a jejich vydělením počtem let, čímž získáme anualizované kapitálové náklady (ACC).

Literatura dále ukazuje vztah mezi instalovaným příkonem a průměrným OPEX. Tento vztah však není relevantní pro modelování HPH, kvůli čemuž byl zvolen přístup výpočtu mezispotřeby IC. Ta je v případě DC tvořena zejména elektřinou – jejíž cenu lze ze vstupů vypočítat přesně – a dalšími složkami jako úklid, ostraha, služby nebo pojištění. Pro jejich obsáhlost a neurčitost byl namísto modelování těchto složek zvolen přístup výpočtu z ACC, resp. odpisů D_y , pomocí stanoveného koeficientu k_{IC} : například výše pojištění se odvíjí od hodnoty vybavení, stejně jako nutnost ostrahy. Mezispotřebu počítáme jako

$$IC = E_{\text{real}} \cdot \text{Price}_{\text{electricity}} + k_{IC} \cdot D_y,$$

kde E_{real} je skutečná spotřeba elektřiny, $\text{Price}_{\text{electricity}}$ je cena elektřiny a k_{IC} je koeficient pro výpočet zbývající mezispotřeby na základě ročních odpisů (potažmo anualizovaných kapitálových nákladů) D_y .

4.4.3 Pracovní místa a zdanění práce

Podobně jako v případě investičních nákladů nabízí literatura údaje o počtu vytvořených pracovních míst (FTE) v závislosti na instalovaném příkonu. Celkový počet vytvořených míst FTE_{total} v datovém centru s instalovaným příkonem P_{IT} (v MW) se tedy vypočítá dle vzorce:

$$FTE_{\text{total}} = P_{IT} \cdot FTE_{\text{per MW}},$$

kde $FTE_{\text{per MW}}$ je průměrný počet FTE vytvořených na 1 MW IT příkonu. Přínosy do státního rozpočtu z oblasti práce se odvozují z celkových hrubých mezd. Pro výpočet povinných odvodů a daní (DPFO, sociální a zdravotní) se použijí následující vzorce:

$$\text{Mandatory Contributions} = FTE_{\text{total}} \cdot W_{\text{avg}} \cdot t_{\text{contributions}},$$

$$\text{Personal Income Tax} = FTE_{\text{total}} \cdot \max(0, W_{\text{avg}} \cdot t_{\text{income}} - \text{Tax Discount}),$$

kde Mandatory Contributions jsou celkové povinné odvody zaměstnavatele a zaměstnance, FTE_{total} je celkový počet FTE, W_{avg} je průměrná hrubá mzda na jednoho zaměstnance, $t_{\text{contributions}}$ je souhrnná sazba pro odvody (sociální a zdravotní za zaměstnance i zaměstnavatele), Personal Income Tax je celková

daň z příjmu fyzických osob, t_{income} je sazba daně z příjmu a Tax Discount je sleva na dani z příjmu.

Sečtením Mandatory Contributions a Personal Income Tax získáme příjmy do veřejného rozpočtu z oblasti práce T_{labor} .

4.4.4 Ekologická daň a daň z nemovitosti

Ekologická daň T_{ecology} se počítá z reálné spotřeby elektřiny E_{real} podle vzorce:

$$T_{\text{ecology}} = E_{\text{real}} \cdot t_{\text{ecology}},$$

kde t_{ecology} je sazba ekologické daně na jednotku spotřebované elektřiny. Při výpočtu je důležité zajistit, že jsou jednotky spotřeby elektřiny a sazby ekologické daně konzistentní (např. spotřeba v MWh a sazba v Kč/MWh).

Daň z nemovitosti se odvíjí od velikosti pozemku a budovy, na kterých se datové centrum nachází, a od sazeb daně z nemovitosti, které jsou stanoveny pro danou lokalitu. Pro výpočet daně z nemovitosti T_{property} se použijí vzorce

$$T_{\text{land}} = A_{\text{land}} \cdot t_{\text{land}} \cdot k_{\text{location}},$$

$$T_{\text{build}} = A_{\text{build}} \cdot t_{\text{build}} \cdot k_{\text{location}},$$

kde T_{land} je daň z pozemku, A_{land} je plocha pozemku, t_{land} je sazba daně z pozemku a k_{location} je koeficient lokality. Pro budovy analogicky. Znovu je nutné zajistit konzistenci jednotek plochy a daňové sazby.

Celková daň z nemovitosti T_{property} je součtem T_{land} a T_{build} .

4.4.5 HPH (Hrubá přidaná hodnota)

Stěžejní částí ekonomické analýzy je výpočet vytvořené HPH. Vypočítá se rozdílem produkce (v tomto případě tržeb) a mezispotřeby (nákladů na elektřinu a dalších vstupů). Zatímco mezispotřeba se počítá totožně pro každý typ DC (viz sekce 4.4.2), produkce se liší v závislosti na typu DC a jeho provozním modelu. $k_{\text{occupancy}}$ z byznysového hlediska označuje, jak efektivně je provozovatel DC schopen prodávat své kapacity, což se odráží v tržbách.

Kolokační centra Jejich produkce je vyjádřena tržbami S_{coloc} z pronájmu prostoru, které jsou odvozeny od IT příkonu a průměrné ceny pronájmu:

$$S_{\text{coloc}} = \text{Price}_{\text{coloc}} \cdot P_{\text{IT}} \cdot k_{\text{occupancy}},$$

kde $\text{Price}_{\text{coloc}}$ je cena za pronájem kapacit a P_{IT} je instalovaný příkon. Je nutné zajistit, aby se shodovaly jednotky příkonu a ceny za pronájem (např. Kč/kW/měsíc a kW).

AI trénovací centra Produkce se odvíjí od počtu GPU a průměrné ceny za jejich pronájem. Počet GPU GPU Count se odvozuje z instalovaného příkonu a průměrné spotřeby jednoho čipu:

$$\text{GPU Count} = P_{IT} \div \text{GPU Power},$$

kde GPU Power je spotřeba na GPU. Tržby S_{training} se vypočítají jako

$$S_{\text{training}} = \text{Price}_{\text{training}} \cdot \text{GPU Count} \cdot k_{\text{occupancy}},$$

kde $\text{Price}_{\text{training}}$ je cena za pronájem GPU. Cena se často uvádí v GPU-hodinách, proto je pro roční modelování nutné sazbu přepočítat (vynásobit 8 760 hodinami).

AI inferenční centra Produkce se odvíjí od maximálního počtu zpracovatelných tokenů Max Tokens:

$$\text{Max Tokens} = E_{IT} \div E_{\text{token}},$$

kde E_{IT} je maximální spotřeba IT vybavením a E_{token} je spotřeba pro zpracování jednoho tokenu. Tržby $S_{\text{inference}}$ se pak vypočítají jako

$$S_{\text{inference}} = \text{Price}_{\text{token}} \cdot \text{Max Tokens} \cdot k_{\text{occupancy}},$$

kde $\text{Price}_{\text{token}}$ je cena za zpracování tokenu.

Výpočet HPH Hrubá přidaná hodnota pro každý typ datového centra se získá jako rozdíl mezi vypočítanou produkcí a mezipotřebou:

$$\text{GVA}_{\text{dc type}} = S_{\text{dc type}} - \text{IC},$$

kde $\text{GVA}_{\text{dc type}}$ je hrubá přidaná hodnota, $S_{\text{dc type}}$ jsou tržby a IC je mezipotřeba (tvořená spotřebou elektřiny a dalšími vstupy).

Celková přidaná hodnota z provozu datového centra $\text{GVA}_{\text{total}}$ se získá sečtením HPH vytvořené jednotlivými datovými centry. Časový rámec přidané hodnoty vychází ze zvolených jednotek. Pokud budeme modelovat roční přidanou hodnotu, pak se všechny vstupy musí vztahovat k roku provozu.

4.4.6 Environmentální dopady

Poslední oblastí modelu jsou environmentální dopady, které jsou odvozeny od celkové spotřeby E_{real} a odpovídajícího faktoru:

$$\text{CO}_2 = E_{\text{real}} \cdot \text{EF},$$

$$\text{Water} = E_{\text{real}} \cdot \text{WF}.$$

CO_2 jsou celkové emise oxidu uhličitého a EF je emisní faktor při výrobě elektřiny. Water je celková spotřeba vody a WF je vodní faktor, který je součtem spotřeby vody datovým centrem a spotřeby vody při výrobě elektřiny. Je důležité zajistit konzistenci jednotek (např. spotřeba v MWh, emisní faktor v tunách CO_2/MWh a vodní faktor v litrech/MWh).

4.4.7 Rozdělení výpočtů do fází výstavby a provozu

Model byl pomyslně rozdělen do dvou fází, které se liší svými vstupy a časovým horizontem. Fázi výstavby charakterizuje jednorázový impuls do ekonomiky, zatímco fáze provozu se vyznačuje dlouhodobými přínosy do veřejného rozpočtu, stabilním zaměstnáním a environmentálními dopady.

Fáze výstavby se obvykle odehrává v prvních 1–3 letech od zahájení projektu, kdy jsou realizovány stavební práce, instalace vybavení a další přípravné činnosti. Klíčové jsou investiční náklady, které se promítají do HPH generované stavební firmou. Na základě dat z ČSÚ byl zjištěn průměrný koeficient pro výpočet HPH ze stavebních projektů, který se pohybuje kolem 30 % [68, 69] hodnoty investice. HPH z výstavby HPH_{const} se vypočítá jako

$$HPH_{const} = I_{build} \cdot k_{GVA \text{ on } I_{build}},$$

kde I_{build} je kapitál investovaný do budovy a $k_{GVA \text{ on } I_{build}}$ je koeficient pro výpočet HPH z investovaných prostředků.

Počet vytvořených pracovních míst ve fázi výstavby se vypočítá podle vzorce uvedeného v podsekcí 4.4.3, přičemž se použije koeficient pro výpočet FTE při výstavbě. K odhadnutí přínosů do veřejného rozpočtu použijeme průměrnou mzdu pracovníků na výstavbě a vzorce z podsekcí 4.4.3.

Ve fázi provozu datového centra se pro modelování HPH použijí vzorce uvedené v podsekcí 4.4.5, které zohledňují tržby z provozu datového centra a mezispotřebu. Pro výpočet přínosů do veřejného rozpočtu se použijí vzorce z podsekcí 4.4.3 s koeficientem FTE při provozu a průměrnou mzdou pracovníků v provozu. Environmentální dopady se vypočítají podle vzorců z podsekcí 4.4.6.

4.5 Finální struktura modelu

Model je navržený tak, aby zachycoval dopady výstavby AI datových center ve třech oblastech: energetika, ekonomika a životní prostředí. Pro každou z těchto oblastí jsou definovány klíčové výpočetní bloky, které se vzájemně propojují a umožňují komplexní analýzu dopadů datových center v ČR. Je však nutno zmínit, že model je záměrně zjednodušený a nezohledňuje všechny možné faktory – přestože jsou instalovaný příkon a PUE stěžejní pro určení spotřeby a rámcově i produkce datového centra, důležitou roli hrají také konkrétní lokalita stavby, vlastnická struktura provozující firmy, architektura chlazení a další. Model tyto nuance zohledňuje pouze prostřednictvím scénářů, které představují vývoj různých variant, avšak nedokáže plně zachytit všechny možnosti.

Z uvedených vstupů tedy model vypočítá celkovou spotřebu datových center, od které odvozuje náklady na elektřinu, ekologickou daň a emise CO_2 do ovzduší. Vstupní parametry dále umožňují odhadnout celkovou produkci datových center, která se následně promítne do hrubé přidané hodnoty. Díky datům o počtu vytvořených pracovních míst a průměrné mzdě model vypočítá zdanění práce, které se spolu s ekologickou daní a daní z nemovitosti sečte do

celkových přínosů do veřejného rozpočtu. HPH a environmentální dopady pak slouží pro komplexní posouzení dopadů výstavby a provozu.

Finálním výstupem modelu jsou jednotlivé ukazatele (HPH, přínosy do veřejného rozpočtu) pro každý z modelovaných scénářů, vynásobené předpokládanou dobou výstavby τ_{const} a sečtené se zbývajících ukazateli (HPH, přínosy, emise CO_2 a spotřeba vody) vynásobenými dobou provozu τ_{ops} – ty jsou dále agregovány do jedné očekávané hodnoty pro každý ukazatel. Jednotlivé parametry použité v modelu jsou uvedeny v příloze B včetně dodatečných komentářů k jejich získávání.

Celkově tato kapitola popsala metodologii výpočtů a strukturu modelu, který bude následně implementován ve webové aplikaci. Model je navržen tak, aby byl flexibilní a umožňoval snadné úpravy vstupních parametrů a scénářů, což je klíčové vzhledem k rychlému vývoji technologií a trhu s AI datovými centry. Jeho funkčnost a použitelnost bude dále demonstrována v kapitole 6, kde budou prezentovány výsledky pro jednotlivé scénáře a jejich interpretace. Zároveň bude model použit pro vymodelování dopadů v jiných zemích podobných České republice, což umožní zjistit jeho přesnost a robustnost na skutečných scénářích.

Vizualizace modelu v aplikaci

Tato kapitola se věnuje druhé polovině praktické části práce – návrhu a implementaci interaktivní webové aplikace pro zhmotnění vytvořeného modelu. Aplikace je určena především pro širokou veřejnost, neboť se v ní vysvětlují základní pojmy a texty jsou napsány populárně naučnou formou. Využít ji však mohou i odborníci, protože parametry modelu jsou plně nastavitelné a aplikace zpřístupňuje rozšiřující rozhraní se všemi vypočítanými hodnotami. V následujících sekcích je popsána motivace k vytvoření aplikace, zvolené technologie, softwarová architektura, způsob nasazení a samotné uživatelské rozhraní.

5.1 Motivace k vytvoření aplikace

Samotný model datových center popsaný v kapitole 4 je pouze abstraktní matematickou konstrukcí, kterou je bez konkrétních hodnot těžké si představit. Formální zápis modelu může být navíc hůře pochopitelný, kvůli čemuž je jeho praktická aplikace obtížná.

Model byl nejprve testován v excelovém souboru, který sice umožňoval rychlé zadávání hodnot a okamžité zobrazení výsledků, ale tento přístup není ideální pro prezentaci širšímu publiku. Webová aplikace nabízí lepší možnosti pro vizualizaci složitých dat a umožňuje uživatelům snadno manipulovat s parametry v přívětivém prostředí s dodatečným vysvětlením.

Důležité je zmínit, že výstavba datových center působí na širokou veřejnost, takže je klíčové, aby informace o nich byly snadno dostupné a srozumitelné. Stejně tak je důležité zvýšit povědomí o hlučnosti, emisích a spotřebě vody datových center, které často nejsou zohledňovány v diskuzích o ekonomických přínosech těchto projektů – zejména kvůli tomu, že jde obvykle o PR články placené jejich investory. K tomu je ale potřeba chápat jisté souvislosti.

Cílem této aplikace je tedy vytvořit interaktivní nástroj, který uživatelům umožní vyzkoušet různé vstupy (postavit si fiktivní datová centra) a okamžitě pozorovat dopady jejich rozhodnutí. Aplikace bude poskytovat jak tvrdá data

vycházející z modelu, tak dodatečné vizualizace a srovnání s běžnými referenčními hodnotami (např. srovnání s Temelínem nebo s průměrnou domácností). Tímto způsobem bude komplexní problematika výstavby datových center přístupná a srozumitelná i pro laiky, což může přispět k informovanější veřejné diskusi o těchto projektech a jejich dopadech na společnost a životní prostředí.

5.2 Technologický stack

Pro vývoj aplikace byl vybrán moderní technologický stack založený na JavaScriptu a Reactu, který umožňuje rychlý vývoj a snadnou údržbu pomocí znovupoužitelných komponent. Pro usnadnění vývoje a zajištění konzistentního vzhledu byla zvolena knihovna shadcn/ui, která poskytuje přizpůsobitelné UI komponenty stylizované pomocí Tailwind CSS. Vizualizaci dat v grafech zpracovává knihovna Recharts. Při vývoji byly použity velké jazykové modely Gemini Pro 3.1 a Gemini 3.5 Flash, které pomohly zejména s vytvářením vlastních stylů a s běžnými, opakujícími se operacemi. Architektura aplikace a logické funkce byly vytvořeny bez umělé inteligence.

5.2.1 Jádru aplikace a správa stavu

Prvním krokem při výběru technologického stacku bylo rozhodnutí o platformě, na které bude aplikace postavena. Vzhledem k tomu, že cílem bylo vytvořit interaktivní webovou aplikaci, nabízela se volba JavaScriptu a Reactu. *JavaScript* je pro webový vývoj standardem, zatímco *React* nabízí efektivní správu stavu a možnost okamžité aktualizovat UI v reakci na změny dat.

Mimo to byl React zvolen kvůli vysoké dostupnosti dodatečných knihoven a nástrojů, které usnadňují vývoj a zlepšují zkušenost vývojářů. Díky tomu bylo možné rychle implementovat složité funkce a vizualizace, které by jinak vyžadovaly mnohem více času a úsilí. Dodatečný komentář je v podsekcí 5.2.2.

Dalším důležitým aspektem bylo zajištění rychlého sestavení a vývoje aplikace, což vedlo k výběru frameworku *Vite*. *Vite* poskytuje rychlé načítání a hot module replacement, což výrazně zrychluje vývojový cyklus a umožňuje okamžité zobrazení změn v prohlížeči.

Pro správu stavu byl zvolen *Zustand* – lehká a flexibilní knihovna pro React. V kombinaci s knihovnou *Immer* umožňuje jednoduše a bezpečně měnit globální stavy bez zbytečného kódu. Díky tomuto přístupu bylo možné centralizovat výpočetní logiku a efektivně spravovat stav celé aplikace. Takto lehká aplikace by se bez *Zustandu* sice obešla (stačilo by použít React hooky *useState* a *useMemo*), ale zvolený přístup umožňuje snadné rozšiřování a údržbu kódu v budoucnu.

5.2.2 Uživatelské rozhraní a vizualizace

Pro usnadnění a urychlení vývoje uživatelského rozhraní byly použity knihovny komponent. To znamená, že místo vytváření vlastních UI prvků od nuly byly

importovány již předpřipravené bloky kódu (např. Sidebar, Card, Button, Input, Select), které lze snadno přizpůsobit a integrovat do projektu. Tento přístup výrazně zrychlil vývoj a umožnil se zaměřit na logiku a funkčnost aplikace, místo na design a implementaci základních UI prvků.

Nevýhodou tohoto přístupu naopak je, že se do projektu dostává více kódu, než je skutečně potřeba, což může zvyšovat velikost výsledné aplikace a ztěžovat její údržbu. Pro tento projekt se však takový kompromis ukázal jako výhodný, protože umožnil rychle vytvořit profesionálně vypadající uživatelské rozhraní.

Konkrétně byla použita knihovna komponent *shadcn/ui*, která používá *Tailwind CSS* pro styling a nabízí širokou škálu přizpůsobitelných komponent. Pro vizualizaci dat a grafů byla použita knihovna *Recharts*, která je postavena přímo pro React a umožňuje snadné vytváření interaktivních grafů. Knihovna *shadcn/ui* je postavená právě na Tailwindu a Recharts, takže se všechny technologie navzájem doplňují a umožňují snadnou integraci.

Pro zlepšení uživatelské přívětivosti a plynulosti aplikace byla použita knihovna *Framer Motion*, která umožnila plynulé přechody a animace (při přepínání záložek). Vizualní styl doplňují ikony z knihovny *Lucide React*.

Zde je shrnující přehled použitých knihoven pro uživatelské rozhraní:

Tailwind CSS Utility-first CSS framework pro rychlý a flexibilní návrh moderního vzhledu a responzivního layoutu. Umožňuje snadné přizpůsobení jednotlivých komponent, nicméně vyžaduje psaní většího množství CSS tříd přímo v kódu. Nevýhodou je obtížné udržení konzistentního stylu napříč celou aplikací, což ale řeší vytváření znovupoužitelných komponent.

shadcn/ui Knihovna znovupoužitelných, přístupných a vysoce přizpůsobitelných UI komponent postavená na Radix UI a Tailwindu. Na rozdíl od klasických knihoven (např. MUI) se komponenty instalují přímo do projektu, což dává plnou kontrolu nad jejich kódem a stylem. I přesto se ale do projektu dostává více kódu, než je skutečně potřeba.

Recharts Knihovna pro tvorbu responzivních a interaktivních grafů postavená přímo pro React. Umožňuje snadné vytváření různých typů grafů (sloupcové, spojnicové, koláčové) a jejich přizpůsobení pro vizualizaci dat z modelu.

Framer Motion Knihovna pro plynulé přechody a animace, které zlepšují uživatelskou přívětivost (např. animované přepínání záložek).

Lucide React Sada čistých a moderních ikon doplňující vizualní styl rozhraní.

5.3 Architektura aplikace a datový tok

Protože aplikace nemusí komunikovat se serverem, byla zvolena čistě frontendová architektura. To znamená, že veškerá logika, správa stavu a vizualizace jsou implementovány na straně klienta – odehrávají se v prohlížeči uživatele. Tento

přístup umožňuje rychlé načítání a okamžité zobrazení výsledků bez potřeby čekat na odpověď ze serveru, což je klíčové pro zamýšlenou interaktivitu.

5.3.1 Datový tok a správa stavu

Na vstupu aplikace je uživatel, který zadává hodnoty do formulářů a interaguje s UI. Z několika zadaných vstupů je poté třeba vypočítat součet všech hodnot, dodatečné ukazatele (maximální spotřebu, produkci uhlíku, vytvořenou HPH) a zobrazit je v agregované formě. Cílem je, aby tyto vstupy byly okamžitě zpracovány a výsledky zobrazeny v přehledné formě. Pro tyto účely je v aplikaci implementován jednosměrný datový tok, který lze popsat následovně:

1. Uživatel zadává hodnoty do formulářů a interaguje s UI.
2. Po stisknutí Enter nebo změně kontextu jsou tyto hodnoty odesílány do globálního stavu pomocí stavového manažera (Zustand).
3. Před uložením do stavu jsou vložené hodnoty validovány. V případě úspěchu validace jsou obohaceny o dodatečné výpočty dle kapitoly 4 na úrovni jednotlivých datových center.
4. Jakmile jsou nové hodnoty uloženy ve stavu, spouští se agregační logika, která počítá data napříč všemi datovými centry.
5. Po změně agregačního objektu se všechny komponenty, které tento objekt používají, automaticky překreslí a zobrazí aktualizované výsledky.

Tento přístup je výhodný kvůli tomu, že umožňuje ukládat všechny hodnoty v centrálním skladu (globálním stavu), který je směrodatný pro celou aplikaci. Díky tomu je zajištěna konzistence a snadná správa dat, protože všechny komponenty se odkazují na stejný objekt. Architektura obohacování jednotlivých DC o dodatečné výpočty navíc umožňuje zobrazit nejen agregované hodnoty, ale také dopady jednotlivých datových center (viz podsekcí 5.5.2).

Algoritmická složitost přidávání datového centra je lineární – samotné přidání objektu DC je konstantní se složitostí $\mathcal{O}(1)$ a následné přepočítání agregace je lineární se složitostí $\mathcal{O}(n)$ vzhledem k počtu datových center. Pro zlepšení výkonu by bylo možné implementovat pokročilý přístup, který by pouze přepočítával agregaci pro změněné datové centrum a celková složitost by tak byla konstantní. To by ale vyžadovalo do stavu ukládat také agregovaný objekt, což by zvyšovalo náročnost údržby. Pro tento projekt však není potřeba optimalizovat výkon, protože počet datových center bude pravděpodobně omezený a lineární přístup je dostatečně rychlý.

5.3.2 Struktura projektu a oddělení zodpovědnosti

Zdrojový kód je rozdělen do několika složek, které logicky oddělují různé aspekty aplikace a usnadňují její údržbu a rozšiřování. Hlavní složky jsou:

components Obsahuje znovupoužitelné UI komponenty, které jsou přizpůsobeny pro potřeby aplikace. Tyto komponenty jsou postavené na knihovně `shadcn/ui` a slouží k vytváření uživatelského rozhraní.

logic Obsahuje veškerou výpočetní logiku, která zpracovává vstupy od uživatele a generuje výsledky. Soubor `enrich.js` implementuje výpočetní logiku z kapitoly 4 a `engine.js` zajišťuje agregaci hodnot datových center.

constants Obsahuje konstantní hodnoty a nastavení, které jsou používány napříč celou aplikací. Tento přístup umožňuje centralizovat důležité hodnoty a usnadňuje jejich údržbu.

store Obsahuje implementaci stavového manažera (`Zustand` a `Immer`), který spravuje globální stav aplikace a zajišťuje jeho konzistenci.

Celkově je aplikace navržena pro snadnou rozšiřitelnost a údržbu, přičemž logika a vizuální komponenty jsou jasně oddělené. Vytváření komponent je závislé na konfiguračních souborech s konstantami (aby bylo možné snadno měnit hodnoty a přizpůsobovat aplikaci bez zásahu do samotných komponent).

Tento přístup se při vývoji osvědčil, protože několikrát umožnil rychle přidat nové funkce a změnit vizuální styl bez nutnosti zásahu do logiky nebo naopak. Díky tomu bylo možné udržet kód čistý a dobře organizovaný, což je klíčové pro jeho úspěšný vývoj.

5.4 Dlouhodobá údržba a provoz aplikace

Vzhledem k tomu, že se jedná o projekt vytvořený pro účely bakalářské práce a nepředpokládá se jeho dlouhodobá údržba ani další rozšiřování, nebyly pro aplikaci vytvořeny automatizované testy ani automatizovaná CI/CD pipeline. Veškeré úkony spojené s nasazením a ověřováním funkčnosti tak probíhají manuálně, což je vzhledem k rozsahu a účelu projektu dostačující.

5.4.1 Nasazení na server

Aplikace byla nasazena na servery Fakulty informačních technologií ČVUT přes službu Cloud FIT. Na žádost byl autorovi práce vytvořen virtuální server s přístupem přes SSH, na který byla aplikace nahrána a nakonfigurována pro běh. Pro zajištění snadného nasazení a správy aplikace byl vytvořen `Dockerfile`, který umožňuje kontejnerizaci celé aplikace. Tento přístup usnadňuje nasazení nové verze, protože stačí sestavit nový Docker image a spustit ho na serveru.

Aplikace byla už od počátku vyvíjena pomocí Dockeru, což umožnilo snadný vývoj, testování i nasazení. Zdrojový kód tak obsahuje vývojový `Dockerfile` `Dockerfile.dev` a `docker-compose.dev.yaml`, které spouštějí kontejner lokálně. Pro produkční nasazení byl vytvořen samostatný `Dockerfile`, který je optimalizovaný pro produkční prostředí a obsahuje pouze nezbytné závislosti a soubory. Tento

Dockerfile umožňuje sestavit image, který je připraven pro nasazení na server a zajišťuje, že aplikace bude běžet stabilně a efektivně.

Distribuce nejnovější verze aplikace probíhá přes vytvoření nového Docker image a jeho nahrání na Docker Hub. Na serveru je poté stažena nejnovější verze image a spuštěna jako kontejner v pozadí. Tento přístup umožňuje rychlé a efektivní nasazení nové verze aplikace bez nutnosti manuální konfigurace nebo zásahu do kódu na serveru. Díky Dockeru je také zajištěna konzistence prostředí, což minimalizuje riziko problémů způsobených rozdíly mezi vývojovým a produkčním prostředím.

5.4.2 Testování aplikace

Vzhledem k rozsahu a primárně akademickému účelu projektu nebyly pro aplikaci vytvořeny komplexní sady automatizovaných testů, a to i přesto, že je aplikace nasazena v ostrém provozu pro veřejnou prezentaci modelu. Během vývoje však byly prováděny důkladné manuální testy, které zahrnovaly zadávání různých hodnot do formulářů a ověřování, že výsledky odpovídají očekáváním na základě vzorců popsaných v kapitole 4. Testování se zaměřovalo na správnost výpočtů, konzistenci zobrazení a uživatelskou přívětivost rozhraní.

Hlavním důvodem, proč nebyly napsány automatizované testy, je fakt, že se z pohledu autora jedná o jednorázový projekt, který nebude dále rozšiřován ani udržován. Psaní testů by v tomto případě nebylo efektivní, protože by vyžadovalo značné množství času a úsilí, které by nebylo adekvátní vzhledem k rozsahu a účelu projektu. Při případném dalším rozvoji aplikace by však bylo vhodné implementaci automatizovaných testů zvážit.

5.5 Uživatelské rozhraní a průchod aplikací

Uživatelské rozhraní aplikace je navrženo tak, aby bylo intuitivní a snadno použitelné. Klíčovým prvkem je boční panel (Sidebar), který funguje jako správce portfolia DC a parametrů modelu. Ve středu obrazovky se pak nacházejí kartičky zobrazující vypočtené hodnoty, které se okamžitě mění v závislosti na zadaných parametrech. V horní části obrazovky je umístěna navigace umožňující přepínat mezi jednotlivými pohledy s detaily o dané oblasti.

Aplikace je optimalizovaná také pro mobilní zařízení, nicméně vzhledem k množství zobrazených dat a komplexnosti rozhraní je doporučeno ji používat na větších obrazovkách. Níže je proto popsán především desktopový zážitek, ale všechny uvedené funkce jsou dostupné i na mobilních zařízeních.

5.5.1 První pohled na model

Při prvotním načtení aplikace se uživateli zobrazí úvodní obrazovka se základním přehledem o zadaném portfoliu, které je zpočátku tvořeno jedním kolokačním datovým centrem. Uživatel má možnost se seznámit s hlavními

metrikami, které jsou zobrazeny na kartičkách uprostřed obrazovky. Obrazovka po prvním načtení a bez jakýchkoli změn je uvedena na obrázku C.1.

Kompletní vysvětlení toho, jak se model používá, se uživateli zobrazí po rozkliknutí sekce „Jak model používat?“, která se nachází přímo pod hlavním přehledem portfolia. Po rozkliknutí se zobrazí několik kartiček, které lépe popisují model a dodávají kompletní návod na jeho použití. Na obrázku C.2 jsou tyto kartičky zobrazeny, nicméně po najetí myši zobrazí další obsah s detailnějším vysvětlením, který na snímku obrazovky není přítomen.

5.5.2 Ovládací panel

Téměř veškeré ovládání modelu se sdružuje v levém bočním panelu (Sidebar), což je uživatelsky přívětivé a snadno pochopitelné. Tento panel slouží jako hlavní místo pro přidávání nových datových center: Uživatel klikne na tlačítko Přidat, načež se mu zobrazí formulář pro zadání základních parametrů datového centra (typ, příkon, PUE a jejich počet). Po zadání nebo úpravě těchto hodnot se model přepočítá a uživatel může okamžitě pozorovat dopady změny.

Hlavní obrazovka po přidání několika datových center je zobrazena na obrázku C.3. Snímek také ukazuje, jak se po rozkliknutí detailu jednotlivých datových center zobrazují dílčí výpočty. To je umožněno architekturou postupného obohacování popsanou v sekci 5.3. Pro lepší pochopení zadávaných hodnot může uživatel kliknout na ikonu otazníku vedle tlačítka Přidat, která mu zobrazí vysvětlení jednotlivých parametrů a dodá základní přehled o typech datových center. Část této nápovědy ukazuje snímek C.4.

Ovládací panel dále umožňuje nastavovat parametry, které se netýkají konkrétního datového centra, ale mají dopad na všechny výpočty. Uživatel rozklikne položku Konfigurace parametrů, která mu zobrazí tlačítko pro přepočítání a resetování parametrů a několik sekcí, v nichž jsou parametry logicky uskupeny. Jednotlivé sekce ukazují obrázek C.5 včetně rozbalené nápovědy u jednoho z parametrů. Tato nápověda existuje pro každý z parametrů.

Pro změnu parametru modelu stačí přepsat hodnotu a kliknout na zelené tlačítko Přepočítat, načež se všechny hodnoty okamžitě aktualizují. Pro resetování všech parametrů do výchozího stavu slouží tlačítko Obnovit. Smazání vlastních parametrů je nicméně potřeba potvrdit ve vyskakovacím okně, aby nedošlo k nechtěné ztrátě dat. Poslední nastavení parametrů se nachází v pravém horním rohu obrazovky, kde lze přepínat výchozí scénář (Pesimistický, Realistický, Optimistický). Tato možnost ovlivňuje zobrazení KPI karet, nicméně na grafy nemá vliv – ty obecně ukazují srovnání všech scénářů najednou.

5.5.3 Záložka Přehled

První záložka, na kterou se uživatel dostane, je Přehled. Ta byla již ve zkratce popsána v podsekci 5.5.1, která se zaměřovala především na průchod aplikací krok za krokem. Samotná obrazovka však nabízí dobrý přehled o zadaném

portfoliu a umožňuje uživateli rychle pochopit, jaké dopady mají jeho rozhodnutí napříč všemi oblastmi. Na kartičkách uprostřed obrazovky se zobrazují klíčové metriky, jako je celková spotřeba energie, produkce uhlíku, vytvořená HPH a další. Chybí zde srovnání a detailnější vysvětlení, neboť ty jsou dostupné v dalších záložkách. Vizualizace je na obrázku C.3.

Vpravo od KPI kartiček se nachází komponenta zobrazující složení portfolia. Ta umožňuje rychle pochopit, jaké typy datových center jsou v zadaném portfoliu zastoupeny a jaký mají podíl na celkových dopadech. Uživatel tak může snadno identifikovat, které typy datových center přispívají nejvíce k určitým metrikám (např. spotřebě energie nebo produkci uhlíku) a případně upravit své portfolio pro dosažení jiných výsledků.

5.5.4 Záložka Elektřina

Po překliknutí na záložku Elektřina se uživateli zobrazí detailnější informace o spotřebě portfolia. Na obrázku C.6 (s přidanými čísly jednotlivých komponent) je zobrazeno celkové rozložení obrazovky, nicméně jednotlivé kartičky se po najetí myši rozbalí a zobrazí komentáře vysvětlující konkrétní hodnoty a dodatečný kontext. Příklad pro rozbalené KPI kartičky je ukázán na obrázku C.7. Komponenty na obrázku odpovídají následujícím popisům:

1. První kartička obsahuje obecný komentář o problematice vysoké elektrické spotřeby datových center. První věta je úvodní, po najetí myši se objeví dodatečný text s hlubšími myšlenkami a dodatečným vysvětlením.
2. Graf *Rozpad spotřeby portfolia* ukazuje srovnání spotřeby napříč všemi scénáři a efektivitu využití energie. Celková výška sloupce je maximální spotřeba energie portfolia, šedá část je nevyužitá kapacita, oranžová část ukazuje režijní spotřebu a modrá efektivní spotřebu výpočetními zařízeními.
3. Komponenta *Kapacity přenosové sítě ČR* ukazuje, zda by se zadané portfolio dokázalo vměstnat do přenosové sítě ČR. Po najetí myši se zobrazí posuvník, pomocí kterého uživatel může nastavit aktuální zatížení přenosové soustavy. Toto zatížení se sečte s celkovým příkonem portfolia a ručička barometru ukáže, zda je v takové situaci celé portfolio provozovatelné.
4. *KPI kartičky* zobrazují klíčové metriky týkající se spotřeby energie, jako je pravděpodobná spotřeba nebo podíl na spotřebě ČR. Tyto kartičky poskytují rychlý přehled o energetickém dopadu zadaného portfolia. Po najetí myši zobrazují srovnání s referenčními hodnotami jako na obrázku C.7. Kliknutí na otazník u srovnání uživatele přesměruje na zdroj informace.
5. Komponenta *Simulátor PUE* není napojena na portfolio datových center, ale umožňuje experimentovat s různými hodnotami energetické efektivity. Uživatel nastaví PUE a na poměrovém posuvníku okamžitě vidí, jak se mění efektivita spotřeby energie.

6. Poslední komponentou je *Kontextová kartička* obsahující čistě textové informace o inovacích a trendech v oblasti energetické efektivity datových center. Uživatel překlíkává mezi jednotlivými záložkami a zobrazí si tak dodatečné informace o různých oblastech.

V rámci celé aplikace se tato obrazovka zaměřuje především na vysvětlení dopadů zadaného portfolia z pohledu spotřeby energie, což je asi nejdůležitější aspekt datových center. Kvůli tomu je obsahově poměrně bohatá a nabízí celou řadu interaktivních komponent.

5.5.5 Záložka **Ekonomika**

Druhá obrazovka se zaměřuje na ekonomické dopady zadaného portfolia. Zobrazuje investiční náklady, počet vytvořených pracovních míst a fiskální přínosy do veřejného rozpočtu. Jednotlivé komponenty jsou interaktivní a po najetí myši zobrazují další informace. Obrázek C.8 odpovídá následujícím popisům:

1. První kartička obsahuje metodický komentář o ekonomických dopadech datových center a o tom, zda se je vyplatí stavět. Po najetí myši se zobrazí poměrně komplexní text popisující ekonomické externality.
2. *KPI kartičky* zobrazují klíčové metriky týkající se ekonomických dopadů, jako jsou anualizované kapitálové náklady, roční HPH, počet vytvořených pracovních míst (FTE) a odhadované daně a odvody. Po najetí myši zobrazují srovnání s referenčními hodnotami (km dálnic, srovnání s ostatními odvětvími, ...).
3. *Kontextová kartička* se zaměřuje na vysvětlení a interpretaci HPH v kontextu DC. Zdůrazňuje, že nejde o ekvivalent zisku ani příjmu do veřejného rozpočtu – naopak ukazuje, že velká část hodnoty se ztratí v odpisech.
4. Graf *Dekompozice tržeb* ukazuje srovnání celkové produkce a jejího rozdělení na přidanou hodnotu a hlavní provozní náklady (zejména elektřinu) napříč všemi scénáři. Výška sloupce představuje celkovou produkci.
5. Graf *Kumulativní vývoj HPH* vizualizuje dlouhodobý pohled na to, jak se v čase sčítá přidaná hodnota vytvořená během výstavby a následného provozu portfolia v horizontu 25, 30 nebo 35 let (v závislosti na scénáři).

U ekonomických údajů bylo poměrně obtížné vymyslet smysluplné srovnání kvůli časovému rozdělení nákladů. Životnost budovy je totiž přes 25 let, zatímco IT vybavení morálně zastarává mnohem rychleji (cca 4 roky). Pro zachování konzistence je tak pro všechny údaje zvoleno referenční období jednoho roku, takže v případě investic se zobrazují anualizované kapitálové náklady za celou dobu životnosti (vč. několika cyklů obměny IT vybavení). Tento přístup dává největší smysl vzhledem k ostatním metrikám, zejména HPH.

5.5.6 Záložka ESG

Poslední tematickou záložkou je ESG popisující environmentální a společenské dopady zadaného portfolia. Tato sekce je důležitá pro investory i veřejnost, neboť výstavba datových center má významnou ekologickou stopu, kterou je třeba monitorovat. Na obrázku C.9 jsou ukázány komponenty odpovídající následujícím popisům:

1. První kartička obsahuje obecný komentář o problematice ESG v kontextu datových center. Jako jediná nemá nastavený hover efekt – její obsah je již zcela zobrazen. Text se zaměřuje na vysvětlení, proč je ESG důležité a jaké jsou hlavní environmentální a sociální dopady datových center.
2. Graf *Srovnání spotřeby a emisí* ukazuje srovnání emisí skleníkových plynů v závislosti na spotřebě napříč všemi scénáři. Po najetí myši se zobrazí komentář, který vysvětluje paradoxní pokles emisí při růstu spotřeby energie.
3. *KPI kartičky* ukazují klíčové metriky týkající se ekologické a sociální stopy, jako jsou roční emise CO₂, roční spotřeba vody, emise uhlíku a prostorová náročnost. Po najetí myši zobrazí srovnání s referenčními hodnotami.

Celkově je ESG nejméně obsáhlou obrazovkou – zejména kvůli tomu, že environmentální a sociální dopady jsou již z velké části zobrazeny v předchozích záložkách. I přesto je nepostradatelnou součástí, protože vysvětluje metodologii výpočtů jednotlivých ukazatelů a poskytuje srovnání s referenčními hodnotami.

5.5.7 Nastavení a debugování

Hover efekty (po najetí myši) jsou v celé aplikaci využívány pro zobrazení dodatečných informací, nicméně na mobilních zařízeních jsou nepoužitelné. Navíc pro některé uživatele může být nepohodlné neustále přejíždět myší. Kvůli tomu byla přidána funkce Rozbalit všechny karty dostupná z Nastavení v horní části obrazovky. Po jejím zapnutí se rozbalí všechny karty, díky čemuž se informace lépe čtou. Fungování je ilustrováno na obrázku C.10.

Pro potřeby odborné veřejnosti a pro ověření správnosti výpočtů aplikace obsahuje skrytou záložku Debug, kterou lze taktéž aktivovat v Nastavení. Záložka zpřístupňuje rozšiřující rozhraní se všemi vypočítanými hodnotami, které nejsou v běžném UI zobrazeny. Uživatel si tak může prohlédnout detailní rozpad všech metrik. Tato záložka je primárně určena pro kontrolu modelu a pro uživatele, kteří chtějí hlouběji porozumět tomu, jak aplikace dospěla k výsledným číslům. Ukázka je na obrázku C.11.

Testovací scénáře pro model

Pro ověření výsledků modelu byla vytvořena vzorová portfolia odpovídající mixu datových center jiných evropských zemí. Tato portfolia lze v uživatelském rozhraní načíst a následně porovnat výsledky modelu s veřejně dostupnými daty o infrastruktuře dané země. Ukázalo se, že tento přístup je problematický kvůli nedostupnosti specifických parametrů a výsledných hodnot. Bez jejich znalosti tak lze spolehlivě otestovat pouze výstupy nezávislé na parametrech specifických pro danou zemi, v čemž model uspěl s vysokou přesností.

6.1 Metodologie testování

Proces testování spočívá v porovnávání výsledků modelu (vypočtených na základě reálných parametrů) se skutečnými údaji o energetické infrastruktuře vybrané země. Metodologie se dá shrnout do následujících kroků:

1. Zjištění složení portfolia datových center pro danou zemi, včetně jejich kapacity a energetické efektivity. Případně je možné složení portfolia odhadnout na základě agregovaných informací.
2. Získaná data se zadají do modelu a vypočítají se výsledné hodnoty. Import je možný buď ručně, nebo zadáním přímo do zdrojového kódu modelu (k tomu je potřeba stáhnout repozitář). Jediný rozdíl mezi uvedenými přístupy je, že zadáním dat do zdrojového kódu se portfolio datových center uloží.
3. Dalším krokem je srovnání výsledků modelu s reálnými daty a informacemi o energetické infrastruktuře dané země. To zahrnuje porovnání vypočítaných hodnot s veřejně dostupnými daty o spotřebě energie, kapacitě datových center a dalšími relevantními parametry.
4. Nakonec dojde k vyhodnocení úspěšnosti testů a identifikaci případných odchylek nebo nesrovnalostí.

Tímto způsobem lze ověřit, zda model poskytuje realistické výsledky. Do zdrojového kódu byla nahrána 4 vzorová portfolia pro různé země: Českou republiku, Irsko, Německo a USA.

6.2 Testovací scénáře

V následujících podsekcích jsou popsány jednotlivé testovací scénáře pro vybrané země. Každý scénář zahrnuje použité portfolio a výsledky modelu, které jsou porovnány s reálnými daty o energetické infrastruktuře dané země.

6.2.1 Testování v uživatelském rozhraní

Do levého menu UI byla přidána záložka s názvem Vzorová portfolia. Ta obsahuje tlačítka s popisem, přičemž každé tlačítko představuje jedno z testovacích portfolií. Po jeho rozkliknutí se portfolio načte do paměti aplikace a okamžitě se aktualizují výstupy modelu. Vizualizace je na obrázku C.12.

Tento způsob umožňuje nejen ověřit správnost výpočtů modelu, ale také demonstrovat rozdíly mezi datovou infrastrukturou v České republice a v zahraničí. Uživatelé tak mohou získat lepší představu o tom, jak se liší energetická náročnost datových center v různých zemích.

6.2.2 Testovací scénář 1: Česká republika

Pro scénář ČR bylo vytvořeno portfolio, které odpovídá datům získaným při autorském mapování domácího trhu (viz sekci 4.1). Údaje byly odvozeny z katastru nemovitostí a Data Center Map. Mix je tvořen několika typy kolokačních a dvěma plánovanými AI trénovacími centry (viz tabulku 6.1).

Jelikož doposud nebyla k dispozici ucelená data o stavu DC v ČR (jejich získání bylo cílem této práce), tento scénář nelze přímo ověřit. I přesto je z uživatelského pohledu důležitý – umožňuje pochopit strukturu českého trhu, porovnat ji se zahraničím a sledovat dopady, které DC v ČR už teď způsobují.

■ **Tabulka 6.1** Složení portfolia pro testovací scénář Česko

Typ centra	IT příkon [MW]	PUE	Počet
Kolokační	0,45	1,70	22
Kolokační	1,33	1,50	11
Kolokační	3,16	1,40	15
Kolokační	9,75	1,35	4
Trénovací	0,20	1,30	2
Trénovací	26,00	1,20	2

Celkový IT příkon tohoto portfolia je 163,33 MW s váženým průměrem PUE 1,32. Odhadovaná roční spotřeba je 1,136 TWh. To odpovídá přibližně 3/4 spotřeby Karlovarského kraje (včetně průmyslu). 70 % výkonu portfolia tvoří kolokační datová centra, zbytek jsou plánovaná AI trénovací centra (Prague Gateway DC a DC Kanice). K dubnu 2026 je české portfolio tvořeno téměř výhradně kolokačními centry.

Co se týče dopadů na ekonomiku, datová centra v ČR budou zaměstnávat přibližně 105 lidí. Tento údaj je však s největší pravděpodobností podhodnocený kvůli velkému podílu kolokačních center v portfoliu. Ta totiž nedosahují tak vysoké míry automatizace jako AI centra, na něž se model primárně zaměřuje. V budoucnu česká datová centra vygenerují HPH 20 miliard Kč ročně – momentálně (bez DC ve výstavbě) je to asi 3 miliardy Kč.

Ani spotřeba vody není v českém scénáři vyjádřena přesně, protože je stejně jako v případě počtu zaměstnanců dimenzovaná především na AI datová centra. Kolokační centra často využívají vzduchové chlazení, které tak vysokou vodní stopu nezpůsobuje. Portfolio teď produkuje asi 200 000 tun CO₂ ročně (Scope II) a po přidání plánovaných DC to bude asi dvakrát tolik (odpovídá ročnímu provozu asi 150 000 osobních automobilů).

6.2.3 Testovací scénář 2: Irsko

Irsko je evropským lídrem v oblasti hyperscale datových center. Jeho portfolio zahrnuje velká kolokační i specializovaná AI centra společností Google, Meta či Amazon (viz tabulku 6.2). Specificky u Irska byla data zapsána ve formě klastrů (shluků center) namísto jednotlivých budov, což vysvětluje nižší absolutní počet položek, ale pro účely testování modelu tato agregace nevádí.

Celkový instalovaný IT příkon portfolia činí 1 050 MW s průměrnou hodnotou PUE 1,33. Portfolio je tvořeno ze dvou třetin kolokačními centry, což je trend potvrzený i v literatuře [70]. Roční spotřeba predikovaná modelem je 6,45 TWh, což také odpovídá veřejně dostupným datům [71]. Reporty uvádějí také emise CO₂, které agentura Bitpower odhaduje na 1,52 milionu tun ročně. Model uvádí odhad 2,1 milionu tun, protože počítá s českým emisním faktorem. Pokud do parametrů nahrajeme irský faktor 0,2241 tuny CO₂/MWh [72], model vypočítá 1,44 milionu tun CO₂, což je blízko hodnotě z reportu.

■ **Tabulka 6.2** Složení portfolia pro testovací scénář Irsko

Typ centra	IT příkon [MW]	PUE	Počet
Kolokační	20,00	1,35	30
Kolokační	10,00	1,60	10
Trénovací	50,00	1,20	3
Inferenční	40,00	1,25	5

Je zajímavé, že Irsko má poměrně nízké PUE – průměr celého portfolia činí 1,32 oproti globálnímu průměru cca 1,50. To je dáno zejména tím, že v Irsku je dostatek vody pro vodní chlazení, které je energeticky efektivnější. Roční spotřebu vody model odhaduje na 15 miliard litrů. To zdaleka neodpovídá vládním datům z roku 2021, která uvádějí hodnotu 810 milionů litrů [73]. Nejedná se ale o chybu modelu, nýbrž o zmiňovanou netransparentnost dat:

- Jak poukazuje McGrathová [74], mezi vládními statistikami a realitou existuje velký rozpor: oficiální dokumentace společnosti Facebook ukazuje, že údajnou roční spotřebu všech DC překračuje dokonce jediné její datové centrum v Clonee. To naznačuje, že vládní data jsou podhodnocená.
- Vláda do svých statistik totiž zahrnuje pouze spotřebu přes vodoměry, ale mnoho datových center využívá vodu z veřejného vodovodu bez měření nebo vodu z přírodních zdrojů, což se v datech neprojeví.
- Dalším důležitým faktorem je, že statistika nezapočítává vodu spotřebovanou pro výrobu elektřiny (Scope II). Podle studie Lohrmannové [75] se pro výrobu 1 MWh elektřiny v Irsku spotřebuje asi 1 300 litrů vody. Pokud číslo vynásobíme odhadovanou roční spotřebou 6,45 TWh, dostaneme dalších 8,4 miliardy litrů vody – desetinásobek oficiálního odhadu.
- Přestože vláda hovoří specificky o přímé spotřebě vody, její přístup je netransparentní. To jen dále poukazuje na to, že údaje o spotřebě vody datovými centry jsou citlivé a že stojí za to se jimi zabývat.
- Je nutno podotknout, že i tak model spotřebu vody s výchozími parametry nejspíš nadhodnocuje asi o 5 miliard litrů. To je dáno tím, že spotřeba vody pro chlazení je odhadována podle dat z USA, které mají průměrně vyšší spotřebu vody na 1 MWh vyrobené energie. Při zadání irských parametrů by odpovídala realitě mnohem více.

Bitpower [71] dále uvádí, že celková investice do výstavby a vybavení irských datových center činila asi jeden bilion Kč. Model projektuje 1,5 bilionu Kč, nicméně tento údaj vypovídá o investicích za celou dobu životnosti datových center. Pokud uvážíme pouze polovinu této částky (průměrně odpovídá 15 letům provozu DC), získáme 800 miliard Kč, což je mnohem blíže částce stanovené Bitpower. Je však nutno poznamenat, že odhad z reportu je pravděpodobně podhodnocený, protože nezahrnuje náklady na pořízení pozemků, které v USA tvoří asi 6 % nákladů na výstavbu (viz sekci 2.3.1).

Ostatní výstupy modelu jsou již velice závislé na specifických parametrech pro Českou republiku, takže jejich srovnávání s reálnými daty pro Irsko nedává smysl. Navíc je údaj jako počet zaměstnanců v irských datových centrech velmi obtížné získat – informace se obvykle agregují na celý IT sektor a samotní poskytovatelé je nezveřejňují. To stejné platí pro data o HPH.

■ **Tabulka 6.3** Složení portfolia pro testovací scénář Německo

Typ centra	IT příkon [MW]	PUE	Počet
Kolokační	1,00	1,60	880
Kolokační	2,00	1,50	400
Kolokační	5,00	1,40	100
Trénovací	70,00	1,25	6
Inferenční	40,00	1,35	10

6.2.4 Testovací scénář 3: Německo

Německý trh patří k největším v Evropě. Portfolio reflektuje vysoký počet menších i středně velkých center (viz tabulku 6.3), přičemž jejich mix byl vybrán podle studie Mordor Intelligence [76]. Německo se momentálně potýká s nedostatkem kapacit přenosové sítě, což způsobuje výraznou stagnaci růstu trhu. Investice by se tak mohly přesunout do okolních zemí – včetně ČR.

Celkový IT příkon německého portfolia je 3 000 MW s váženým průměrem PUE 1,43. Model předpokládá roční spotřebu 19,921 TWh, což potvrzuje report německého Ministerstva ekonomických věcí a klimatu z roku 2025 [77] (projektuje 20 TWh). Zajímavá jsou data od Německé agentury pro obchod a investice (GTAI) [78], která odhadují příspěvek DC k německému HDP na 10,4 miliardy eur ročně (asi 250 miliard Kč). Model v realistickém scénáři předpovídá 210 miliard Kč, což je relativně blízko odhadu GTAI.

Velmi dobře odpovídá také odhad emisí CO₂ – model predikuje 6,6 milionu tun, zatímco ministerstvo [77] uvádí 6,5 milionu tun. Přesnost tohoto výpočtu je dána tím, že ČR a Německo mají podobný emisní faktor. Údaje o počtu zaměstnanců a o spotřebě vody se opět nepodařilo získat.

6.2.5 Testovací scénář 4: USA

USA jako globální lídr disponují největším a nejrozmanitějším portfoliem, které zahrnuje tisíce menších i desítky obřích center (viz tabulku 6.4).

Celkový instalovaný IT příkon pro tento rozsáhlý scénář je 22 050,25 MW při váženém průměru PUE 1,54. Toto vysoké PUE je dáno stářím trhu s vysokým podílem menších kolokačních center, která nevyužívají moderní technologie chlazení. Mnohdy navíc bývají umístěna v nehostinných oblastech bez dostatku vody, což energetickou efektivitu dále snižuje. Odhadovaná roční spotřeba v realistickém scénáři je 173 TWh, což odpovídá literatuře [24].

Původní data z USA byla použita pro vytvoření modelu, kvůli čemuž nemá smysl je srovnávat s jeho výstupy – jednalo by se de facto o srovnání stejných hodnot. Scénář proto slouží spíše k poskytnutí pohledu na to, jak model funguje pro zemi s rozmanitým portfoliem datových center.

■ **Tabulka 6.4** Složení portfolia pro testovací scénář USA

Typ centra	IT příkon [MW]	PUE	Počet
Kolokační	0,85	2,10	2545
Kolokační	3,20	1,85	1440
Kolokační	18,50	1,55	182
Kolokační	92,00	1,45	11
Inferenční	12,00	1,50	156
Inferenční	35,00	1,40	72
Inferenční	110,00	1,30	8
Trénovací	22,00	1,45	94
Trénovací	65,00	1,35	28
Trénovací	145,00	1,25	12

6.3 Vyhodnocení testování modelu

Z testování plyne, že neparametrizované výpočty modelu fungují dobře. Maximální spotřeba, IT příkon nebo průměrné PUE jsou u všech scénářů vypočítány správně. Výpočty používající parametry nezávislé na českých specifikách model provádí také s vysokou přesností, zejména výpočet reálné spotřeby elektřiny. To je klíčové, protože od této hodnoty se odvíjejí další výpočty modelu.

Výpočty závislé na parametrech specifických pro ČR pak nedává smysl srovnávat s daty z jiných zemí, neboť by musely být použity jiné parametry. Při nastavení správných parametrů model odpovídá realitě, což se potvrdilo například u irské produkce oxidu uhličitého. V rámci této práce však nebylo realistické stihnout získat a ověřit všechny parametry pro další země.

Předpoklad je tedy takový, že model správně počítá reálnou spotřebu portfolia datových center, což je klíčový vstup pro další výpočty. Z toho plyne, že i navazující výpočty vypovídají o realitě. Například emise CO₂, které jsou odvozeny z reálné spotřeby, jsou zajisté správné, neboť závisí pouze na spotřebě a emisním faktoru, který je pro Českou republiku známý.

V případě spotřeby vody je situace složitější, protože je složená ze spotřeby samotných DC a spotřeby vody při výrobě elektřiny (Scope II). Model také chybně předpokládá stejnou spotřebu vody pro chlazení u všech typů DC. Predikce tak mohou systematicky vycházet nadehnocené, zejména pro portfolia s vysokým podílem kolokačních center.

Velkou výhodou vytvořené aplikace je však skutečnost, že umožňuje parametry snadno změnit. Pokud bude model testován pro jinou zemi, stačí v UI nastavit odpovídající parametry a spustit výpočet. Momentálně jsou tedy výsledky pro jiné země pouze orientační, ale při doplnění specifických parametrů může model správně vypovídat o různých ekonomikách po celém světě.

Limitace a přínosy práce

Závěrečná kapitola kriticky hodnotí dosažené výsledky, metodologii modelu a praktické přínosy práce. Text rozebírá souvislosti mezi teoretickou rešerší a praktickou implementací, identifikuje hlavní překážky při získávání transparentních informací a shrnuje přidanou hodnotu práce pro odbornou i laickou veřejnost v kontextu rozvoje datových center na území České republiky.

7.1 Diskuse výsledků získaných z modelu

Model poskytuje ucelený pohled na dopady výstavby datových center v České republice a otevírá několik kritických témat pro digitální strategii státu:

Energetika ČR brzy dosáhne negativní energetické bilance i bez vlivu datových center. To však nepředstavuje zásadní problém – elektřinu lze dovézt ze zahraničí. Model však identifikoval úzké hrdlo v kapacitě české přenosové soustavy, která má při běžném zatížení rezervu asi 2 000 MW, ale v energetických špičkách volné kapacity prakticky mizí. Rozvoj velkých AI center by tak vyžadoval buď masivní investice do posílení soustavy, nebo koordinaci spotřeby tak, aby DC omezila výkon v době špičkového zatížení sítě.

Ekonomika Z ekonomického pohledu model odhaluje paradox vysoké produktivity. Datová centra vykazují velmi vysokou HPH, která je však ovlivněna kapitálovou náročností IT hardwaru – jeho odpisy mohou tvořit přes polovinu vytvořené přidané hodnoty. HPH se tak jeví jako nevhodná metrika pro hodnocení přínosů pro ekonomiku, neboť je silně zkresluje. Podobně i dopad na DPH je u AI center nízký, protože se tato daň odvádí v místě spotřeby služby, nikoli ve fyzické lokalitě výpočtu.

Zaměstnanost Nejvýraznějším zjištěním je nepoměr mezi investicemi a zaměstnaností. Jedno špičkové 100MW AI centrum vytvoří přibližně 40 kvalifikovaných pracovních míst. Anualizované náklady na budovu a výpočetní

techniku (cca 18,7 mld. Kč) by však mohly vytvořit přibližně 4 500 míst ve stavebnictví, nebo 2 800 míst ve školství. Provozovatel DC tak na přímých daních a odvodech z mezd odvede do veřejných rozpočtů asi 300 milionů Kč ročně, což je vzhledem k obrovským investicím marginální částka.

Životní prostředí Česká energetika má relativně vysoký emisní faktor, kvůli čemuž je provoz datových center u nás méně ekologický než v severských zemích využívajících vodu nebo ve Francii s jadernou energetikou. Na území ČR navíc není dostatek vody pro vodní chlazení – jeho substituce je sice možná vyšším elektrickým příkonem, ale vede k neefektivitě a snížení hustoty racků, což dále snižuje konkurenceschopnost domácího trhu.

Z čistě ekonomického pohledu tedy výstavba datových center pro globální korporace jako Amazon, Google nebo Meta nedává smysl – dopad na národní hospodářství by byl srovnatelný, i kdyby výpočetní uzly stály v sousední zemi. Rozhodnutí o podpoře výstavby by proto mělo být vedeno strategickými zájmy. Výpočetní výkon je novodobou komoditou podobnou ropě nebo plynu. Smysl dává pouze taková výstavba, kde investor garantuje zpřístupnění kapacit pro domácí výzkum nebo zvýšení kompetencí lokálních firem. Pokud stát nepodmíní výstavbu těmito strategickými požadavky, ČR se stane pasivním hostitelem prázdných budov s minimálním přínosem pro obyvatelstvo.

7.2 Limitace

Při hodnocení výsledků práce je nezbytné reflektovat i její omezení, která mohou ovlivnit interpretaci získaných dat a závěrů. Limitace identifikované během výzkumu shrnují následující body, které jsou vztaženy především k modelu jako stěžejní části této práce, nicméně své technologické limitace má i vytvořená webová aplikace (např. neukládání zadaných vstupů).

Nedostatek dat Za zásadní omezení této práce lze považovat nízkou úroveň transparentnosti v sektoru datových center, což se projevilo již při sběru primárních dat ze zahraničí. Data použitá pro získání hodnot základních technických parametrů v USA pocházejí z různých studií a agregovaných zdrojů, které jsou samy o sobě kvalifikovanými odhady. V českém kontextu pak bylo nutné odhadovat příkon DC na základě velikosti budov z katastru nemovitostí. Matematické vztahy v modelu jsou tedy exaktní, ale některé vstupní konstanty představují pouze nejlepší možnou aproximaci reality.

Umístění DC Model implicitně předpokládá, že v České republice existuje neomezený počet vhodných lokalit s odpovídajícími pozemky a především dostatečně dimenzovanou přípojkou k přenosové nebo distribuční soustavě. Proces hledání konkrétního místa, které splňuje technické, legislativní a logistické požadavky pro výstavbu velkého AI centra, je však velmi náročný. To je ale spíše praktická než metodologická limitace.

Spotřeba vody Metodologickou chybou je zavedení identických koeficientů spotřeby vody a počtu FTE napříč všemi typy datových center. Model využívá data odvozená primárně pro moderní AI centra, ale tradiční kolokační DC v těchto oblastech vykazují odlišné charakteristiky (zpravidla nižší spotřebu vody a vyšší počet zaměstnanců). To sice reflektuje primární zaměření modelu na AI infrastrukturu, ale výsledky pro portfolia tvořená převážně kolokačními centry pak mohou být mírně zavádějící.

Indukované efekty Ekonomická část modelu se omezuje na přímé dopady (daně, odvody, investice) a nezahrnuje nepřímé ani indukované efekty (útraty zaměstnanců v místní ekonomice, poptávka u subdodavatelů). Tyto efekty sice reálně existují, ale jejich kvantifikace by vyžadovala použití ekonomických multiplikátorů a input-output analýz, což přesahuje rámec této práce. Vzhledem k extrémně nízkému počtu zaměstnanců v DC jsou však odvozené efekty méně významné než u jiných odvětví, což potvrzují i četné studie.

Rychlý vývoj trhu Budoucí limitací je aktuálnost parametrů v čase. Trh datových center se mění ze dne na den a neustále vznikají nové generace čipů nebo chlazení, které mohou učinit výchozí parametry neaktuálními. Tento problém je však v rámci práce systémově ošetřen architekturou webové aplikace, která umožňuje uživateli v reálném čase měnit všechny vstupní koeficienty a upravovat tak výpočty podle nejnovějších informací.

Na první pohled by se jako omezení mohlo zdát také nezahrnutí dopadů využití samotné umělé inteligence. Toto rozhodnutí však bylo učiněno vědomě: autorská analýza evropského trhu ukázala, že přínosy plynoucí z adopce AI (např. zvýšení efektivity procesů) nejsou vázány na geografickou polohu výpočtu. Pro ekonomiku tedy není rozhodující, zda jsou výpočty prováděny v ČR nebo v zahraničí – výsledný přínos pro národní hospodářství je identický. Model tak korektně uvažuje pouze dopady fyzické existence DC na daném území.

7.3 Zhodnocení přínosů práce

Prvním zásadním přínosem práce je zpracování komplexní mezioborové literární rešerše, která shrnuje poznatky z technických, ekonomických, energetických i environmentálních oblastí. Tato rešerše nabízí ucelený a v českém prostředí unikátní vhled do celé problematiky datových center. Text srovnává globální technologické trendy s analýzou trhu ve Spojených státech a specifickou situací v České republice. Právě tato šíře záběru umožňuje čtenáři pochopit datová centra nikoliv jako izolované budovy, ale jako součást širšího socioekonomického a infrastrukturního systému.

Na základě teoretických poznatků byl následně vyvinut komplexní matematický model, který představuje stěžejní autorský přínos. Model dokáže v reálném čase propojovat různorodé parametry a kvantifikovat jejich vzájemné vlivy. Velmi důležitou součástí tohoto přínosu byla rovněž identifikace, sběr

a následná syntéza sady vstupních parametrů, které jsou relevantní a optimalizované pro český kontext (např. specifika daňového systému, emisní faktory či lokální mzdové náklady). Tento datový podklad tvoří robustní metodický rámec, který dosud v publikované podobě pro území ČR chyběl.

Všechny výstupy modelu byly nakonec vizualizovány v interaktivní webové aplikaci, která je hlavním praktickým vyústěním práce. Aplikace doplňuje strohá data o rozsáhlý edukativní obsah a referenční srovnání s reálnými objekty (např. spotřebou českých domácností nebo krajů). Díky tomuto propojení odborné metodiky s intuitivním rozhraním a srozumitelnou interpretací výsledků je nástroj vhodný jak pro experty při strategickém plánování, tak pro širokou veřejnost k pochopení dopadů nastupující digitální transformace.

7.4 Možnosti dalšího rozvoje

Vytvořený model a webová aplikace tvoří robustní základ, který však lze dále rozšiřovat a zpřesňovat. Další vývoj by se mohl ubírat těmito směry:

Zahrnutí indukovaných efektů a multiplikátorů Současná verze modelu se soustředí na přímé dopady. Pro komplexnější ekonomický obraz by bylo vhodné integrovat analýzu indukovaných a nepřímých efektů.

Pokročilá daňová analýza Rozšíření modelu by mohlo zahrnovat analýzu zdanění zisků v závislosti na tom, kde je hodnota fyzicky generována vs kde je deklarována. Dále by byla přínosná analýza mechanismů DPH v kontextu digitálních služeb poskytovaných z ČR do celého světa.

Rozšíření sběru dat Získání a analýza dat z jiných zemí pomocí scraperu by umožnila vytvořit benchmark, který by v reálném čase porovnával dopady výstavby v ČR oproti např. Polsku či Německu. Zpřesnění vstupních parametrů by dále snížilo míru neurčitosti v predikcích modelu.

Technologické vylepšení aplikace V aplikaci se nabízí přidání pokročilých komponent pro vizualizaci citlivostní analýzy. Pro zajištění udržitelnosti kódu by bylo žádoucí implementovat testy a nastavit CI/CD pipeline.

Architektura s backendem Přidání backendu a API by umožnilo provádět výpočetně náročnější simulace na straně serveru a poskytovat výsledky (např. ve formátu JSON) dalším systémům. Data by se mohla na server také ukládat a uživatelé by mohli tvořit a sdílet svá portfolia.



Kapitola 8

Závěr

Cílem této práce bylo vytvořit komplexní socioekonomický model a interaktivní webovou aplikaci pro analýzu dopadů výstavby moderních datových center na území České republiky. V kontextu probíhající AI revoluce a s ní spojeného nárůstu poptávky po výpočetním výkonu tato práce představuje multidisciplinární propojení technologického, ekonomického a energetického pohledu na digitální infrastrukturu, která se stává nepostradatelnou pro rozvoj umělé inteligence.

Teoretická část práce poskytla základ pro pochopení fungování datových center, jejich klíčových parametrů a globálních trendů, přičemž analýza trhu v USA posloužila jako varovný i inspirativní příklad. Navržený model tyto poznatky převádí do matematických vztahů, které zohledňují specifika českého daňového systému, energetické sítě i přírodních zdrojů.

Hlavním zjištěním práce je odhalení velkého paradoxu – model ukázal, že ačkoli se do datových center investují desítky miliard korun, jejich přínos pro národní hospodářství (v podobě pracovních míst nebo daňových výnosů) je v porovnání s tradičním průmyslem minimální. Práce rovněž identifikovala úzké hrdlo v podobě kapacity přenosové soustavy, která by při nekontrolované výstavbě AI center mohla v energetických špičkách čelit vážným problémům.

Vytvořená webová aplikace umožňuje odborníkům i široké veřejnosti simulovat různé scénáře rozvoje a v reálném čase sledovat jejich dopady na spotřebu elektřiny, vody, HDP či veřejný rozpočet. Mimo to je praktickým přínosem práce také scraper pro automatický sběr dat o českém trhu s datovými centry.

Celkově by Česká republika k podpoře výstavby datových center pro globální technologické giganty měla přistupovat se strategickou opatrností. Samotná fyzická přítomnost infrastruktury bez garantovaného přístupu k výpočetnímu výkonu pro výzkum a vývoj nepřináší státu výraznou přidanou hodnotu. Tato práce tak slouží jako metodický základ pro strategické rozhodování o tom, zda se ČR stane pouze pasivním hostitelem energeticky náročné infrastruktury, nebo aktivním hráčem, který dokáže výpočetní výkon využít k posílení vlastní technologické suverenity a konkurenceschopnosti.

Popis požadavků v klasifikaci Tier

Následuje slovní popis požadavků v klasifikaci Tier, podle které se určuje dostupnost služeb poskytovaných datovým centrem pro koncové uživatele. Tyto popisy jsou převzaty přímo ze specifikace Uptime Institute [9]:

Tier I: Základní infrastruktura Představuje nejnižší úroveň, která disponuje pouze jednou cestou pro napájení a chlazení bez jakýchkoli redundantních komponent. Tato třída je náchylná k přerušením způsobeným jak plánovanou údržbou, tak neplánovanými poruchami, přičemž očekávaná roční dostupnost dosahuje 99,671 %. Infrastruktura tohoto typu je vhodná pro úlohy, u nichž není kritická kontinuita provozu.

Tier II: Redundantní komponenty Zvyšuje spolehlivost přidáním záložních komponent – stále však využívá jedinou distribuční cestu. Ačkoli redundantní komponenty umožňují snazší údržbu vybraných částí, plánované odstávky distribučních cest stále vyžadují vypnutí systému. Očekávaná dostupnost u této třídy činí 99,741 %.

Tier III: Souběžně udržitelná infrastruktura Představuje skok v robustnosti, neboť disponuje více distribučními cestami pro napájení a chlazení, ale aktivní je vždy jen jedna. Hlavní výhodou je možnost provádět jakoukoli plánovanou údržbu libovolné části infrastruktury bez nutnosti přerušit provoz systému. Tato úroveň garantuje dostupnost 99,982 % a je odolná vůči většině incidentů.

Tier IV: Infrastruktura odolná proti poruchám Nejvyšší třída využívá více nezávislých a současně aktivních distribučních cest. Systém je navržen tak, aby i po kritické poruše jakékoli komponenty nebo cesty zůstal IT výkon nedotčen, což zajišťuje dostupnost na úrovni 99,995 %. Tato třída je určena pro nejkritičtější aplikace.

Vstupní data pro model

V tabulce B.1 jsou uvedeny hodnoty všech použitých parametrů. Obecně vycházejí z literatury a jsou detailně popsány v kapitolách 1, 2 a 3, nicméně některé musely být kvůli nedostatku dat odhadnuty. Pro plnou transparentnost jsou v této příloze uvedeny komentáře, které odhadnuté parametry opodstatňují:

Průměrné mzdy Mzdy na výstavbě vycházejí z předpokladu, že průměrný pracovník pobírá asi 60 000 Kč hrubého za měsíc práce. V tom jsou zahrnuty jak mzdy řemeslníků, tak lépe ohodnocených architektů a projektantů elektrických rozvodů a chlazení. Mzdy v provozu pak vycházejí z průměrné mzdy ve výši 75 000 Kč, do čehož jsou zahrnuty jak vysoce nadprůměrné mzdy IT techniků, tak nižší mzdy ostrahy a případného úklidu.

Cena elektřiny Průměrná cena elektřiny byla vypočítána z dat společnosti Ember [79]. Realistický scénář obsahuje průměr ceny elektřiny za poměrně stabilní dvouleté období leden 2024 – prosinec 2025, přičemž pesimistický a optimistický scénář představují 20% odchylku od této ceny. V realitě mohou být výkyvy vyšší, ale velcí odběratelé si obvykle nasmlouvají odběry na roky dopředu.

Ostatní OPEX Ostatní provozní náklady (nezahrnující energie) jsou modelovány jako fixní podíl z celkových investičních nákladů na výstavbu a vybavení. Realistický scénář uvažuje s hodnotou 2,5 %. Pesimistický (3 %) a optimistický (2 %) scénář pak reflektují variační rozpětí těchto nákladů. Koeficient vychází z díla Pham [37], ve kterém je OPEX uveden jako 8,6 % investičních nákladů, z čehož 39,5 % jde právě na údržbu, administraci a další ($8,6 \% \cdot 39,5 \% \approx 3,40 \%$).

Spotřeba vody Literatura se zde trochu liší, resp. některé studie přesněji neuvádějí, zda se jedná o Scope I, Scope II nebo kombinovanou spotřebu. Uvedené hodnoty se však veskrze shodují, kvůli čemuž byl zaveden předpoklad, že ji lze interpretovat jako Scope I + Scope II spotřebu – tedy vodu

spotřebovanou jak samotným datovým centrem, tak vodu spotřebovanou při výrobě elektřiny pro datové centrum.

Koeficienty pro daň z nemovitosti Model předpokládá, že DC bude postaveno ve středně velkém městě (České Budějovice, Ústí nad Labem, Brno, Olomouc, Zlín, Ostrava), pro která platí koeficient 3,5. Místní koeficient mají tato města také podobný, obvykle 2. Jejich součin tedy činí 7.

Koeficient prodaných kapacit Pro trénovací a inferenční centra se předpokládá, že využití datového centra z prodaných kapacit bude maximální, tzn. veškerá kapacita bude využita k nějakým účelům (typicky pro scénář, kdy DC vlastní jedna firma). Kolokační centra obvykle neprodají veškeré kapacity, což tento koeficient reflektuje. Inferenční centra sice mají vysoce stochastickou poptávku, ale jejich průměrné vytížení zhruba odpovídá kolokačním datovým centrům.

Koeficient spotřeby Přestože mohou inferenční a trénovací centra prodat veškeré kapacity, kvůli prostojům a stochastické inferenci modelů není možné využít kapacitu na maximum, což tento koeficient reflektuje. Koeficient prodaných kapacit tak popisuje ekonomickou dimenzi, zatímco koeficient reálné spotřeby popisuje dimenzi energetickou. Koeficient skutečné spotřeby DC se získá vynásobením těchto dvou koeficientů.

Investiční náklady na výpočetní vybavení Provozovatelé kolokačních datových center nevlastní žádné vybavení – to je ve vlastnictví jejich zákazníků. Inferenční datová centra používají nákladově efektivnější servery než trénovací DC s cenou asi poloviční oproti trénovacím datovým centrům. [5]

Pronájem jednoho GPU Ceny za pronájem GPU se v čase výrazně mění – zatímco před dvěma lety se pohybovaly okolo 7 USD / hodina (NVIDIA H100 80 GB), dnes jsou ceny díky vyšší nabídce nižší. Hyperscale firmy je dnes pronajímají asi za 2,5 USD na hodinu, což odpovídá také českému prostředí. K dubnu 2026 tyto grafické čipy k pronájmu nabízejí 2 společnosti, ZonerCloud (3,77 USD/hod pro NVIDIA H200 NVL 141 GB) a WRDatacentrum (2,12 EUR/hod NVIDIA H100 80 GB).

Cena a energetická náročnost tokenů Pro oba parametry je nutné zvolit jeden výchozí jazykový model, protože cena tokenu se odvíjí od jeho energetické náročnosti. Jegham et al. [1] ve své práci ukazují průměrné energetické nároky třiceti modelů napříč různými délkami vstupu včetně odchylek, které jsou použity pro modelování pesimistického a optimistického scénáře. Do parametrů byl vybrán model GPT-4o mini firmy Open AI, který na 100 vstupních a 300 výstupních tokenů (odpovídá běžné inferenci modelu) spotřebuje 0,577 Wh, průměrně tedy 0,0014 Wh na token. Cena za milion vstupních tokenů je k dubnu 2026 0,15 USD a za milion výstupních 0,60 USD. Pro zjednodušení uvažujeme průměrnou cenu za milion tokenů 0,49 USD (vážený průměr).

■ **Tabulka B.1** Podrobné parametry modelových scénářů

Parametr	Pesimistický	Realistický	Optimistický	Zdroj
Investiční náklady a výstavba				
Náklady na 1 MW příkonu ($I_{\text{build per MW}}$)	148,2 mil. Kč	211,7 mil. Kč	275,2 mil. Kč	[5, 22, 80]
FTE při výstavbě na 1 MW ($FTE_{\text{build per MW}}$)	4,0	5,0	6,0	[36, 41]
Roční prům. mzda výstavba ($W_{\text{avg const}}$)	660 000 Kč	720 000 Kč	780 000 Kč	příloha B
HPH z nákladů na výstavbu ($k_{\text{GVA on I_build}}$)	28 %	30 %	32 %	příloha B
Doba výstavby v letech (τ_{const})	1,5	2,0	3,0	[36, 14, 37, 21, 41]
Provozní parametry a lidské zdroje				
Doba provozu v letech (τ_{ops})	25	30	35	[5]
Doba odpisu budovy (UL_{build})	25	30	35	[5]
Doba odpisu IT vybavení ($UL_{\text{equipment}}$)	3	4	5	[5]
Přímí FTE v provozu na 1 MW ($FTE_{\text{ops per MW}}$)	0,3	0,4	0,5	[36, 41, 40]
Roční prům. mzda v provozu ($W_{\text{avg ops}}$)	780 000 Kč	900 000 Kč	1 080 000 Kč	příloha B
Cena elektřiny za MWh ($Price_{\text{electricity}}$)	1 768 Kč	2 210 Kč	2 652 Kč	[79], příloha B
Ostatní mezispotřeba % z I_{total} (k_{IC})	4,0 %	3,0 %	2,0 %	[37], příloha B
Environmentální faktory a pozemky				
Emise CO_2 (EF)	0,43 t/MWh	0,33 t/MWh	0,23 t/MWh	[57]
Spotřeba vody na 1 MWh (WF)	1 800 l	2 350 l	2 900 l	[31, 26, 21, 22]
Výměra pozemku na 1 MW (A_{land})	2400,0 m^2	2998,00 m^2	3600,0 m^2	sekce 4.1
Poměr zastavěné plochy ($A_{\text{build}} / A_{\text{land}}$)	58,19 %	72,74 %	87,28 %	sekce 4.1
Daně a odvody (společné pro všechny scénáře)				
DPFO (t_{income} / Tax Discount)	15,00 % / 30 840 Kč			3.3.2
Odvody (zaměstnavatel / prac.) ($t_{\text{contributions}}$)	33,80 % / 11,60 %			3.3.2
Sazba ekologické daně (t_{ecology})	28,30 Kč / MWh			3.3.2


Pokračování na další straně...

Tabulka B.1 – pokračování z předchozí strany

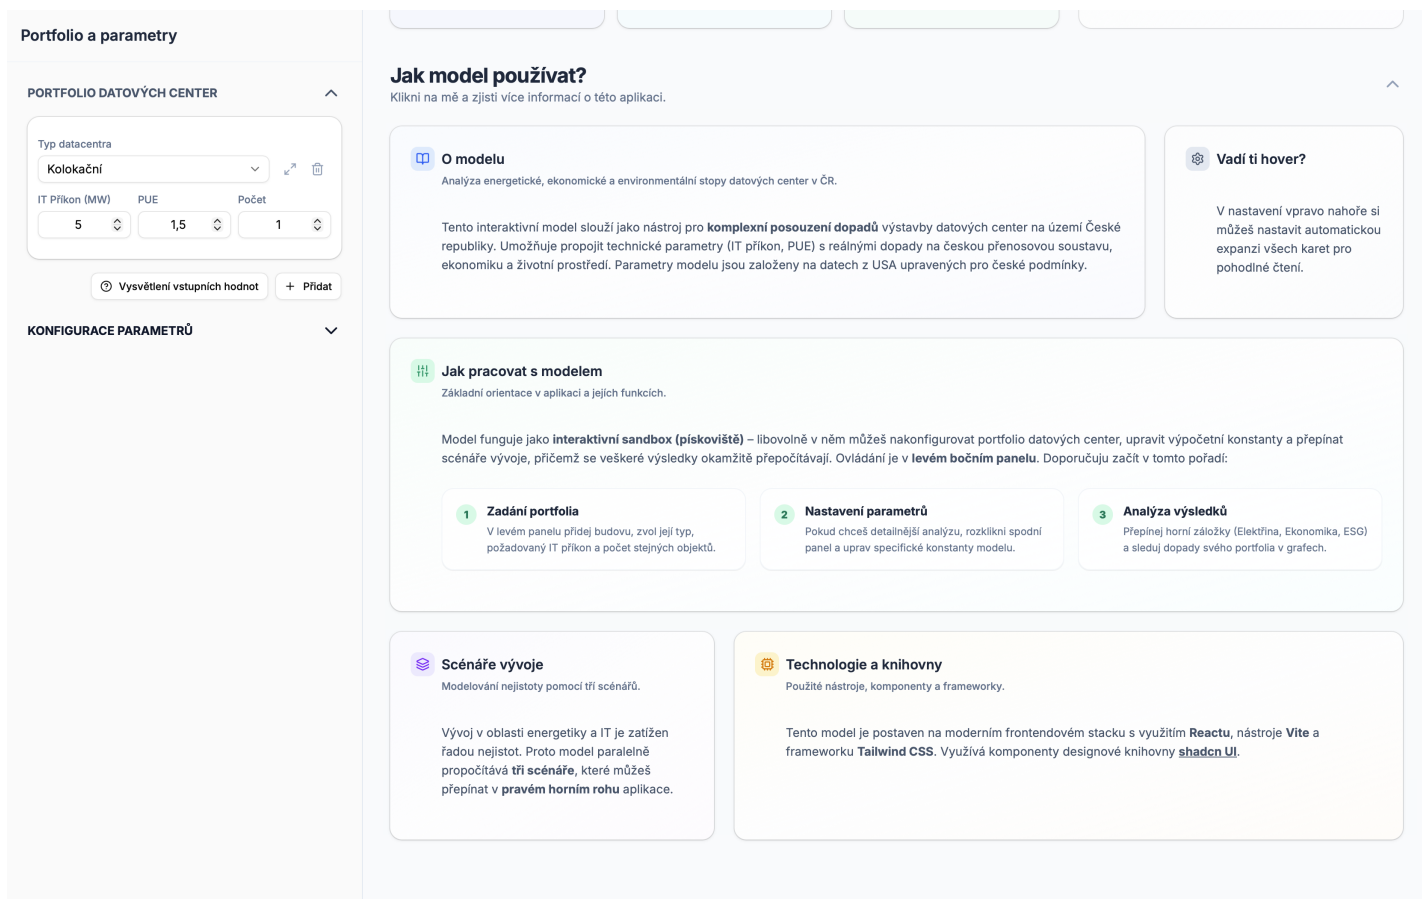
Parametr	Pesimistický	Realistický	Optimistický	Zdroj
Sazby daně z nemovitosti (t_{build} / t_{land})	18 Kč / 9 Kč (na m^2)			3.3.2
Součin koef. daně z nemovitosti (k_{location})	7			příloha B
Koeficient prodaných kapacit ($k_{\text{occupancy}}$)				
Colocation DC	88,0 %	92,6 %	97,2 %	[81], odchylka 5 %
AI trénovací	100,00 %	100,00 %	100,00 %	příloha B
AI inferenční	100,00 %	100,00 %	100,00 %	příloha B
Koeficient spotřeby z prodaných kapacit ($k_{\text{utilization}}$)				
Colocation DC	40,00 %	50,00 %	60,00 %	[82]
AI trénovací	80,00 %	90,00 %	100,00 %	[24, 14, 21, 24]
AI inferenční	40,00 %	50,00 %	60,00 %	[14, 21]
Náklady na pořízení výpočetního vybavení na 1 MW ($I_{\text{equipment}}$ per MW)				
Colocation DC	0,00 Kč	0,00 Kč	0,00 Kč	příloha B
AI trénovací	618,0 mil. Kč	721,0 mil. Kč	824,0 mil. Kč	[5, 31]
AI inferenční	319,0 mil. Kč	360,5 mil. Kč	412,0 mil. Kč	[5], příloha B
Cena za služby jednotlivých typů DC				
Roční pronájem 1 MW kapacity ($\text{Price}_{\text{coloc}}$)	44,49 mil. Kč	48,70 mil. Kč	53,15 mil. Kč	[81]
Roční pronájem GPU ($\text{Price}_{\text{training}}$)	360 921 Kč	541 368 Kč	721 824 Kč	příloha B
Cena za 1 mil. tokenů ($\text{Price}_{\text{token}}$)	10,09 Kč	10,09 Kč	10,09 Kč	příloha B
Specifické parametry jednotlivých typů DC				
Počet GPU na 1 MW kapacity (GPU Count)	800	800	800	1.4.1
Spotřeba na 1 mil. tokenů (E_{token})	1 790,00 Wh	1 442,50 Wh	1 095,00 Wh	[1], GPT-4o mini

Snímky obrazovky průchodu aplikací

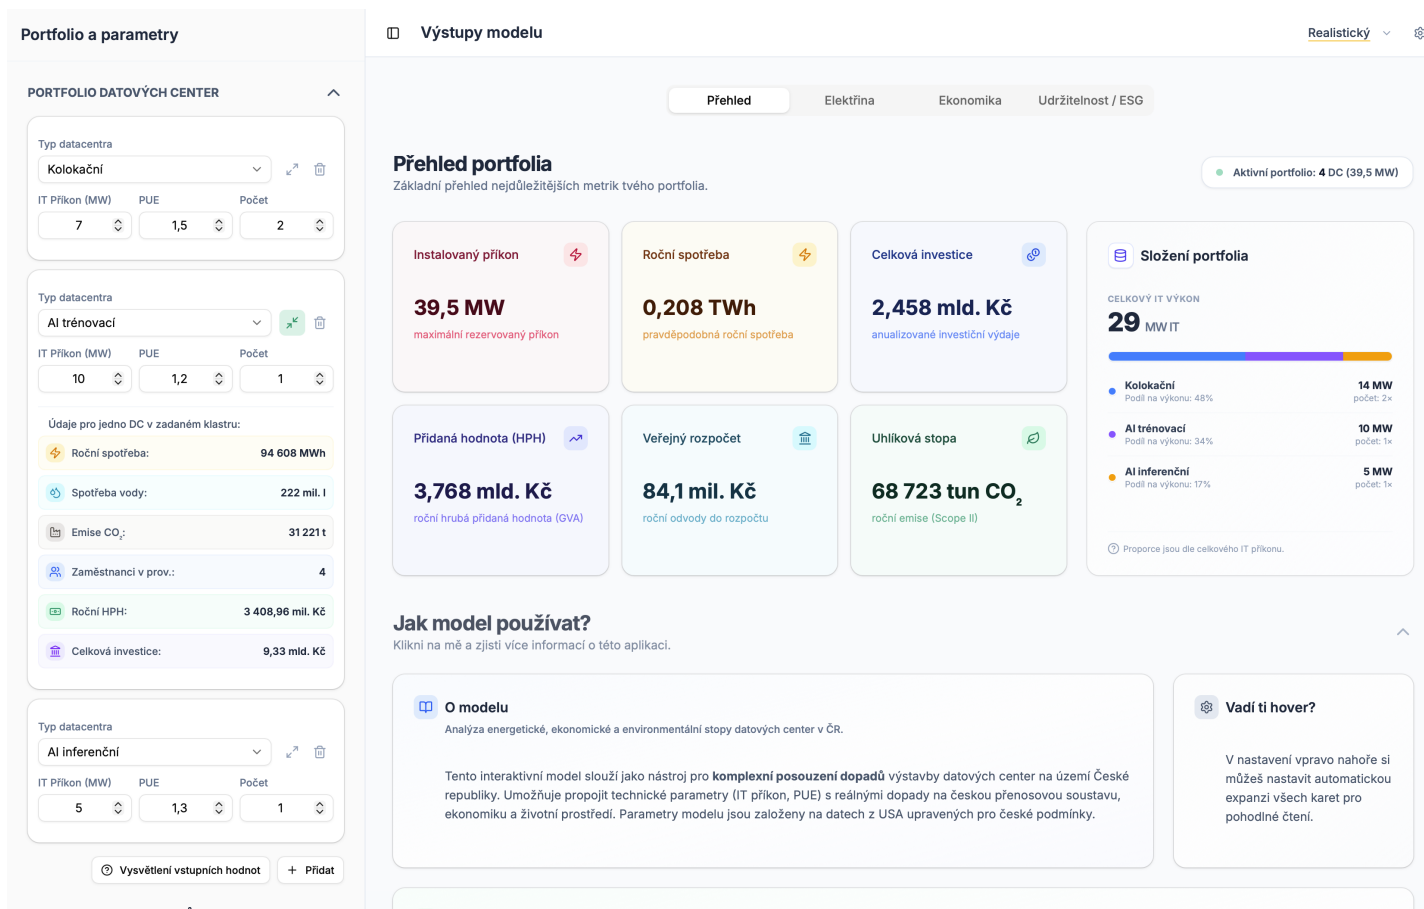
V této příloze jsou uvedeny snímky obrazovky z aplikace, které ilustrují průchod uživatele jednotlivými kroky a zobrazeními. Tyto snímky slouží k lepší představě o tom, jak aplikace vypadá a jak se s ní pracuje, přičemž zachycují klíčové momenty interakce s uživatelským rozhraním. Jednotlivé obrázky jsou umístěny na šířku, aby bylo možné lépe zobrazit všechny detaily a usnadnit orientaci v aplikaci. Jejich popis se nachází v textu kapitoly 5.5.



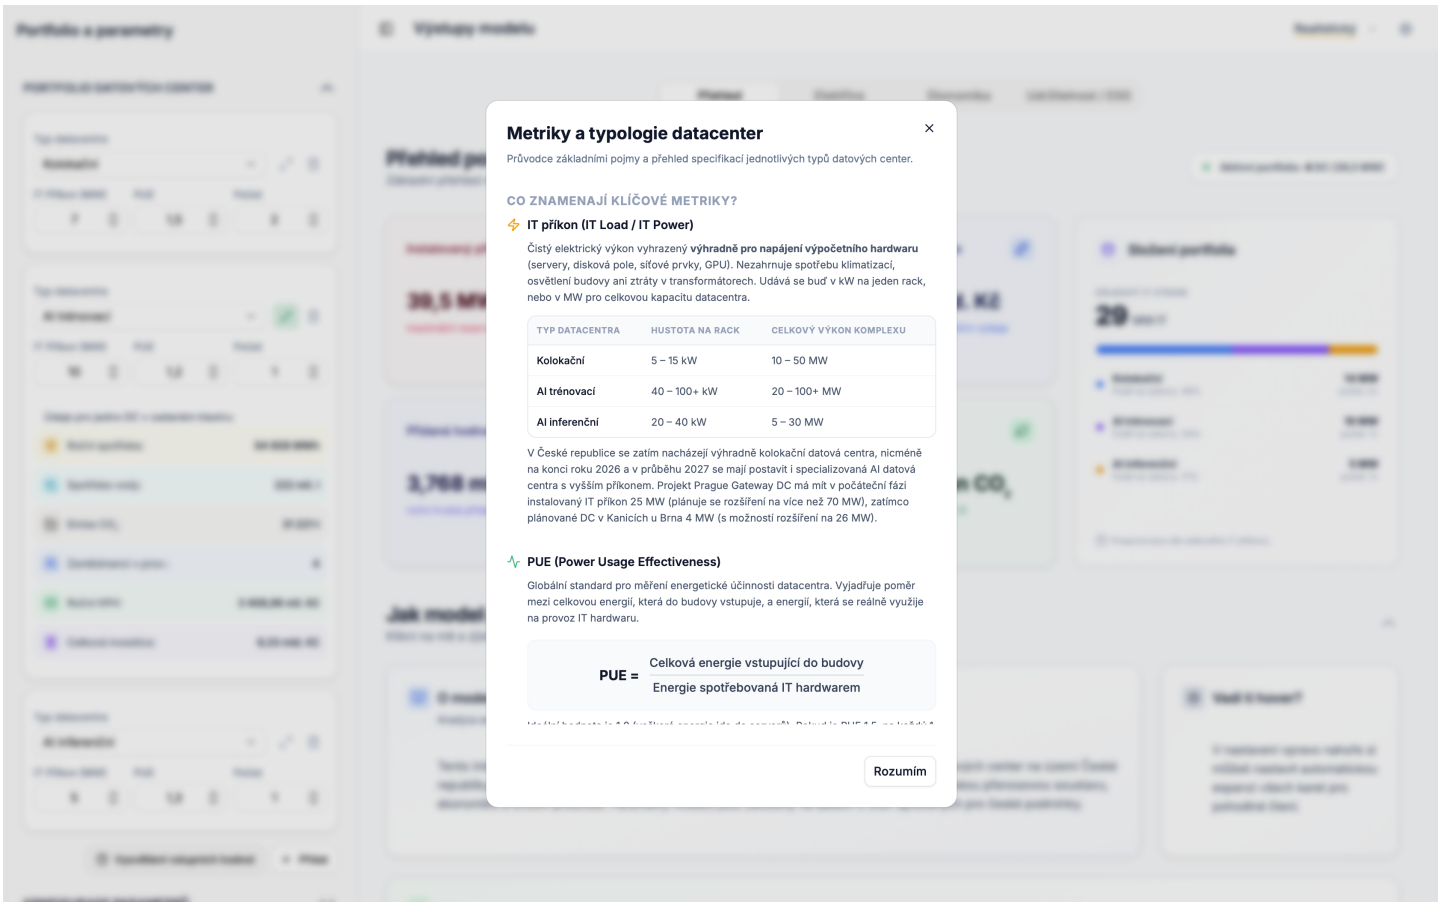
■ **Obrázek C.1** Ukázka prvního pohledu na model po načtení aplikace



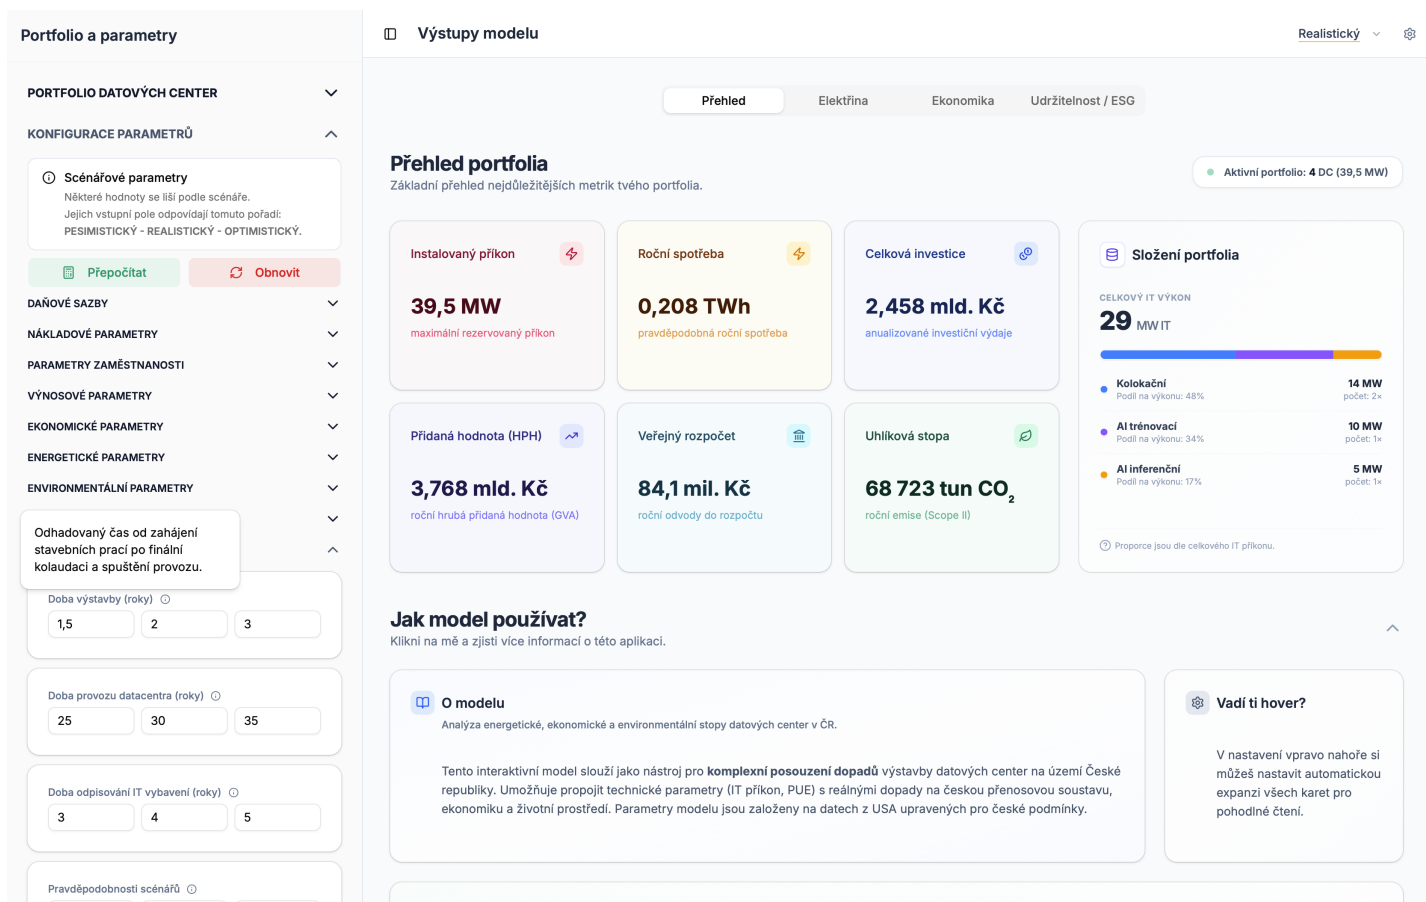
■ Obrázek C.2 Ukázka návodu na použití aplikace



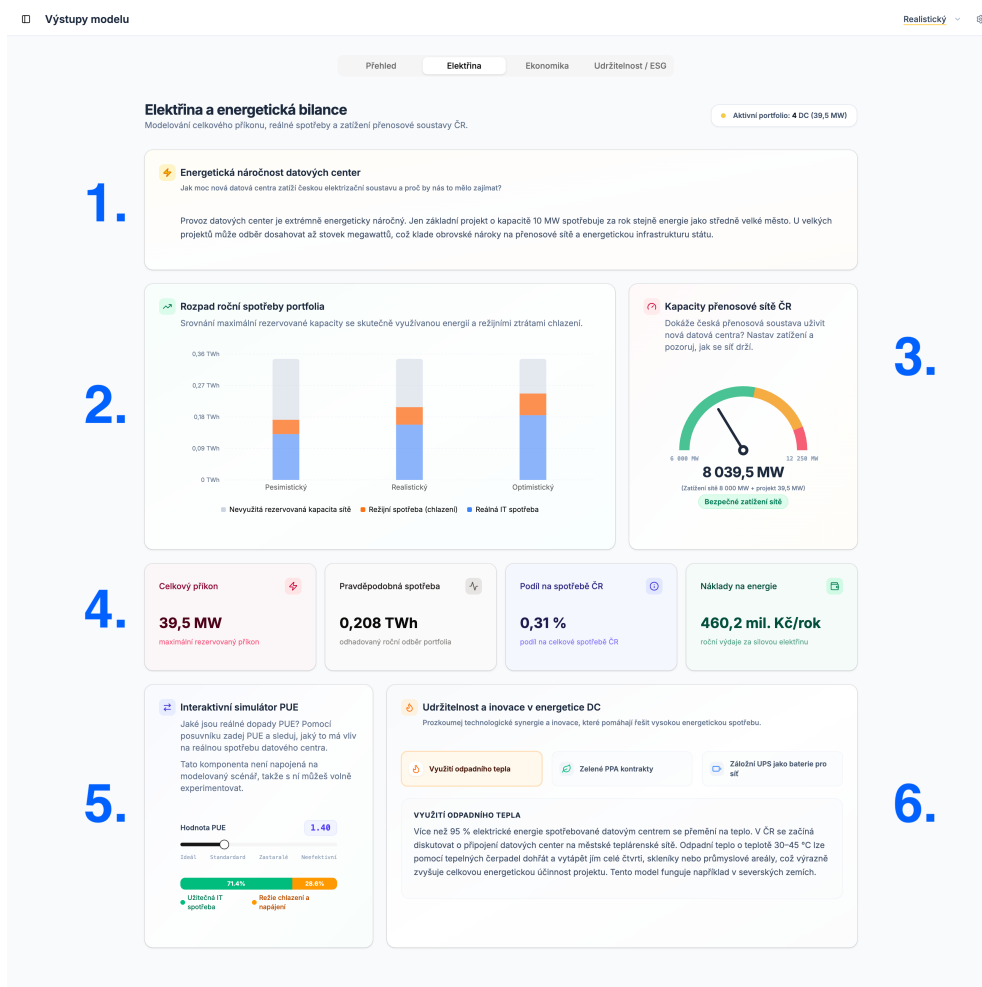
■ **Obrázek C.3** Ukázka stavu aplikace po zadání několika DC



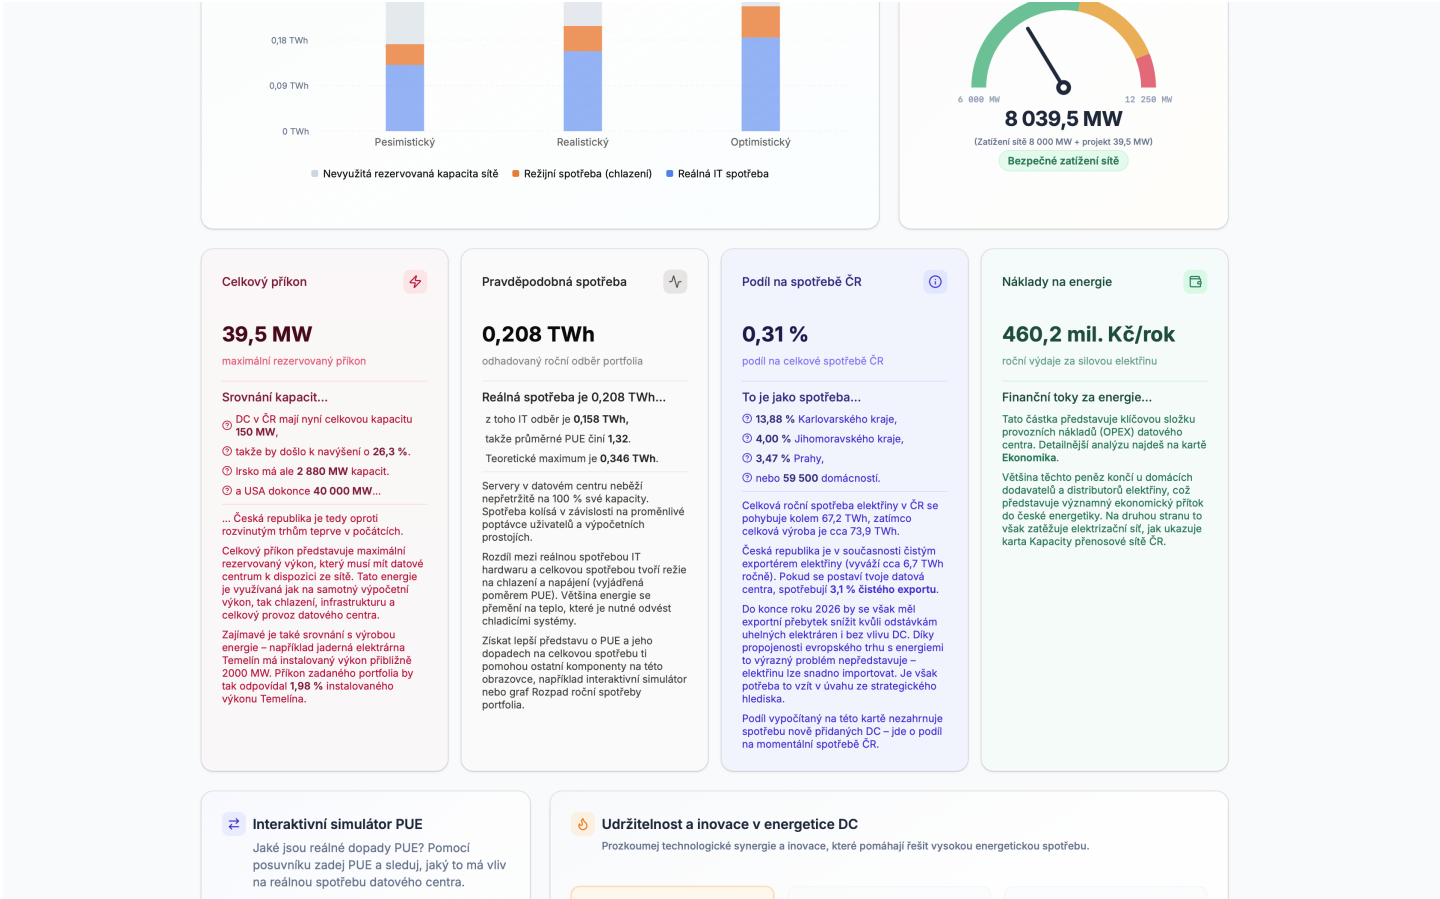
■ **Obrázek C.4** Ukázka návodu na zadání vstupních dat



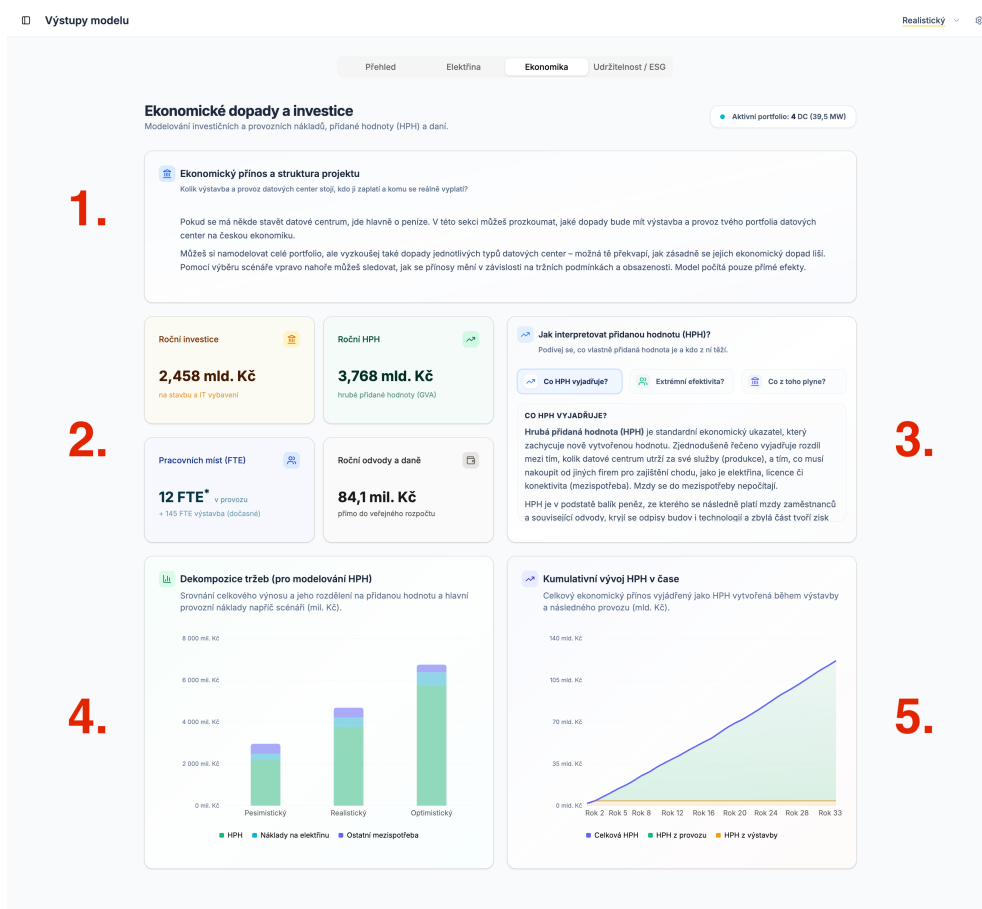
■ Obrázek C.5 Ukázka nastavování parametrů pro jednotlivé scénáře



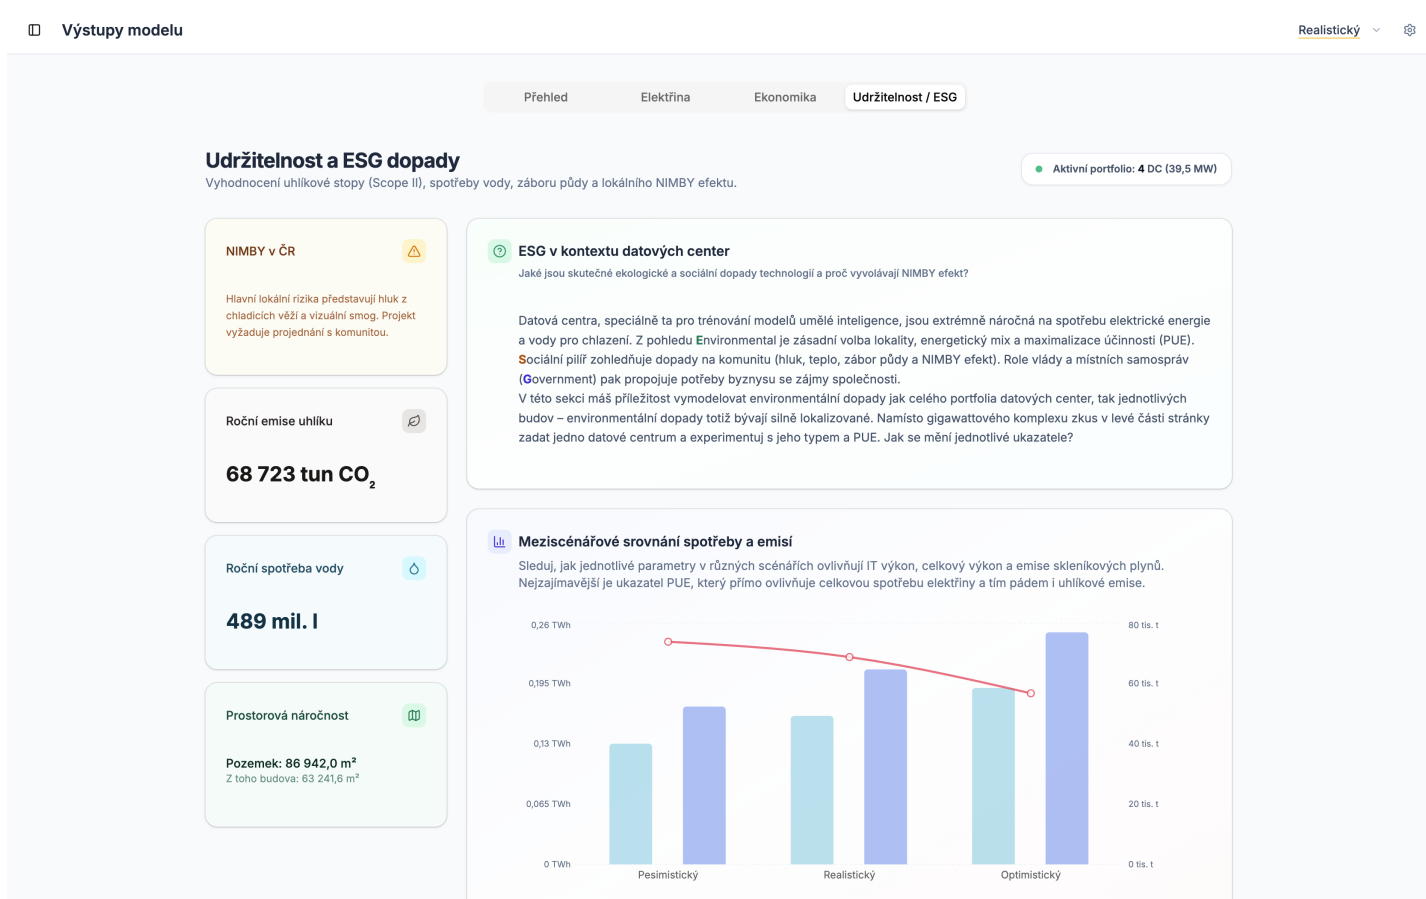
Obrázek C.6 Ukázka zobrazení dopadů zadaných DC na spotřebu elektřiny



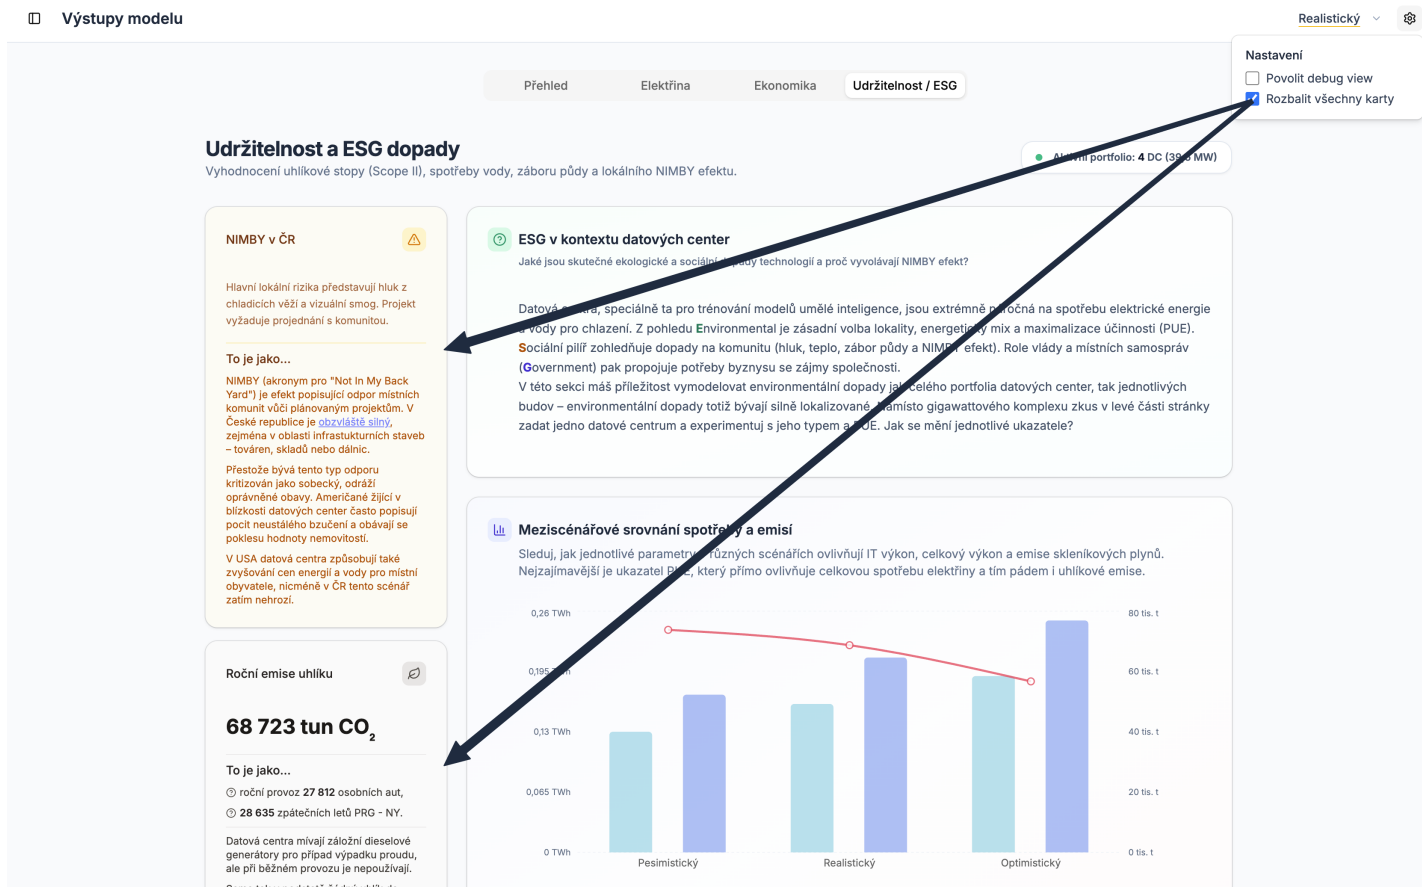
■ Obrázek C.7 Ukázka obsahu KPI karet pro spotřebu elektřiny



Obrázek C.8 Ukázka zobrazení dopadů zadaných DC na ekonomiku



■ Obrázek C.9 Ukázka zobrazení dopadů zadaných DC na okolí



■ Obrázek C.10 Ukázka nastavení zobrazení bez hoveru

Výstupy modelu

Realistický

Nastavení

☒ Povolit debug view

☒ Rozbalit všechny karty

Přehled

Elektrina

Ekonomika

Udržitelnost / ESG

Debug

MODEL PARAMETERS (DEBUG)

SUMMARIZED DATA (DEBUG)

LIVE DATA STORE (DEBUG)

[

{

"id": "c865c3f5-a118-4251-ac37-73e0e814de57",

"type": "coloc",

"itPower": 7,

"pue": 1.5,

"count": 2,

"totalPower": 18.5,

"maxEnergyConsumption": 91988,

"maxITConsumption": 61320,

"PESSIMISTIC": {

"realEnergyConsumption": 32376.960000000003,

"realITConsumption": 21584.640000000003,

"buildingInvestment": 1037400000,

"itEquipmentInvestment": 0,

"totalInvestment": 1037400000,

"electricityCosts": 57242465.28,

"otherOpex": 41496000,

"intermediateConsumption": 98738465.28,

"fteConstruction": 28,

"fteOperations": 3,

"emissionsTonnesCO2": 13922.0928,

"waterConsumptionLiters": 58278528.00000001,

"landUse": 16800,

"buildingArea": 9775.92,

"incomeTaxConstruction": 1908480,

"contributionsConstruction": 8389920,

"incomeTaxOperations": 258480,

"contributionsOperations": 1062360,

"ecologyTax": 916267.9680000001,

"propertyTax": 2290165.92,

"yearlySales": 274858400,

"yearlyOperationsGva": 175319934.72,

"yearlyConstructionGva": 290472000,

"totalPublicIncome": 14825673.888,

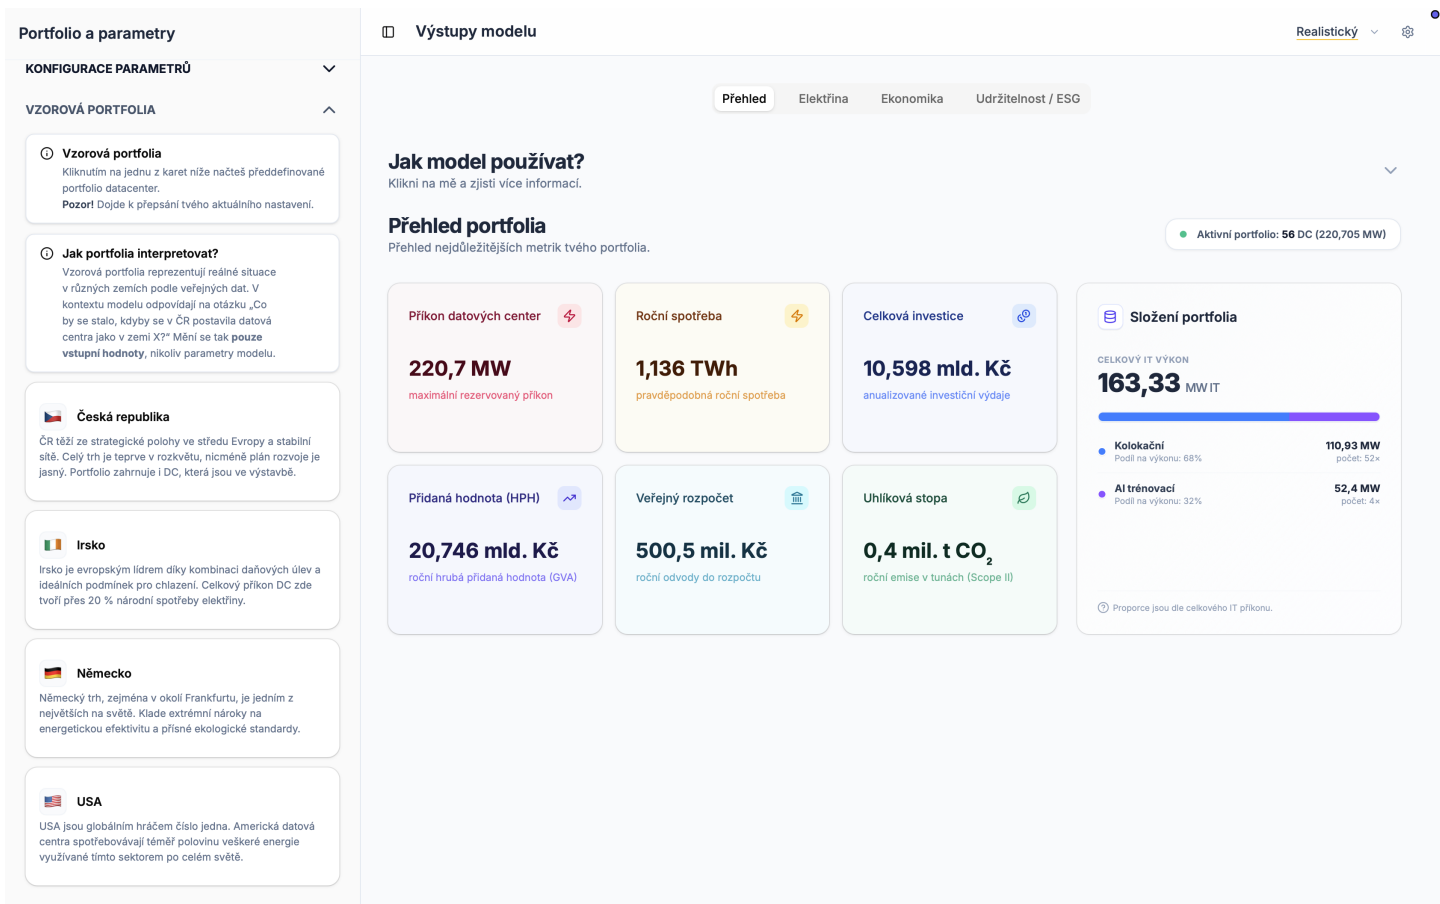
"totalOperationsCapex": 1037400000,

"annualizedCapex": 41496000

},

"REALISTIC": {

■ Obrázek C.11 Ukázka zobrazení pro ladění modelu



■ Obrázek C.12 Ukázka zobrazení pro výběr testovacích portfolií

Bibliografie

1. JEGHAM, Nidhal; ABDELATTI, Marwan; KOH, Chan Young; ELMOU-BARKI, Lassad; HENDAWI, Abdeltawab. *How Hungry is AI? Benchmarking Energy, Water, and Carbon Footprint of LLM Inference* [online]. arXiv, 2025 [cit. 2026-03-07]. Dostupné z DOI: 10.48550/ARXIV.2505.09598. Version Number: 6.
2. LI, Pengfei; YANG, Jianyi; ISLAM, Mohammad A.; REN, Shaolei. *Making AI Less "Thirsty": Uncovering and Addressing the Secret Water Footprint of AI Models* [online]. arXiv, 2025 [cit. 2026-03-05]. Č. arXiv:2304.03271. Dostupné z DOI: 10.48550/arXiv.2304.03271.
3. RANGANATHAN, Parthasarathy; HÖLZLE, Urs. Twenty Five Years of Warehouse-Scale Computing. *IEEE Micro* [online]. 2024, roč. 44, č. 5, s. 11–22 [cit. 2026-03-08]. ISSN 0272-1732, ISSN 1937-4143. Dostupné z DOI: 10.1109/MM.2024.3409469.
4. BIZO, Daniel. *Silicon heatwave: the looming change in data center climates* [online]. New York, 2022-08-01 [cit. 2026-02-13]. UII-74 v1.0M. Uptime Institute. Dostupné z: https://uptimeinstitute.com/uptime_assets/4cf0d2135dc460d5e9d22f028f7236f7b5c3dd2f75672c3d2b8dfd4df3a3eea6-silicon-heatwave-the-looming-change-in-data-center-climates.pdf.
5. BARROSO, Luiz André; RANGANATHAN, Parthasarathy. *The Data Center as a Computer: Designing Warehouse-Scale Machines* [online]. Cham: Springer Nature Switzerland, 2026 [cit. 2026-03-07]. Synthesis Lectures on Computer Architecture. ISBN 978-3-031-99488-3. Dostupné z DOI: 10.1007/978-3-031-99489-0.
6. BARROSO, Luiz Andre. A Brief History of Warehouse-Scale Computing. *IEEE Micro* [online]. 2021, roč. 41, č. 2, s. 78–83 [cit. 2026-03-11]. ISSN 0272-1732, ISSN 1937-4143. Dostupné z DOI: 10.1109/MM.2021.3055379.

7. TATNALL, Arthur (ed.). *Reflections on the History of Computing*. Sv. 387 [online]. Berlin: Springer Berlin Heidelberg, 2012 [cit. 2026-03-05]. IFIP Advances in Information and Communication Technology. ISBN 978-3-642-33898-4. Dostupné z DOI: 10.1007/978-3-642-33899-1.
8. FADAEEFATH ABADI, Mostafa; HAGHIGHAT, Fariborz; NASIRI, Fuzhan. Data center maintenance: applications and future research directions. *Facilities* [online]. 2020, vol. 38, no. 9, s. 691–714 [cit. 2026-03-09]. ISSN 0263-2772, ISSN 0263-2772. Dostupné z DOI: 10.1108/F-09-2019-0104.
9. TURNER IV, WP; PE, JH; SEADER, PE; BRILL, KJ. *Tier classification define site infrastructure performance* [online]. New Mexico, USA, 2008 [cit. 2026-03-13]. Uptime Institute. Dostupné z: <https://fsta.dk/wp-content/uploads/2023/07/Tier-Classifications-Define-Site-Infrastructure-Performance.pdf>.
10. LEWIS, Grace. *Basics About Cloud Computing* [online]. Pittsburgh, 2010-09 [cit. 2026-04-26]. Software Engineering Institute. Dostupné z: https://www.sei.cmu.edu/documents/101/2010_019_001_28877.pdf.
11. CAREY, Cathleen; RAISINGHANI, Mahesh S.; WHITE, Becky. Foundations of Data Center: Key Concepts and Taxonomies. In: MARX GÓMEZ, Jorge; MORA, Manuel; RAISINGHANI, Mahesh S.; NEBEL, Wolfgang; O'CONNOR, Rory V. (eds.). *Engineering and Management of Data Centers* [online]. Cham: Springer International Publishing, 2017, s. 1–13 [cit. 2026-03-09]. ISBN 978-3-319-65081-4. Dostupné z DOI: 10.1007/978-3-319-65082-1_1. Series Title: Service Science: Research and Innovations in the Service Economy.
12. NVIDIA. *What is an AI Factory?* [online]. 2026. [cit. 2026-03-13]. Dostupné z: <https://www.nvidia.com/en-us/glossary/ai-factory/>.
13. CRUZES, Sergio. *DATA CENTERS IN THE AGE OF AI: A TUTORIAL SURVEY ON INFRASTRUCTURE, SUSTAINABILITY, AND EMERGING CHALLENGES* [online]. Preprints, 2025 [cit. 2026-03-07]. Dostupné z DOI: 10.36227/techrxiv.176158592.23065552/v1.
14. GINZBURG-GANZ, Elinor; LIFSHITS, Pavel; MACHLEV, Ram; BELIKOV, Juri; KRIEGER, Ziv; LEVRON, Yoash. Technical Challenges of AI Data Center Integration into Power Grids—A Survey. *Energies* [online]. 2025, vol. 19, no. 1, s. 137 [cit. 2026-03-07]. ISSN 1996-1073. Dostupné z DOI: 10.3390/en19010137.
15. KANT, Krishna. Data center evolution. *Computer Networks* [online]. 2009, vol. 53, no. 17, s. 2939–2965 [cit. 2026-03-05]. ISSN 13891286. Dostupné z DOI: 10.1016/j.comnet.2009.10.004.

16. HU, Pearl; ZHOU, Wei. *How to Choose an IT Rack* [online]. Schneider Electric, 2020 [cit. 2026-03-06]. Dostupné z: <https://netsystemvn.com/uploaded/files/cach-chon-tu-rack-apc.pdf>.
17. AVELAR, Victor; DONOVAN, Patrick; LIN, Paul; TORELL, Wendy; ARANGO, Maria A Torres. *The AI Disruption: Challenges and Guidance for Data Center Design* [online]. 2023. [cit. 2026-04-24]. 110. SCHNEIDER ELECTRIC: Energy Management Research Center. Dostupné z: https://media.datacenterdynamics.com/media/documents/Schneider_Electric_-_Modernization_WP110_V1.1_EN.pdf.
18. PALADUGU, Phani Suresh. *The Evolution of Data Centers and Cloud AI Infrastructure* [online]. 2025 [cit. 2026-03-09]. ISSN 2945-3585. Dostupné z DOI: 10.5281/ZENODO.16570544.
19. GENG, Hwaiyu. *Data Center Handbook* [online]. 1st ed. Wiley, 2014 [cit. 2026-03-09]. ISBN 978-1-118-43663-9. Dostupné z DOI: 10.1002/9781118937563.
20. BUTLER, Christopher; CAMPBELL, Rob. *Unlocking data center growth through the convergence of power and compute* [online]. 2025-07-15. [cit. 2025-03-14]. Dostupné z: <https://flex.com/resources/unlocking-data-center-growth-through-the-convergence-of-power-and-compute>.
21. SHENG, Yu; ZHANG, Chenxuan; ZHU, Zixuan; XU, Hongyi; WEN, Junqi; WANG, Ruoheng; YANG, Jianjun; WANG, Qin; BU, Siqi. *Power for AI Data Centers: Energy Demand, Grid Impacts, Challenges and Perspectives*. *Energies* [online]. 2026, vol. 19, no. 3, s. 722 [cit. 2026-03-07]. ISSN 1996-1073. Dostupné z DOI: 10.3390/en19030722.
22. INTERNATIONAL ENERGY AGENCY [IEA]. *Energy and AI* [online]. Paříž, 2025-04-10 [cit. 2026-03-31]. Dostupné z: <https://www.iea.org/reports/energy-and-ai>.
23. CHEN, Xin; WANG, Xiaoyang; COLACELLI, Ana; LEE, Matt; XIE, Le. *Electricity Demand and Grid Impacts of AI Data Centers: Challenges and Prospects* [online]. arXiv, 2025 [cit. 2026-03-07]. Dostupné z DOI: 10.48550/ARXIV.2509.07218. Version Number: 4.
24. SHEHABI, A.; SMITH, S. J.; HUBBARD, A.; NEWKIRK, A. *2024 United States Data Center Energy Usage Report*. Berkeley, California, 2024. Lawrence Berkeley National Laboratory. Dostupné také z: <https://eta-publications.lbl.gov/sites/default/files/2024-12/lbnl-2024-united-states-data-center-energy-usage-report.pdf>.
25. ENERGETICKÝ REGULAČNÍ ÚŘAD. *Spotřeba elektřiny v krajích dle sektorů* [online]. 2024. [cit. 2026-03-18]. Dostupné z: <https://www.enviro.cz/data/spotreba-elektriny-v-krajich-dle-sektoru>.

26. DE ROUCY-ROCHEGONDE, Laure; BUFFARD, Adrien. *AI, Data Centers and Energy Demand: Reassessing and Exploring the Trends* [online]. 2025-02-24. [cit. 2026-04-26]. IFRI. ISBN 979-10-373-1000-2. Dostupné z: <https://www.ifri.org/en/papers/ai-data-centers-and-energy-demand-reassessing-and-exploring-trends-0>.
27. MAHAJAN, R.; CHIA-PIN CHIU; CHRYSLER, G. Cooling a Micro-processor Chip. *Proceedings of the IEEE* [online]. 2006, roč. 94, č. 8, s. 1476–1486 [cit. 2026-03-13]. ISSN 0018-9219, ISSN 1558-2256. Dostupné z DOI: 10.1109/JPROC.2006.879800.
28. GIGABYTE. *TDP* [About TDP] [online]. 2026. [cit. 2026-03-13]. Dostupné z: <https://www.gigabyte.com/Glossary/tdp>.
29. NVIDIA. *NVIDIA Blackwell Ultra* [online]. 2025. [cit. 2026-03-13]. Dostupné z: <https://resources.nvidia.com/en-us-blackwell-architecture/blackwell-ultra-datasheet>.
30. NVIDIA. *NVIDIA Blackwell Architecture Technical Brief* [online]. 2025. [cit. 2026-03-13]. Dostupné z: <https://resources.nvidia.com/en-us-blackwell-architecture>.
31. PILZ, Konstantin; HEIM, Lennart. *Compute at Scale: A Broad Investigation into the Data Center Industry* [online]. arXiv, 2023 [cit. 2026-03-07]. Dostupné z DOI: 10.48550/ARXIV.2311.02651. Version Number: 4.
32. GREEN, Ben; NGUYEN, Terry. *What Happens When Data Centers Come to Town?* [online]. 2025-07-15. [cit. 2026-03-29]. University of Michigan. Dostupné z DOI: 10.7302/26670.
33. GARGANO, Antonio; GIACOLETTI, Marco. *Subsidizing the Cloud: U.S. State Incentives to Data Centers* [online]. SSRN, 2025 [cit. 2026-03-24]. Dostupné z DOI: 10.2139/ssrn.5881105.
34. SHAH, Sameer H. Four water insecurity concerns about datacenters driving the AI revolution. *PLOS Water* [online]. 2026, vol. 5, no. 1, e0000500 [cit. 2026-03-07]. ISSN 2767-3219. Dostupné z DOI: 10.1371/journal.pwat.0000500.
35. LIN, Liuzixuan; WIJAYAWARDANA, Rajini; RAO, Varsha; NGUYEN, Hai; GNIBGA, Emmanuel Wedan; CHIEN, Andrew A. Exploding AI Power Use: an Opportunity to Rethink Grid Planning and Management. In: *Proceedings of the 15th ACM International Conference on Future and Sustainable Energy Systems*. New York, NY, USA: Association for Computing Machinery, 2024, s. 434–441. e-Energy '24. ISBN 979-8-4007-0480-2. Dostupné z DOI: 10.1145/3632775.3661959.

36. TO, Thi Serena; TOMBE, Trevor (vedoucí). *Alberta's AI Data Center Opportunity: Economic Impacts and Investment Strategy*. Calgary, Kanada, 2025. Dostupné také z: <https://ucalgary.scholaris.ca/server/api/core/bitstreams/231c2d25-8530-4399-947b-93adf7ecbcbc/content>. Dis. pr. University of Calgary.
37. PHAM, Nam. Data Centers: Jobs and Opportunities in Communities Nationwide. *SSRN Electronic Journal* [online]. 2017 [cit. 2026-03-24]. ISSN 1556-5068. Dostupné z DOI: 10.2139/ssrn.2998644.
38. PRATIKKUMAR DILIPKUMAR PATEL. Artificial Intelligence in Datacenters: Optimizing Performance, Power, and Thermal Management. *Journal of Computer Science and Technology Studies* [online]. 2025, roč. 7, č. 4, s. 952–963 [cit. 2026-03-25]. ISSN 2709-104X. Dostupné z DOI: 10.32996/jcsts.2025.7.4.109.
39. JOHNSON ECONOMICS. *Economic Impact Analysis of Prospective Exascale Data Center Development in Morrow County, Oregon* [online]. Morrow County, Oregon, USA, 2025-01 [cit. 2026-03-16]. Report. Johnson Economics. Dostupné z: https://www.morrowcountyor.gov/sites/default/files/fileattachments/planning_commission/page/16917/exhibit_08_-_economic_impact_analysis.pdf.
40. DIAO, Clyde; PARKER, Jared. *Economic Benefits of Data Centers* [online]. USA, 2025-08 [cit. 2026-03-16]. Report. Regional Economic Consulting Group. Dostupné z: <https://consumerenergyalliance.org/cms/wp-content/uploads/2025/12/Economic-Impact-of-Data-Centers.pdf>.
41. LEE, Vivian; SESHADRI, Pattabi; O'NIELL, Clark; CHOUDHARY, Archit; HOLSTEGE, Braden; DEUTSCHER, Stefan A. *Breaking Barriers to Data Center Growth*. BCG, 2025. Dostupné také z: <https://web-assets.bcg.com/pdf-src/prod-live/breaking-barriers-data-center-growth.pdf>. Published: BCG (Boston Consulting Group).
42. KSHETRI, Nir; VOAS, Jeffrey. Data Centers in Your Backyard? *Computer* [online]. 2024, roč. 57, č. 1, s. 82–87 [cit. 2026-03-24]. ISSN 0018-9162, ISSN 1558-0814. Dostupné z DOI: 10.1109/MC.2023.3319882.
43. NGATA, Wacuka M; BASHIR, Noman; WESTERLAKEN, Michelle; LIOTE, Laurent; CHANDIO, Yasra; OLIVETTI, Elsa. The Cloud Next Door: Investigating the Environmental and Socioeconomic Strain of Datacenters on Local Communities. In: *Proceedings of the ACM SIGCAS/SIGCHI Conference on Computing and Sustainable Societies* [online]. Toronto ON Canada: ACM, 2025, s. 769–774 [cit. 2026-03-24]. ISBN 979-8-4007-1484-9. Dostupné z DOI: 10.1145/3715335.3736324.

44. DAVENPORT, Carly; SINGER, Brian; MEHTA, Neil; LEE, Brian; MAC-KAY, John; MODAK, Ati; CORBETT, B; MILLER, J; HARI, T; RITCHIE, J et al. *AI, data centers and the coming US power demand surge* [online]. 2024-04-28. [cit. 2024-04-26]. Equity Research. Goldman Sachs. Dostupné z: <https://www.goldmansachs.com/pdfs/insights/pages/generational-growth-ai-data-centers-and-the-coming-us-power-surge/report.pdf>.
45. DATA CENTER MAP. *Number of data centers in Central and Eastern Europe in 2025, by country* [online]. Statista, 2025 [cit. 2026-04-24]. Dostupné z: <https://www.statista.com/statistics/1429579/cee-number-of-data-centers-by-country/>.
46. DATA CENTER MAP. *Czech Republic Data Centers* [online]. 2026. [cit. 2026-04-24]. Dostupné z: <https://www.datacentermap.com/czech-republic/>.
47. MORDOR INTELLIGENCE. *Czechia Data Center Market Size, Share & 2030 Trends Report — mordorintelligence.com* [online]. Indie, 2025-09-01 [cit. 2026-04-26]. Dostupné z: <https://www.mordorintelligence.com/industry-reports/czechia-data-center-market>.
48. CRA. *České Radiokomunikace začaly stavět Prague Gateway DC, největší datové centrum v regionu* [online]. Praha: Ministerstvo průmyslu a obchodu, 2025 [cit. 2026-03-07]. Dostupné z: <https://mpo.gov.cz/cz/rozcestnik/pro-media/tiskove-zpravy/ceske-radiokomunikace-zacaly-stavet-prague-gateway-dc---nejvetsi-datove-centrum-v-regionu---289344>.
49. PROCHÁZKA, Martin. *Šéf Českých Radiokomunikací: Zájem o AI data-centra je obří, otevřeme největší v Česku* [online]. Novinky.cz, 2026-03-27 [cit. 2026-04-24]. Dostupné z: <https://www.novinky.cz/clanek/ekonomika-sef-ceskych-radiokomunikaci-zajem-o-ai-datacentra-je-obri-otevreme-nejvetsi-v-cesku-40569400>.
50. RICHTER, Jan. *Gigatovárna na umělou inteligenci za 90 miliard může stát u Prahy* [online]. Seznam Zprávy, 2025-06-20 [cit. 2026-04-24]. Dostupné z: <https://www.seznamzpravy.cz/clanek/ekonomika-firmy-gigatovarna-na-umelou-inteligenci-za-90-miliard-ma-stat-u-prahy-279747>.
51. RABASOVÁ, Michaela. *U Brna vznikne první AI datové centrum. MasterDC jej postaví do roka* [online]. MasterDC, 2025 [cit. 2026-03-07]. Dostupné z: <https://www.master.cz/blog/u-brna-vznikne-prvni-a-i-datove-centrum-masterdc-jej-postavi-do-roka/>.
52. CENTRAL STATISTICS OFFICE IRELAND. *Share of total electricity consumption in Ireland used by data centers from 2015 to 2023* [online]. Statista, 2024 [cit. 2026-04-25]. Dostupné z: <https://www.statista.com>

- /statistics/1551302/data-center-share-of-electricity-consumption-ireland/.
53. BARTOŠ, Jan; BARTUŠKA, Václav; BERKA, Jan; BOŘEK, JAROSLAV. *Energetika v době transformace*. Sv. 1 [online]. Praha: ČEPS, a.s., 2025 [cit. 2026-03-31]. ISBN 978-80-11-07306-0. Dostupné z: <https://www.ceps.cz/cs/publikace-ke-stazeni-verejnost>.
 54. VLČEK, Tomáš; ČERNOCH, Filip. *Energetický sektor České republiky* [online]. 1. vyd. Brno: Masarykova univerzita, 2012 [cit. 2026-03-31]. ISBN 978-80-210-5982-5. Dostupné z: <https://munispace.muni.cz/library/catalog/view/812/2583/473-1/#preview>.
 55. KLÍMOVÁ, Hana. *Grid Speciál* [online]. Praha: ČEPS, a. s., 2025 [cit. 2026-03-31]. Dostupné z: <https://www.ceps.cz/cs/publikace-ke-stazeni-verejnost>.
 56. ENERGETICKÝ REGULAČNÍ ÚŘAD. *Roční zpráva o provozu elektrizační soustavy České republiky 2024* [online]. Česká republika: Energetický regulační úřad, 2025 [cit. 2026-04-25]. Dostupné z: <https://eru.gov.cz/rocnizprava-o-provozu-elektrizacni-soustavy-cr-pro-rok-2024>.
 57. BUFKA, Aleš; DAŇHELKA, Michal; VOZKA, Petr. *Hodnota emisního faktoru CO₂ z výroby a spotřeby elektřiny v roce 2025*. Praha, 2026-04. Ministerstvo průmyslu a obchodu [Oddělení analýz a datové podpory koncepcí]. Dostupné také z: [https://mpo.gov.cz/assets/cz/energetika/statistika/elektrina-a-teplo/2026/4/Metodika-emisni-faktor-CO₂_elektrina_2025.pdf](https://mpo.gov.cz/assets/cz/energetika/statistika/elektrina-a-teplo/2026/4/Metodika-emisni-faktor-CO2_elektrina_2025.pdf).
 58. CHLUBNÁ, Tereza. *Vypnutí tří uhelných elektráren Česko ustojí. Nehrozí zdražení elektřiny ani blackoutu, ujistují odborníci* [online]. Praha: Český rozhlas, 2025-11-26 [cit. 2026-04-25]. Dostupné z: https://www.irozhlas.cz/zpravy-domov/vypnuti-tri-uhelnych-elektraren-cesko-ustoji-nehrozi-zdrazeni-elektřiny-ani_2511261418_mst.
 59. HORNÍČEK, Roman; RACLAUSKÝ, Jaroslav. Water Supply in the Czech Republic: Review of Infrastructure Risks and Comparison with Worldwide Practices. *Water* [online]. 2026, vol. 18, no. 4, s. 512 [cit. 2026-04-25]. ISSN 2073-4441. Dostupné z DOI: 10.3390/w18040512.
 60. MÜLLEROVÁ, Hana; SNOPKOVÁ, Tereza; ZICHA, Jiří. Water policy and legislative responses to climate change in the Czech Republic. *International Journal of Water Resources Development* [online]. 2024, vol. 40, no. 2, s. 268–283 [cit. 2026-04-25]. ISSN 0790-0627, ISSN 1360-0648. Dostupné z DOI: 10.1080/07900627.2023.2238085.
 61. HEJDUKOVÁ, Pavlína; KUREKOVÁ, Lucie. Water scarcity: regional analyses in the Czech Republic from 2014 to 2018. *Oeconomia Copernicana* [online]. 2020, roč. 11, č. 1, s. 161–181 [cit. 2026-04-25]. ISSN 2353-1827, ISSN 2083-1277. Dostupné z DOI: 10.24136/oc.2020.007.

62. MINISTERSTVO PRŮMYSLU A OBCHODU. *Národní strategie umělé inteligence České republiky 2030* [online]. Praha: Ministerstvo průmyslu a obchodu, 2024 [cit. 2026-04-25]. Dostupné z: <https://mpo.gov.cz/assets/cz/podnikani/2024/9/Narodni-strategie-umele-intelligence-CR-2030.pdf>.
63. EUROPEAN COMMISSION. *AI Continent Action Plan* [online]. Brussels, 2025 [cit. 2026-04-25]. Dostupné z: <https://digital-strategy.ec.europa.eu/en/library/ai-continent-action-plan>.
64. HORÁČKOVÁ, Soňa. *Vodní hospodářství v Česku* [Statistika & My] [online]. Český statistický úřad, 2026-02-23 [cit. 2026-05-05]. Dostupné z: <https://statistikaamy.csu.gov.cz/vodni-hospodarstvi-v-cesku>.
65. ČESKÝ STATISTICKÝ ÚŘAD. *Zaměstnanci a mzdy / Statistika — csu.gov.cz*. Praha: Český statistický úřad, 2026. Dostupné také z: https://csu.gov.cz/zamestnanci-a-mzdy?pocet=10&start=0&1_pocet=10&1_start=0&1_skupiny=11&1_vlastnostiVystupu=12&1_razeni=-datumVydani&skupiny=11&vlastnostiVystupu=15&pouzeVydane=true&razeni=-datumVydani.
66. OECD. *OECD Glossary of Statistical Terms* [online]. OECD, 2008 [cit. 2026-05-08]. ISBN 978-92-64-05508-7. Dostupné z DOI: 10.1787/9789264055087-en.
67. ČESKÝ STATISTICKÝ ÚŘAD. *Makroekonomická dvojčata / Statistika a My — statistikaamy.csu.gov.cz*. 2024. Dostupné také z: <https://statistikaamy.csu.gov.cz/o-slozitem-jednoduse-makroekonomicka-dvojcata-2>.
68. ČESKÝ STATISTICKÝ ÚŘAD. *TB0001P2a Mezišpotřeba (běžné ceny)* [online]. <https://apl.czso.cz/pll/rocenka/rocenkavyber.socas>: Časové řady ukazatelů účtů výroby a tvorby důchodů, 2026 [cit. 2026-05-09].
69. ČESKÝ STATISTICKÝ ÚŘAD. *TB0001P1a Produkce (běžné ceny)* [online]. <https://apl.czso.cz/pll/rocenka/rocenkavyber.socas>: Časové řady ukazatelů účtů výroby a tvorby důchodů, 2026 [cit. 2026-05-09].
70. KING, William; STEVENSON BROWN, Juliet. *Market Spotlight: Dublin* [online]. London, 2023-11-16 [cit. 2026-05-31]. Market Spotlight. DC Byte. Dostupné z: https://www.dcbyte.com/wp-content/uploads/2023/11/DC-BYTE_MARKET-SPOTLIGHT_DUBLIN_Final_16Nov23.pdf.
71. BITPOWER. *Ireland Q4 2024 Market Update: Insights into the scale of Ireland's digital infrastructure* [online]. 2024-10. [cit. 2026-05-31]. Market Update Report. Bitpower. Dostupné z: https://bitpower.ie/images/Reports/2024_Q4_Market_Update_Ireland_v1-2.pdf.
72. SEAI. *Conversion Factors* [online]. Sustainable Energy Authority of Ireland, 2025 [cit. 2026-05-31]. Dostupné z: <https://www.seai.ie/data-and-insights/seai-statistics/conversion-factors>.

73. SOUTH DUBLIN COUNTY COUNCIL. *Chief Executive's Reply to Question: Data Centre Development Impact* [online]. South Dublin County Council, 2022 [cit. 2026-05-31]. Dostupné z: <https://meetings.southdublin.ie/Home/ViewReply/75396>. Published: Official Council Meeting Reply.
74. MCGRATH, Triona. *Data Centre Water Use in Ireland* [online]. 2024-10. [cit. 2026-05-31]. Policy Brief. An Fóram Uisce / The Water Forum. Dostupné z: <https://thewaterforum.ie/app/uploads/2024/10/McGrath-2024-Data-Centre-Water-Use-in-Ireland-.pdf>.
75. LOHRMANN, Alena; CHILD, Michael; BREYER, Christian. Assessment of the water footprint for the European power sector during the transition towards a 100% renewable energy system. *Energy* [online]. 2021, vol. 233, s. 121098 [cit. 2026-05-31]. ISSN 03605442. Dostupné z DOI: 10.1016/j.energy.2021.121098.
76. MORDOR INTELLIGENCE. *Germany Data Center Market Size & Share Analysis - Growth Trends & Forecasts (2024 - 2029)* [online]. Mordor Intelligence, 2026-05-01 [cit. 2026-05-31]. Dostupné z: <https://www.mordorintelligence.com/industry-reports/germany-data-center-market>.
77. FEDERAL MINISTRY FOR ECONOMIC AFFAIRS AND CLIMATE ACTION. *Status and Development of the German Data Centre Landscape: Executive Summary* [online]. Berlin, 2025-03 [cit. 2026-05-31]. Research Report Summary. Federal Ministry for Economic Affairs a Climate Action (BMWK). Dostupné z: https://www.bundeswirtschaftsministerium.de/Redaktion/EN/Publikationen/Digitale-Welt/status-and-development-of-the-german-data-centre-landscape-executive-summary.pdf?__blob=publicationFile&v=2.
78. GERMANY TRADE & INVEST. *Data Centers in Germany: Europe's Premier Data Hub* [online]. Germany Trade & Invest, 2026 [cit. 2026-05-31]. Dostupné z: <https://www.gtai.de/en/invest/industries/digital-economy/data-center>.
79. EMBER. *Average monthly electricity wholesale price in Czechia from January 2019 to April 2026 (in euros per megawatt-hour)* [online]. Statista, 2026-04-09 [cit. 2026-05-10]. Dostupné z: <https://www.statista.com/statistics/1314520/czechia-monthly-wholesale-electricity-price/>.
80. ROYCHOUDHURY, Saurav; ROSS, Justin; YAKOVLEV, Pavel. *Economic Impact of Data Centers in Ohio: An Interim Report*. Ohio, USA, 2025. SRC Evalmetrics. Dostupné také z: https://www.gongwer-oh.com/public/Interim_Report-DC-_2025-SRC-v4.pdf.

81. CBRE. *Global Data Center Trends 2025* [online]. 2025. [cit. 2026-05-10]. Dostupné z: <https://www.cbre.com/insights/reports/global-data-center-trends-2025>.
82. SHEHABI, Arman; SMITH, Sarah; SARTOR, Dale; BROWN, Richard; HERRLIN, Magnus; KOOMEY, Jonathan; MASANET, Eric; HORNER, Nathaniel; AZEVEDO, Inês; LINTNER, William. *United States Data Center Energy Usage Report* [online]. 2016-06-01. [cit. 2026-03-11]. LBNL-1005775, 1372902. Dostupné z DOI: 10.2172/1372902.

Obsah příloh

/	
— README.md	stručný popis obsahu média
— out	adresář s vygenerovanými výstupy
— text	text práce
— ctufit-thesis.pdf	text práce ve formátu PDF
— csv	datové exporty z analytické části
— scraped-data.csv	surová data a velikosti pozemků
— manually-enriched-data.csv	manuálně doplněná data
— transformed-data.csv	data doplněná o odhadované hodnoty
— transformed-data-analyzed.csv	agregační statistiky
— src	zdrojové kódy
— model-app	zdrojové kódy webové aplikace (React)
— scraper	skripty pro sběr a zpracování dat (Python)
— thesis	zdrojová forma práce ve formátu $\text{\LaTeX}$
— LICENSE	licenční ujednání